DriveCompose：通过联合补全实现可组合驾驶场景的生成式重建

Supplementary Material

A. 跨数据集泛化

我们评价从 Waymo 到 nuScenes 的零样本迁移，以考察模型在训练数据集之外的重建质量。将在 Waymo 上训练的检查点直接应用于 nuScenes，评价时固定全部模型参数。

如表 S1 所示，DriveCompose 在所比较方法中取得最高的 PSNR 和 SSIM，分别达到 26.47 dB 和 0.803，比表现最好的基线 DGGT 分别提高 1.16 dB 和 0.009。这些结果表明，在不进行目标域适配的情况下，DriveCompose 提升了目标数据集上的重建质量。

Table S1. 从 Waymo 到 nuScenes 的零样本泛化。PSNR 和 SSIM 越高越好。

	Zero-shot	
Method	PSNR ↑	SSIM ↑
STORM [4]	17.77	0.669
DGGT [1]	25.31	0.794
StreetForward [5]	23.17	0.712
Ours	**26.47**	**0.803**

B. 训练细节

学习分为四个阶段，使补全目标具有稳定含义。恢复模块确定证据与支撑，编解码器定义潜空间坐标，补全网络学习缺失潜码的分布。最后一个阶段将该分布适配到真实观测，同时保持其预测的表示不变。

阶段一：视觉恢复。 我们利用几何、语义、实例归属和资产标注监督图像编码器、几何头、身份槽及状态头。在整条轨迹上执行一次匹配，将槽分配给目标身份，并在所有时刻复用这一匹配。根平移、旋转和固定尺寸约束车辆状态；人体还需要身份一致的体型、模板绑定和关节监督。置信度根据几何可靠性训练或校准，依据包括深度、遮挡和重投影信息。这些目标建立聚合所需的坐标与身份一致性。

阶段二：潜表示拟合。 冻结恢复模块，训练类型专属编码器和解码器。每个样本先由部分输入建立一次查询布局，再将更完整的观测聚合到完全相同的位置、类型、顺序和归属上。这种对应关系是潜码补全的前提；若为完整场景另建布局，就会改变待预测变量。RGB、深度和轮廓监督训练解码场景，并结合空域不透明度与高斯尺度正则。高斯集合目标也可以采用集合匹配；仅在子高斯对应已知时使用直接坐标监督。

对于渲染图像 $\widehat{\mathbf{I}}$ 和深度 $\widehat{d}$，表示拟合及后续适配使用的观测项为带掩码的 L1 误差：

$$\mathcal{L}_{\text{rgb}} = \langle \|\widehat{\mathbf{I}} - \mathbf{I}\|_1/3 \rangle_{\Omega_I}, \tag{S1}$$

$$\mathcal{L}_{\text{depth}} = \langle |\widehat{d} - d| \rangle_{\Omega_d}. \tag{S2}$$

符号 $\langle \ell \rangle_\Omega$ 表示在掩码 Ω 的有效元素上取平均。深度目标 d 及其有效掩码由可用监督提供；它们不使观测检查成为独立的精度测量。

阶段三：补全先验学习。 冻结恢复模块和整个编解码器，将完整目标编码为 $\mathbf{z}_1$，并以主稿式 (10) 优化补全 Transformer。完整场景或资产样本必须为主稿式 (9) 中的每个未知查询提供有效目标，单独的部分真实日志不满足这一条件。完整场景提供跨组件上下文，完整资产提供对象内部内容；任一未知查询缺少有效目标潜码时，有效性检查会拒绝该样本。

条件掩码模拟连续未见表面、背景空洞、长时间遮挡、短轨迹和不均匀相机覆盖。对恢复位姿、实例归属和置信度施加扰动，使生成器接触不完美证据。该阶段中，目标潜码和输入潜码始终使用相同的编解码器与查询定义。

阶段四：通过渲染适配。 保持恢复模块与编解码器冻结，通过流积分、解码和渲染反向传播，仅更新补全网络。部分真实日志监督渲染观测，已知自由射线和几何后端样本约束新增内容：

$$\begin{aligned}\mathcal{L}_{\text{scene}} = {} & \lambda_e \langle a_r^2 \rangle + \lambda_g \langle [-d_f]_+^2 \rangle \\ & + \lambda_c \langle |d_f| \rangle_{\Omega_c} + \lambda_p \langle [d_p]_+^2 \rangle, \end{aligned} \tag{S3}$$

$$\mathcal{L}_{\text{adapt}} = \lambda_r \mathcal{L}_{\text{rgb}} + \lambda_d \mathcal{L}_{\text{depth}} + \mathcal{L}_{\text{scene}}. \tag{S4}$$

其中，a_r 为已知自由射线上的累积不透明度，d_f 为脚点有符号距离且地面上方为正，Ω_c 选择接地脚点，d_p 为穿透深度且另一资产内部为正。采用 $[x]_+ = \max(x, 0)$；无掩码的平均在提供的样本上计算。系数 λ 为有效约束赋权。自由射线不透明度在查询级空域掩码之外，进一步约束新增内容的渲染影响。

完整目标样本可与真实日志适配交替使用以保留先验，得到 $\mathcal{L}_4 = \lambda_f \mathcal{L}_{\text{flow}} + \mathcal{L}_{\text{adapt}}$，各项仅作用于具备所需目标的样本。已见锚点由冻结解码和潜码硬恢复维持。

推理。 日志只编码一次，随后固定支撑与证据，由补全模型积分未知潜码。解码并检查场景后，导出固定内容；运行时渲染仅使用这些内容和指定状态。恢复模块、编解码器、补全网络与查询定义的版本一并记录，因为前两者的变化会改变补全网络学习的潜分布。

C. 场景装配与检查细节

状态驱动渲染。 在线步 k 的状态 s_k 指定自车位姿、活动资产、车辆变换，以及人体根位姿与关节姿态。车辆的高斯中心和协方差变换为

$$\boldsymbol{\mu}^w = \mathbf{R}\boldsymbol{\mu}^a + \mathbf{t}, \qquad \boldsymbol{\Sigma}^w = \mathbf{R}\boldsymbol{\Sigma}^a\mathbf{R}^\top. \tag{S5}$$

人体使用加权蒙皮变换 $\mathbf{A}_i = \sum_j w_{ij}\mathbf{P}_j\mathbf{B}_j^{-1}$，其中 $\mathbf{B}_j$ 和 $\mathbf{P}_j$ 是根坐标系中的静止与当前全局关节矩阵。变换后的中心为 $\bar{\boldsymbol{\mu}}_i^w = \mathbf{T}_h^w\mathbf{A}_i\bar{\boldsymbol{\mu}}_i^h$。组合局部线性映射 $\mathbf{J}_i$ 将协方差变换为 $\mathbf{J}_i\boldsymbol{\Sigma}_i\mathbf{J}_i^\top$，其逆 $\mathbf{J}_i^{-1}$ 将观察方向映回规范坐标，并在外观求值前归一化。接近奇异的蒙皮变换被拒绝。根位姿控制整体放置，根关节保持静止变换。

渲染器合成背景、活动资产和有效天空。外部策略与动力学可推进状态：

$$o_k = \mathcal{R}(\mathrm{Compose}(\mathcal{W}, s_k), \mathcal{C}_k), \tag{S6}$$

$$s_{k+1} = F_{\mathrm{dyn}}(s_k, \pi(o_k), \Delta t). \tag{S7}$$

重置或分支轨迹改变状态，同时保留 $\mathcal{W}$ 及其种子。有限空间支撑和有效天空方向决定覆盖范围。道路网格与碰撞代理采用和视觉资产一致的坐标，由物理后端维护。

构建场景的检查。 固定已见潜码能够保持解码参数，但新增表面仍可能遮挡这些内容。接受场景之前，我们在原始相机和资产状态下渲染补全候选及仅由已见查询构成的观测参考；参考渲染关闭全部非已见查询。令 $e_{\mathrm{cand}}(p)$ 和 $e_{\mathrm{obs}}(p)$ 为像素 p 处两者的平均绝对 RGB 误差，局部退化定义为

$$\Delta e(p) = \max\{e_{\mathrm{cand}}(p) - e_{\mathrm{obs}}(p), 0\}. \tag{S8}$$

在可靠的非自车像素上平均这一量，避免某一区域的改善抵消其他区域的退化。接受条件还限制绝对 RGB 误差、有效深度误差和前景侵入率，并要求最低覆盖率；这些条件同时检查聚合结果和最差视图。前景侵入指新增渲染表面位于预测参考深度之前，且未出现在观测参考渲染中；其比例按可靠的非天空几何像素归一化。预测深度提供观测一致性参照，独立几何评测需要另一份参考。被拒绝的候选不导出复用。

D. 视觉恢复与聚合细节

共享视觉编码。 Driving Log Encoder 使用图像 patch 划分 [2] 与 Transformer 注意力 [3]，并加入图像位置、相机标定和时间编码。图像内部注意力提取空间特征，第二个 Transformer 在不同视角与时刻的池化图像摘要之间交互，再将上下文送回 patch 特征。几何头预测相机光轴深度、法线、置信度、语义和实例归属。置信度决定哪些预测可以提供表面证据。

可学习的资产查询读取全部图像 token，形成轨迹级身份槽；每个槽再读取单个时刻的特征以估计状态。由此，持久身份、尺寸和人体体型与逐帧变化的根位姿、关节旋转分开表示。根位姿先在支架坐标中预测，再通过 $\mathbf{T}_r^w(t)$ 映射到世界坐标。人体体型码选择对应身份的模板，模板包含固定规范支撑、骨架拓扑和绑定。身份槽容量限定可表示的资产数量。

查询支撑。 每个查询存储规范位置 $\mathbf{q}_i$、单元尺度 $\boldsymbol{\delta}_i$、类型 k_i、局部注意力组 g_i 和参考世界坐标 $\mathbf{q}_i^w$。可靠深度样本提供表面锚点。背景锚点与有限世界网格结合；车辆锚点经运动规范化后，与局部包围体中的网格结合。人体查询位于规范模板表面，天空查询为按立方体贴图面分组的单位方向。这些支撑为已见与缺失内容提供明确位置。

补全过程中布局保持固定。我们将查询放到第一帧的配置中以得到 $\mathbf{q}_i^w$，其中人体包含蒙皮变换。规范坐标标识组件内部的内容，参考世界坐标则使生成器能够联系该组件与周围场景。

运动感知证据聚合。 对于每份观测，我们将规范查询放到对应的资产状态：

$$\mathbf{p}_i(t) = \begin{cases} \mathbf{q}_i, & k_i = \text{background}, \\ \mathrm{xyz}(\mathbf{T}_a^w(t)\bar{\mathbf{q}}_i), & k_i = \text{vehicle}, \\ \mathrm{xyz}(\mathbf{T}_h^w(t)\mathbf{A}_i(t)\bar{\mathbf{q}}_i), & k_i = \text{human}. \end{cases} \tag{S9}$$

其中，$\bar{\mathbf{q}}_i$ 为齐次坐标，xyz 提取欧氏坐标，$\mathbf{A}_i(t)$ 为加权蒙皮变换。投影到相机后，得到深度 $z_{i,t,v}$ 以及采样特征、深度和置信度 $(\boldsymbol{\phi}_{i,t,v}, d_{i,t,v}, c_{i,t,v})$。给定容差 $\eta = \eta_{\mathrm{abs}} + \eta_{\mathrm{rel}} d$，定义 $r = (d - z)/\eta$。表面观测需位于图像内、深度有效、置信度足够，与查询的实例身份一致，并满足 $|r| \le 1$。背景查询还要求静态背景语义。令 $a_{i,t,v}$ 表示这一有效性判断，则聚合为

$$w_{i,t,v} = a_{i,t,v} c_{i,t,v} \exp(-r_{i,t,v}^2/2), \tag{S10}$$

$$\mathbf{h}_i = \frac{\sum_{t,v} w_{i,t,v}[\boldsymbol{\phi}_{i,t,v}; r_{i,t,v}]}{\max(\varepsilon, \sum_{t,v} w_{i,t,v})}. \tag{S11}$$

查询置信度取被接受观测中的最大值。该筛选排除深度或实例身份与查询不一致的观测。仅当整个支撑单元都位于观测表面之前时，可靠射线才提供自由空间票：

$$z_{i,t,v} + \tfrac{1}{2}\|\boldsymbol{\delta}_i\|_2 < d_{i,t,v} - \eta. \tag{S12}$$

有效观测权重之和大于零时，查询被标为已见。否则，足够的自由空间票将其标为自由空间，其余查询为未知。掩码 m_i、f_i 和 u_i 互斥，满足 $m_i + f_i + u_i = 1$。天空投影仅使用相机旋转，采用可靠天空语义和零深度残差，不接收自由空间票。

References

[1] Xiaoxue Chen, Ziyi Xiong, Yuantao Chen, Gen Li, Nan Wang, Hongcheng Luo, Long Chen, Haiyang Sun, Bing Wang, Guang Chen, Hongyang Li, Ya-Qin Zhang, Hangjun Ye, and Hao Zhao. DGGT: Feedforward 4D Reconstruction of Dynamic Driving Scenes using Unposed Images. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 1265–1276, 2026. 1

[2] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. In *International Conference on Learning Representations (ICLR)*, 2021. 2

[3] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Ł ukasz Kaiser, and Illia Polosukhin. Attention is All you Need. In *Advances in Neural Information Processing Systems*, 2017. 2

[4] Jiawei Yang, Jiahui Huang, Boris Ivanovic, Yuxiao Chen, Yan Wang, Boyi Li, Yurong You, Apoorva Sharma, Maximilian Igl, Peter Karkus, Danfei Xu, Yue Wang, and Marco Pavone. STORM: Spatio-TempOral Reconstruction Model For Large-Scale Outdoor Scenes. In *International Conference on Learning Representations*, pages 50446–50465, 2025. 1

[5] Zhongrui Yu, Zhao Wang, Yijia Xie, Yida Wang, Xueyang Zhang, Yifei Zhan, and Kun Zhan. StreetForward: Perceiving Dynamic Street with Feedforward Causal Attention. *arXiv preprint arXiv:2603.19552*, 2026. 1