DriveCompose：通过联合补全实现驾驶场景的可组合生成式重建

Supplementary Material

A. 跨数据集泛化

我们评价从 Waymo 到 nuScenes 的零样本迁移，以考察模型在训练数据集之外的重建质量。将在 Waymo 上训练的检查点直接应用于 nuScenes，评价时固定全部模型参数。

如表 S1 所示，DriveCompose 在所比较方法中取得最高的 PSNR 和 SSIM，分别达到 26.47 dB 和 0.803，比表现最好的基线 DGGT 分别提高 1.16 dB 和 0.009。这些结果表明，在不进行目标域适配的情况下，DriveCompose 提升了目标数据集上的重建质量。

Table S1. 从 Waymo 到 nuScenes 的零样本泛化。PSNR 和 SSIM 越高越好。

	Zero-shot	
Method	PSNR ↑	SSIM ↑
STORM [4]	17.77	0.669
DGGT [1]	25.31	0.794
StreetForward [5]	23.17	0.712
Ours	**26.47**	**0.803**

B. 训练细节

学习分为四个阶段，使补全目标具有稳定含义。恢复模块确定证据与支撑，编解码器定义潜空间坐标，补全网络学习缺失潜码的分布。最后一个阶段将该分布适配到真实观测，同时保持其预测的表示不变。

阶段一：视觉恢复。 我们利用几何、语义、实例归属和资产标注监督图像编码器、几何头、身份槽及状态头。在整条轨迹上执行一次匹配，将槽分配给目标身份，并在所有时刻复用这一匹配。根平移、旋转和固定尺寸约束刚体资产状态；人体还需要身份一致的体型、模板绑定和关节监督。置信度根据几何可靠性训练或校准，依据包括深度、遮挡和重投影信息。这些目标建立聚合所需的坐标与身份一致性。

阶段二：潜表示拟合。 冻结恢复模块，训练类型专属编码器和解码器。每个样本先由部分输入建立一次查询布局，再将更完整的观测聚合到完全相同的位置、类型、顺序和归属上。共享布局使部分观测与完整目标逐查询对应。RGB、深度和轮廓监督训练解码场景，并结合空域不透明度与高斯尺度正则。高斯集合目标也可以采用集合匹配；仅在子高斯对应已知时使用直接坐标监督。

对于渲染图像 $\widehat{\mathbf{I}}$ 和深度 $\widehat{d}$，表示拟合及后续适配使用的观测项为带掩码的 L1 误差：

$$\mathcal{L}_{\text{rgb}} = \langle \|\widehat{\mathbf{I}} - \mathbf{I}\|_1/3 \rangle_{\Omega_I}, \tag{S1}$$

$$\mathcal{L}_{\text{depth}} = \langle |\widehat{d} - d| \rangle_{\Omega_d}. \tag{S2}$$

符号 $\langle \ell \rangle_\Omega$ 表示在掩码 Ω 的有效元素上取平均。深度目标 d 及其有效掩码由可用监督提供。

阶段三：补全先验学习。 冻结恢复模块和整个编解码器，将完整目标编码为 $\mathbf{z}_1$，并以主稿式 (9) 优化补全 Transformer。完整场景或资产样本为主稿式 (8) 中的未知查询提供目标潜码。完整场景提供跨组件上下文，完整资产提供对象内部的几何与外观。

条件掩码模拟连续未见表面、背景空洞、长时间遮挡、短轨迹和不均匀相机覆盖。对恢复位姿、实例归属和置信度施加扰动，使生成器接触不完美证据。该阶段中，目标潜码和输入潜码始终使用相同的编解码器与查询定义。

阶段四：通过渲染适配。 保持恢复模块与编解码器冻结，通过流积分、解码和渲染反向传播，仅更新补全网络。部分真实日志监督渲染观测，已知自由射线和几何后端样本约束新增内容：

$$\begin{aligned}\mathcal{L}_{\text{scene}} = {} & \lambda_e \langle a_r^2 \rangle + \lambda_g \langle [-d_f]_+^2 \rangle \\ & + \lambda_c \langle |d_f| \rangle_{\Omega_c} + \lambda_p \langle [d_p]_+^2 \rangle, \end{aligned} \tag{S3}$$

$$\mathcal{L}_{\text{adapt}} = \lambda_r \mathcal{L}_{\text{rgb}} + \lambda_d \mathcal{L}_{\text{depth}} + \mathcal{L}_{\text{scene}}. \tag{S4}$$

其中，a_r 为已知自由射线上的累积不透明度，d_f 为脚点有符号距离且地面上方为正，Ω_c 选择接地脚点，d_p 为穿透深度且另一资产内部为正。采用 $[x]_+ = \max(x, 0)$；无掩码的平均在提供的样本上计算。系数 λ 为有效约束赋权。自由射线不透明度在查询级空域掩码之外，进一步约束新增内容的渲染影响。

完整目标样本可与真实日志适配交替使用以保留先验，得到 $\mathcal{L}_4 = \lambda_f \mathcal{L}_{\text{flow}} + \mathcal{L}_{\text{adapt}}$，各项仅作用于具备所需目标的样本。已见锚点由冻结解码和潜码硬恢复维持。

推理。 日志只编码一次，随后固定支撑与证据，由补全模型积分未知潜码。分类型解码器生成背景与规范资产，渲染时按指定相机与参与者状态组合这些固定组件。

C. 场景组合细节

状态驱动渲染。 在线步 k 的状态 s_k 指定自车位姿、活动资产、刚体变换，以及人体根位姿与关节姿态。刚体资产的高斯中心和协方差变换为

$$\boldsymbol{\mu}^w = \mathbf{R}\boldsymbol{\mu}^a + \mathbf{t}, \qquad \boldsymbol{\Sigma}^w = \mathbf{R}\boldsymbol{\Sigma}^a\mathbf{R}^\top. \tag{S5}$$

人体使用加权蒙皮变换 $\mathbf{A}_i = \sum_j w_{ij}\mathbf{P}_j\mathbf{B}_j^{-1}$，其中 $\mathbf{B}_j$ 和 $\mathbf{P}_j$ 是根坐标系中的静止与当前全局关节矩阵。变换后的中心为 $\bar{\boldsymbol{\mu}}_i^w = \mathbf{T}_h^w\mathbf{A}_i\bar{\boldsymbol{\mu}}_i^h$。组合局部线性映射 $\mathbf{J}_i$ 将协方差变换为 $\mathbf{J}_i\boldsymbol{\Sigma}_i\mathbf{J}_i^\top$，其逆 $\mathbf{J}_i^{-1}$ 将观察方向映回规范坐标，并在外观求值前归一化。上述逆映射使用非奇异蒙皮变换。根位姿控制整体放置，根关节保持静止变换。

渲染器合成背景、活动资产和有效天空。外部策略与动力学可推进状态：

$$o_k = \mathcal{R}(\mathrm{Compose}(\mathcal{W}, s_k), \mathcal{C}_k), \tag{S6}$$

$$s_{k+1} = F_{\mathrm{dyn}}(s_k, \pi(o_k), \Delta t). \tag{S7}$$

相机与参与者状态变化时复用同一背景和规范资产。道路网格、碰撞代理与视觉组件采用相同坐标，可由物理仿真器驱动其运动。

D. 视觉恢复与聚合细节

输入约定与预处理。 输入是同步图像 $\mathbf{I}_{t,v}$、时间戳、内参 $\mathbf{K}_v$ 及相机到传感器支架的标定 $\mathbf{T}_{c_v}^r$。支架位姿 $\mathbf{T}_r^w(t)$ 由日志提供，或以第一帧为参考估计；相机位姿为 $\mathbf{T}_{c_v}^w(t) = \mathbf{T}_r^w(t)\mathbf{T}_{c_v}^r$。变换作用于列向量，距离单位为米。图像采用校正后的针孔模型与线性 RGB；畸变、滚动快门和曝光差异在证据聚合之前处理。

共享视觉编码。 Driving Log Encoder 使用图像 patch 划分 [2] 与 Transformer 注意力 [3]，并加入图像位置、相机标定和时间编码。图像内部注意力提取空间特征，第二个 Transformer 在不同视角与时刻的池化图像摘要之间交互，再将上下文送回 patch 特征。几何头预测相机光轴深度、法线、置信度、语义和实例归属。置信度决定哪些预测可以提供表面证据。

可学习的资产查询读取全部图像 token，形成轨迹级身份槽；每个槽再读取单个时刻的特征以估计状态。由此，持久身份、尺寸和人体体型与逐帧变化的根位姿、关节旋转分开表示。根位姿先在支架坐标中预测，再通过 $\mathbf{T}_r^w(t)$ 映射到世界坐标。人体体型码选择对应身份的模板，模板包含固定规范支撑、骨架拓扑和绑定。身份槽容量限定可表示的资产数量。

查询支撑。 每个查询存储规范位置 $\mathbf{q}_i$、单元尺度 $\boldsymbol{\delta}_i$、类型 k_i、局部注意力组 g_i 和参考世界坐标 $\mathbf{q}_i^w$。可靠深度样本提供表面锚点。背景锚点与有限世界网格结合；刚体锚点经逆 SE(3) 变换对齐后，与局部包围体中的网格结合。人体查询位于规范模板表面，天空查询为按立方体贴图面分组的单位方向。这些支撑为已见与缺失内容提供明确位置。

补全过程中布局保持固定。我们将查询放到第一帧的配置中以得到 $\mathbf{q}_i^w$，其中人体包含蒙皮变换。规范坐标标识组件内部的内容，参考世界坐标则使生成器能够联系该组件与周围场景。

运动感知证据聚合。 对于每份观测，我们将规范查询放到对应的资产状态：

$$\mathbf{p}_i(t) = \begin{cases} \mathbf{q}_i, & k_i = \text{background}, \\ \mathrm{xyz}(\mathbf{T}_a^w(t)\bar{\mathbf{q}}_i), & k_i = \text{rigid}, \\ \mathrm{xyz}(\mathbf{T}_h^w(t)\mathbf{A}_i(t)\bar{\mathbf{q}}_i), & k_i = \text{human}. \end{cases} \tag{S8}$$

其中，$\bar{\mathbf{q}}_i$ 为齐次坐标，xyz 提取欧氏坐标，$\mathbf{A}_i(t)$ 为加权蒙皮变换。投影到相机后，得到深度 $z_{i,t,v}$ 以及采样特征、深度和置信度 $(\boldsymbol{\phi}_{i,t,v}, d_{i,t,v}, c_{i,t,v})$。给定容差 $\eta = \eta_{\mathrm{abs}} + \eta_{\mathrm{rel}}d$，定义 $r = (d - z)/\eta$。表面观测需位于图像内、深度有效、置信度足够，与查询的实例身份一致，并满足 $|r| \le 1$。背景查询还要求静态背景语义。令 $a_{i,t,v}$ 表示这一有效性判断，则聚合为

$$w_{i,t,v} = a_{i,t,v}c_{i,t,v}\exp(-r_{i,t,v}^2/2), \tag{S9}$$

$$\mathbf{h}_i = \frac{\sum_{t,v} w_{i,t,v}[\boldsymbol{\phi}_{i,t,v}; r_{i,t,v}]}{\max(\varepsilon, \sum_{t,v} w_{i,t,v})}. \tag{S10}$$

查询置信度取被接受观测中的最大值。该筛选排除深度或实例身份与查询不一致的观测。仅当整个支撑单元都位于观测表面之前时，可靠射线才提供自由空间票：

$$z_{i,t,v} + \tfrac{1}{2}\|\boldsymbol{\delta}_i\|_2 < d_{i,t,v} - \eta. \tag{S11}$$

有效观测权重之和大于零时，查询被标为已见。否则，足够的自由空间票将其标为自由空间，其余查询为未知。掩码 m_i、f_i 和 u_i 互斥，满足 $m_i + f_i + u_i = 1$。天空投影仅使用相机旋转，采用可靠天空语义和零深度残差，不接收自由空间票。

E. 高斯解码细节

每个高斯存储中心 $\boldsymbol{\mu}$、协方差 $\boldsymbol{\Sigma}$、不透明度 α 和方向外观。

背景、刚体和人体高斯解码器分别将每个查询独立映射为 K 个子高斯。查询 i 的子高斯 k 的中心被限制在其支撑单元内：

$$\boldsymbol{\mu}_{i,k} = \mathbf{q}_i + \tfrac{1}{2}\boldsymbol{\delta}_i \odot \tanh(\mathbf{b}_{i,k}). \tag{S12}$$

正尺度与归一化旋转确定正定协方差。不透明度乘以 $1 - f_i$，使自由空间查询不能产生可见高斯。人体子高斯继承支撑查询的蒙皮权重；刚体子高斯共用所属

资产的刚体变换。独立天空头预测立方体贴图颜色，并在 V_{sky} 中保留观测支持的方向域。

外观为每个颜色通道存储常数 RGB 项和三个局部方向系数，按 $c(d) = \max(0, c_0 + C_{\text{app}}\hat{d}_{\text{local}})$ 求值。解码逐查询执行：编解码器冻结后，不变的已见潜码产生不变的高斯参数。补全网络可以在查询之间交换上下文，同时保留这一解码性质。

References

[1] Xiaoxue Chen, Ziyi Xiong, Yuantao Chen, Gen Li, Nan Wang, Hongcheng Luo, Long Chen, Haiyang Sun, Bing Wang, Guang Chen, Hongyang Li, Ya-Qin Zhang, Hangjun Ye, and Hao Zhao. DGGT: Feedforward 4D Reconstruction of Dynamic Driving Scenes using Unposed Images. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 1265–1276, 2026. 1

[2] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. In *International Conference on Learning Representations (ICLR)*, 2021. 2

[3] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Ł ukasz Kaiser, and Illia Polosukhin. Attention is All you Need. In *Advances in Neural Information Processing Systems*, 2017. 2

[4] Jiawei Yang, Jiahui Huang, Boris Ivanovic, Yuxiao Chen, Yan Wang, Boyi Li, Yurong You, Apoorva Sharma, Maximilian Igl, Peter Karkus, Danfei Xu, Yue Wang, and Marco Pavone. STORM: Spatio-TempOral Reconstruction Model For Large-Scale Outdoor Scenes. In *International Conference on Learning Representations*, pages 50446–50465, 2025. 1

[5] Zhongrui Yu, Zhao Wang, Yijia Xie, Yida Wang, Xueyang Zhang, Yifei Zhan, and Kun Zhan. StreetForward: Perceiving Dynamic Street with Feedforward Causal Attention. *arXiv preprint arXiv:2603.19552*, 2026. 1