DriveCompose：通过联合补全实现驾驶场景的可组合生成式重建

Supplementary Material

A. 跨数据集泛化

我们在 nuScenes 的 150 个验证场景上评价 Waymo 训练权重的零样本迁移。每场景选一个固定的 20 帧连续相机片段，采用 FRONT、FRONT_LEFT 和 FRONT_RIGHT。按原生相机时间戳采样，片段约 1.67 s。输入索引为 $\{0, 5, 10, 15\}$，其余 16 帧评价，共 150 个片段、1,800 张上下文图像与 7,200 张目标图像，其中插值 5,400 张、外推 1,800 张，输出为 240×160。

给定相机与参与者状态的条件以及统一状态适配器与 Waymo 相同。网络、codec 和归一化参数全部冻结，不训练目标域权重或执行场景适配。表 S1 为均值及训练种子样本 SD。Ours 相比 DGGT 提高 1.16 dB PSNR 与 0.009 SSIM，支持固定条件下的跨数据集重建迁移。各数据集保留原生相机时序。

Table S1. nuScenes 零样本重建。均值 ± 训练种子 SD。

方法	PSNR ↑	SSIM ↑
STORM	17.77 ± 0.12	0.669 ± 0.003
DGGT	25.31 ± 0.08	0.794 ± 0.002
StreetForward	23.17 ± 0.10	0.712 ± 0.003
Ours	**26.47 ± 0.07**	**0.803 ± 0.002**

B. 训练细节

学习分为四个阶段，使补全目标具有稳定含义。恢复模块确定证据与支撑，编解码器定义潜空间坐标，补全网络学习缺失潜码的分布。最后一个阶段将该分布适配到真实观测，同时保持其预测的表示不变。

数据组成与划分。 表 S2 的数量均为质量检查后的有效数据。Waymo 原训练集划分为 740 条训练与 58 条开发序列，开发集用于选模，202 条验证序列用于测试。合成地图、车辆基础模型及人体身份按源资产隔离；同一模型的不同纹理、同一人体的不同服装及动作留在同一划分。真实日志按路段、连续采集片段和可识别身份去重隔离。完整性指有限查询支撑内的几何、材质与运动绑定目标完整性。

合成测试划分中，100 个场景用于隐藏表面的配对评价，20 个场景用于资产编辑；另在 20 个真实场景上评价固定资产复用（附录 H 和 I）。

固定布局上的完整目标。 部分输入建立 $\mathcal{Q}$。两个分支使用相同的查询位置、尺度、类型和顺序，并共享组件归属与人体绑定，沿用 `QueryBundle.blocks` 的块顺序及块内索引。完整网格沿该固定支撑查询。对非天空查询，将所属组件网格转换到查询坐标系，与支撑单元 B_i 求交；非零面积的相交三角片提供表面目标。资产完整性检查通过且没有相交表面的单元采用无表面目标。

面积为 A_f 的相交三角片 f 采用

$$n_f = \max\left(1, \left\lceil \frac{64 A_f}{\delta_{\min}^2} \right\rceil\right) \tag{S1}$$

个确定性面积样本，$\delta_{\min}$ 为单元最短边。资产、查询和三角片编号共同确定采样位置。在固定照明与原始材质下渲染 RGB、光轴深度、实例及三角片编号。基础视图包含八个方位角和三个仰角，局部隔离视图覆盖剩余相交片，为基础视图中被遮挡的表面提供特征。

阶段一训练后冻结的同一视觉编码器将渲染 RGB 映射为 128 维特征。在各表面样本投影处提取特征，附加相对查询中心的归一化深度残差，并截断至 $[-1, 1]$。先在每个样本的有效视图间按观测权重平均，再按相交片面积聚合，形成 $\mathbf{h}_i^{\text{full}} \in \mathbb{R}^{129}$。部分分支沿用查询中心投影和可见性加权聚合。

无表面单元采用 129 维零特征和明确的零不透明度监督。无表面目标描述网格表面的缺失，自由空间标签来自观测射线。天空目标由完整环境贴图提供，深度残差为零。两分支共享视觉特征基、输入格式和类型专属 codec，目标潜码为

$$\mathbf{z}_{1,i} = E_{k_i}([\mathbf{h}_i^{\text{full}}; \mathbf{q}_i; \boldsymbol{\delta}_i]) \in \mathbb{R}^{128}. \tag{S2}$$

135 维输入依次通过 $135 \to 128 \to 128$ MLP 与 LayerNorm。编码器偏置允许零特征映射为非零潜码；补全过程的硬投影另行将自由空间潜码清零。

阶段一：视觉恢复。 真实训练日志与合成场景监督图像编码器、几何预测头、身份槽和状态头。真实深度来自训练 LiDAR，车辆状态来自标注；带置信度的真实语义及人体关节辅助标签，与合成体型、骨架、绑定和关节监督共同训练恢复模块。整条轨迹执行一次身份匹配，并在各时刻复用。置信度根据深度、遮挡和重投影可靠性训练或校准，各项权重见表 S4。

阶段二：潜表示拟合。 冻结恢复模块，以合成场景和完整资产训练 codec，并使用真实 RGB、深度及轮廓观测。目标为

$$\begin{aligned}\mathcal{L}_2 = \mathcal{L}_{\text{rgb}} + 0.1\mathcal{L}_{\text{depth}} + 0.2\mathcal{L}_{\text{silhouette}} \\ + 0.05\mathcal{L}_{\text{empty}} + 0.001\mathcal{L}_{\text{scale}}.\end{aligned} \tag{S3}$$

渲染 RGB $\widehat{\mathbf{I}}$ 和深度 $\widehat{d}$ 的观测损失为带掩码的 L1 均值：

$$\mathcal{L}_{\text{rgb}} = \langle \|\widehat{\mathbf{I}} - \mathbf{I}\|_1 / 3 \rangle_{\Omega_I}, \tag{S4}$$

$$\mathcal{L}_{\text{depth}} = \langle |\widehat{d} - d| \rangle_{\Omega_d}. \tag{S5}$$

Table S2. 数据与监督来源。场景地图和独立资产均按源身份划分。

数据	训练	开发	测试	监督
Waymo 序列	740	58	202	图像、标定、自车位姿、LiDAR、车辆框与轨迹
自建合成场景	10,000	1,000	1,000	完整几何、材质、深度、语义、实例及演员状态
合成场景地图	80	10	10	静态背景几何及道路结构
独立车辆资产	10,000	1,000	1,000	完整规范几何、材质、尺寸及刚体坐标系
独立人体身份	2,500	250	250	身份体型、纹理、规范模板、骨架、蒙皮及关节状态

Table S3. 网络与空间支撑配置。基础网格另保留观测锚点和规范人体模板查询。

模块	配置
视觉恢复	宽度 128，patch 尺寸 16，4 头；1 层图像注意力和 2 层跨视图 / 时刻摘要交互
身份与人体状态	24 个身份槽，10 维体型码，17 关节接口
查询特征与潜码	特征 129 维，潜码 128 维；分类型 $135 \to 128 \to 128$ 编码器及 LayerNorm
补全网络	宽度 128，4 层，4 头，16 个可学习记忆 token
高斯解码	每查询 4 个子高斯，每个 23 个输出参数，其中外观参数 12 个
方向外观	每颜色通道包含常数项和三个局部方向系数
基础支撑	背景 $20 \times 12 \times 6$（单元 $5 \times 5 \times 3$ m），刚体实际包围盒内 $8 \times 4 \times 4$，天空每面 4×4
采样	24 步显式 Euler，每步恢复已见潜码并清零自由空间潜码

Table S4. 阶段一监督权重。

损失	权重	损失	权重
深度	1.0	根旋转	0.2
法线	0.2	尺寸	0.1
语义	0.1	人体体型	0.1
实例	0.1	关节	0.2
根平移	0.5	置信度	0.1

$\langle \ell \rangle_\Omega$ 表示在有效元素上平均。无表面单元采用不透明度平方损失 $\mathcal{L}_{\text{empty}}$，并结合轮廓监督和高斯尺度正则。阶段二结束后冻结恢复模块与 codec，编码生成先验学习使用的固定完整目标 $\mathbf{z}_1$。

阶段三：补全先验学习。 GCM 学习主稿式 (9) 中的未知查询流匹配目标。接纳的合成样本在每个未知查询上均具有有效几何、外观与绑定目标；未知目标无效的样本退出本阶段，损失选择器 s_i 作用于有效目标内部。完整场景提供跨组件上下文，完整资产提供对象几何与外观。条件掩码模拟连续未见表面、背景空洞、长遮挡和短轨迹，以及不均匀相机覆盖。对位姿、实例和置信度施加扰动，使生成器接触恢复误差。

阶段四：通过渲染适配。 通过流积分、解码和渲染反向传播，仅更新 GCM。完整合成样本与 740 条训练序列的真实日志以 1:3 混合，目标为

$$\mathcal{L}_4 = \mathcal{L}_{\text{flow}} + \mathcal{L}_{\text{rgb}} + 0.1\mathcal{L}_{\text{depth}} + 0.05\mathcal{L}_{\text{free}} + 0.1\mathcal{L}_{\text{ground}} + 0.1\mathcal{L}_{\text{contact}} + 0.1\mathcal{L}_{\text{penetration}}. \quad \text{(S6)}$$

Flow 项使用完整合成样本，观测和几何项分别使用具有对应监督的样本，各项按自身有效元素平均。令 a_r 为自由射线累计不透明度，d_f 为地面上方取正的脚部有符号距离，Ω_c 为接地脚部，d_p 为进入其他参与者内部时取正的穿透深度，几何项为

$$\mathcal{L}_{\text{free}} = \langle a_r^2 \rangle, \qquad \mathcal{L}_{\text{ground}} = \langle [-d_f]_+^2 \rangle,$$
$$\mathcal{L}_{\text{contact}} = \langle |d_f| \rangle_{\Omega_c}, \qquad \mathcal{L}_{\text{penetration}} = \langle [d_p]_+^2 \rangle, \quad \text{(S7)}$$

其中 $[x]_+ = \max(x, 0)$。冻结解码器和潜码硬恢复共同保持已见锚点。

优化与推理。 四阶段设置见表 S5。训练使用八张 A100 80 GB、FP16 和 AdamW，$\beta = (0.9, 0.95)$，weight decay 为 0.01；各阶段预热后采用余弦学习率衰减。58 条开发序列用于选模，202 条验证序列用于测试。四阶段共更新 287,360 步，消耗 1,001.5 GPU 小时，包含方法专用目标预处理。各阶段成本依次为 278.6、184.3、326.9 和 211.7 GPU 小时。三个 GCM 训练种子共享恢复模块与 codec，总成本为 2,078.7 GPU 小时。w/o CCM 复用阶段一、二，以相同预算重训阶段三、四；确定性的 w/o GCM 使用固定恢复模块和 codec。

推理时对日志编码一次，在 24 步 Euler 积分中固定查询布局与已见潜码，再由分类型解码器生成资产，供不同状态反复装配。

C. 场景组合细节

状态驱动渲染。 在线步 k 的状态 s_k 指定自车位姿、活动资产、刚体变换，以及人体根位姿与关节姿态。刚体资产的高斯中心和协方差变换为

Table S5. 四阶段训练设置。R 为恢复模块，C 为 codec，G 为 GCM。D_R 表示真实训练日志，D_S 为合成场景，D_A 为完整资产。batch 为全局大小。

阶段	更新	冻结	数据	更新步数	Batch	初始学习率
视觉恢复	R	–	D_R, D_S	86,208	32	2×10^{-4}
潜表示拟合	C	R	D_S, D_A, D_R	57,472	32	3×10^{-4}
补全先验	G	R, C	完整 D_S, D_A	114,944	32	10^{-4}
渲染适配	G	R, C	$D_S : D_R = 1:3$	28,736	8	3×10^{-5}

$$\boldsymbol{\mu}^w = \mathbf{R}\boldsymbol{\mu}^a + \mathbf{t}, \qquad \boldsymbol{\Sigma}^w = \mathbf{R}\boldsymbol{\Sigma}^a\mathbf{R}^\top. \tag{S8}$$

人体使用加权蒙皮变换 $\mathbf{A}_i = \sum_j w_{ij}\mathbf{P}_j\mathbf{B}_j^{-1}$，其中 $\mathbf{B}_j$ 和 $\mathbf{P}_j$ 是根坐标系中的静止与当前全局关节矩阵。权重满足 $w_{ij} \geq 0$、$\sum_j w_{ij} = 1$，因此静止状态 $\mathbf{P}_j = \mathbf{B}_j$ 下有 $\mathbf{A}_i = \mathbf{I}$。变换后的中心为 $\bar{\boldsymbol{\mu}}_i^w = \mathbf{T}_h^w\mathbf{A}_i\bar{\boldsymbol{\mu}}_i^h$。组合局部线性映射 $\mathbf{J}_i$ 将协方差变换为 $\mathbf{J}_i\boldsymbol{\Sigma}_i\mathbf{J}_i^\top$，其逆 $\mathbf{J}_i^{-1}$ 将观察方向映回规范坐标，并在外观求值前归一化。上述逆映射使用非奇异蒙皮变换。根位姿控制整体放置，根关节保持静止变换。

渲染器合成背景、活动资产和有效天空。外部策略与动力学可推进状态：

$$o_k = \mathcal{R}(\mathrm{Compose}(\mathcal{W}, s_k), \mathcal{C}_k), \tag{S9}$$

$$s_{k+1} = F_{\mathrm{dyn}}(s_k, \pi(o_k), \Delta t). \tag{S10}$$

相机与参与者状态变化时复用同一背景和规范资产。道路网格、碰撞代理与视觉组件采用相同坐标，可由物理仿真器驱动其运动。

D. 视觉恢复与聚合细节

输入约定与预处理。 输入是同步图像 $\mathbf{I}_{t,v}$、时间戳、内参 $\mathbf{K}_v$ 及相机到传感器支架的标定 $\mathbf{T}_{c_v}^r$。支架位姿 $\mathbf{T}_r^w(t)$ 在受控评价中统一给定，并以第一帧为参考；相机位姿为 $\mathbf{T}_{c_v}^w(t) = \mathbf{T}_r^w(t)\mathbf{T}_{c_v}^r$。变换作用于列向量，距离单位为米。图像采用校正后的针孔模型与线性 RGB；畸变、滚动快门和曝光差异在证据聚合之前处理。

共享视觉编码。 Driving Log Encoder 使用图像 patch 划分 [1] 与 Transformer 注意力 [3]，并加入图像位置、相机标定和时间编码。图像内部注意力提取空间特征，第二个 Transformer 在不同视角与时刻的池化图像摘要之间交互，再将上下文送回 patch 特征。几何头预测相机光轴深度、法线、置信度、语义和实例归属。置信度决定哪些预测可以提供表面证据。

可学习的资产查询读取全部图像 token，形成轨迹级身份槽；每个槽再读取单个时刻的特征以估计状态。由此，持久身份、尺寸和人体体型与逐帧变化的根位姿、关节旋转分开表示。根位姿先在支架坐标中预测，再通过 $\mathbf{T}_r^w(t)$ 映射到世界坐标。人体体型码选择对应身份的模板，模板包含固定规范支撑、骨架拓扑和绑定。身份槽容量限定可表示的资产数量。

查询支撑。 每个查询存储规范位置 $\mathbf{q}_i$、单元尺度 $\boldsymbol{\delta}_i$、类型 k_i、局部注意力组 g_i 和参考世界坐标 $\mathbf{q}_i^w$。可靠深度样本提供表面锚点。背景锚点与有限世界网格结合；刚体锚点经逆 SE(3) 变换对齐后，与局部包围体中的网格结合。人体查询位于规范模板表面，天空查询为按立方体贴图面分组的单位方向。这些支撑为已见与缺失内容提供明确位置。

补全过程中布局保持固定。我们将查询放到第一帧的配置中以得到 $\mathbf{q}_i^w$，其中人体包含蒙皮变换。规范坐标标识组件内部的内容，参考世界坐标则使生成器能够联系该组件与周围场景。

米制支撑与锚点选择。 背景基础网格覆盖 $[-20, 80] \times [-30, 30] \times [-3, 15]$ m，包含 $20 \times 12 \times 6$ 个单元，单元尺度为 $5 \times 5 \times 3$ m；最多补入 2,048 个边长 0.20 m 的观测锚点。每辆车在实际包围盒内使用 $8 \times 4 \times 4$ 网格，单元边长为 $(L/8, W/4, H/4)$，另含最多 512 个边长 0.20 m 的观测锚点。人体查询位于规范模板表面，支撑邻域边长为 0.10 m。天空为六个 cubemap 面，每面 4×4 个方向查询。背景注意力按 4 m 空间桶分组，分组尺度与支撑单元尺度分别设置。

有效估计深度在各分支坐标系中生成锚点。按空间桶索引 $\lfloor \mathbf{p}/0.20 \rfloor$ 去重，同桶保留首次出现的点；超过分支上限后，按有序唯一桶列表的索引等间隔选取。锚点保留深度采样得到的位置。人体查询在补全前携带模板绑定权重，四个解码子高斯继承相应权重。根位姿负责整体放置，内部根关节保留静止变换。

运动感知证据聚合。 对于每份观测，我们将规范查询放到对应的资产状态：

$$\mathbf{p}_i(t) = \begin{cases} \mathbf{q}_i, & k_i = \text{background}, \\ \mathrm{xyz}(\mathbf{T}_a^w(t)\bar{\mathbf{q}}_i), & k_i = \text{rigid}, \\ \mathrm{xyz}(\mathbf{T}_h^w(t)\mathbf{A}_i(t)\bar{\mathbf{q}}_i), & k_i = \text{human}. \end{cases} \tag{S11}$$

其中，$\bar{\mathbf{q}}_i$ 为齐次坐标，xyz 提取欧氏坐标，$\mathbf{A}_i(t)$ 为加权蒙皮变换。投影到相机后，得到深度 $z_{i,t,v}$ 以及采样特征、深度和置信度 $(\boldsymbol{\phi}_{i,t,v}, d_{i,t,v}, c_{i,t,v})$。给定容差 $\eta = \eta_{\mathrm{abs}} + \eta_{\mathrm{rel}} d$，定义 $r = (d - z)/\eta$。表面观测需位于图像内、深度有效、置信度足够，与查询的实例身份一致，并满足 $|r| \leq 1$。背景查询还要求静态背景语义。令 $a_{i,t,v}$ 表示这一有效性判断，则聚合为

$$w_{i,t,v} = a_{i,t,v} c_{i,t,v} \exp(-r_{i,t,v}^2/2), \tag{S12}$$

$$\mathbf{h}_i = \frac{\sum_{t,v} w_{i,t,v} [\boldsymbol{\phi}_{i,t,v}; r_{i,t,v}]}{\max(\varepsilon, \sum_{t,v} w_{i,t,v})}. \tag{S13}$$

查询置信度取被接受观测中的最大值。主重建协议采用中心射线规则 C，深度容差为 $\eta = 0.15 + 0.02d$ m，置信度阈值为 0.8。可靠查询中心射线满足下式时提供自由空间票：

$$z_{i,t,v} + \tfrac{1}{2}\|\boldsymbol{\delta}_i\|_2 < d_{i,t,v} - \eta. \tag{S14}$$

观测权重为正的查询标为已见；其余查询至少获得两票时标为自由空间，否则保持未知。天空投影使用相机旋转、可靠天空语义和零深度残差，不接收自由空间票。

足迹规则与下游重建。 在 100 个合成测试场景的固定查询布局上，比较中心射线投票与足迹判据。足迹判据依据查询的刚体或蒙皮变换放置单元八个顶点，并计算

$$z_{i,t,v}^{\max} = \max_{x \in B_i(t)} z_v(x), \qquad \Omega_{i,t,v} = \pi_v(B_i(t)). \tag{S15}$$

投影足迹向外取整，覆盖全部相交深度像素。单视图要求足迹完全位于图像内、深度全部有效、置信度均不低于 0.8，且不含天空或自车像素，并满足

$$z_{i,t,v}^{\max} < \min_{p \in \Omega_{i,t,v}} \left[D_{t,v}(p) - 0.15 - 0.02 D_{t,v}(p) \right]. \tag{S16}$$

满足全部条件的视图投票，其余视图弃权。两票规则、已见表面优先及硬清零机制保持一致。

足迹判据将占据单元误标从 1,374 个降至 19 个（表 S6）。使用参考深度时，中心判据仍误标 934 个占据单元，将一部分错误定位到单元的横向覆盖。连续参考深度的完整足迹下界在该审计集合中误标为零；离散估计深度下的 19 个剩余错误主要位于亚像素结构和深度边界。

从掩码标签到重建表面。 两种规则从首次硬清零前的同一中间状态出发，固定权重、查询布局、输入深度、后处理与逐查询随机噪声。在相同的 100 场景隐藏区域评价上，F 将 PSNR 提高 0.18 dB、覆盖率提高 1.2 个百分点、F-score 提高 1.3 个百分点（表 S7）。薄结构、遮挡边界与人体隐藏表面覆盖率分别提高 2.7、2.2 和 1.0 个百分点。人体语义切片可与结构切片重叠，分别计分。这里的覆盖率统一采用 2 cm 点到网格阈值，人体资产编辑仍采用 1 cm。

掩码审计以 99,184 个含参考表面的查询单元为分母，互斥分类描述单元标签错误；隐藏表面覆盖率通过面积均匀采样衡量参考表面召回。误标净减少 1,355 个（98.62%）与覆盖率增加 1.2 个百分点分别描述这两个环节。射线违例采用附录 J 的 2,020,000 条固定射线分母。

Waymo 输入视角上，F 的 PSNR 和深度 MAE 为 30.406 dB、0.1215 m，C 为 30.391 dB、0.1220 m。新增遮挡率从 0.18% 变为 0.17%，严格自由射线违例率从 0.07% 变为 0.08%。两种规则均严格保持观测高斯参数。RTX 4090 上，F 的构建耗时为 2.86 s，C 为 2.66 s，增加约 7.5%。渲染测量见附录 J，计时条件见附录 K。

E. 高斯解码细节

每个高斯存储中心 $\boldsymbol{\mu}$、协方差 $\boldsymbol{\Sigma}$、不透明度 α 和方向外观。

背景、刚体和人体高斯解码器分别将每个查询独立映射为 $K = 4$ 个子高斯。每个子高斯输出 23 个参数，包括三个中心偏移、三个尺度、四个旋转参数、一个不透明度和十二个外观系数。查询 i 的子高斯 k 的中心被限制在其支撑单元内：

$$\boldsymbol{\mu}_{i,k} = \mathbf{q}_i + \tfrac{1}{2}\boldsymbol{\delta}_i \odot \tanh(\mathbf{b}_{i,k}). \tag{S17}$$

正尺度与归一化旋转确定正定协方差。不透明度乘以 $1 - f_i$，使自由空间查询不能产生可见高斯。人体子高斯继承支撑查询的蒙皮权重；刚体子高斯共用所属资产的刚体变换。独立天空头预测立方体贴图颜色，并在 V_{sky} 中保留观测支持的方向域。

外观为每个颜色通道存储常数 RGB 项和三个局部方向系数，按 $c(d) = \max(0, c_0 + C_{\text{app}}\hat{d}_{\text{local}})$ 求值。解码逐查询执行：编解码器冻结后，不变的已见潜码产生不变的高斯参数。补全网络可以在查询之间交换上下文，同时保留这一解码性质。

F. 重建协议与基线

主比较评价给定相机及参与者状态下的重建，最后四帧评价条件时间外推。表 S10 列出测试条件。目标人体关节来自独立离线标注 / 拟合，人体体型和绑定由上下文恢复，测试 LiDAR 专用于评价。测试时全部网络权重固定。

训练资源。 STORM、DGGT 和 StreetForward 保留各自原生结构，随机初始化重训。每种方法使用相同真实训练日志 D_R、合成场景 D_S 和完整资产 D_A。基线通过自身目标接收 RGB、深度、轮廓及完整资产目标视图监督，Ours 另用单元空域和模板绑定监督。各方法在固定预算内训练，并在共同开发集上选择 checkpoint（表 S8）。CCM 消融匹配恢复模块、codec、数据和优化预算，以测量组件交换的贡献。

统一状态适配器。 各基线使用共同的确定性状态适配器。将高斯可见渲染贡献投到同一组上下文实例掩码，累积加权身份票。车辆依据给定根位姿执行逆 SE(3)，同时变换中心、协方差和方向坐标基。人体高斯在上下文恢复的同身份模板上匹配三角形，以重心插值得到

Table S6. 100 个合成场景的自由空间掩码审计。错误指包含参考表面的单元被标为自由空间，各类别互斥。C 为中心射线规则，F 为投影足迹规则；主重建表采用 C，F 单独评价。

类别	含表面单元	中心判据误标	足迹判据误标
薄结构	18,437	614	9
遮挡边界	27,619	587	7
其余区域	53,128	173	3
合计	99,184	1,374	19
错误 / 含表面单元		1.385%	0.019%
自由空间标签数量		47,286	32,871
含表面污染 / 自由标签		2.906%	0.058%

Table S7. **自由空间规则的下游影响**。相同 checkpoint 和逐查询噪声，汇总九组种子；覆盖率与 F-score 阈值为 2 cm。

指标	C	F
隐藏区域 PSNR ↑	23.18	**23.36**
隐藏区域 LPIPS ↓	0.192	**0.185**
隐藏表面覆盖率 ↑	95.0%	**96.2%**
隐藏表面 F-score ↑	88.6%	**89.9%**
薄结构覆盖率 ↑	92.1%	**94.8%**
边界覆盖率 ↑	93.0%	**95.2%**
人体覆盖率 ↑	95.8%	**96.8%**

17 关节蒙皮权重，再执行逆蒙皮。适配器保留预测外观，不增加预测网络。未绑定输出保留评价，无法装配的参与者编辑计为失败。

同一高斯集合经逆变换和正变换后，最大线性 RGB 差低于 4×10^{-6}。将原生时变表示转换为固定规范资产的跨时刻重建变化见表 S9，适配后列用于正文主比较。

每条测试序列取前 200 个有效同步帧，形成 10 个不重叠的 20 帧片段，共 2,020 个片段。三相机上下文索引为 $\{0, 5, 10, 15\}$，其余 12 帧插值产生 72,720 张图像，$\{16, 17, 18, 19\}$ 四帧外推产生 24,240 张图像，共 96,960 张。全部目标时刻具有有效动态掩码和深度评价样本。表 S11 按插值 / 外推 3:1 汇总，恢复主表均值。深度尺度对齐仅用于评价，不反馈给重建或渲染。

深度尺度与米制评价。 对齐深度列在固定有效 LiDAR 掩码 M_t 上估计逐帧正尺度：

$$s_t = \mathrm{median}_{p \in M_t} \frac{d_t(p)}{\widehat{d}_t(p)}. \tag{S18}$$

拟合量为单一尺度。表 S12 的对齐与未对齐深度使用相同掩码，按帧、片段和序列依次汇总。尺度对齐在深度评价器内执行；重建、装配、表面距离和 RGB 重投影使用原始米制坐标。

G. 消融协议与种子统计

两个学习版本使用训练种子 $\{0, 1, 2\}$，每个 checkpoint 评价生成种子 $\{7, 17, 27\}$，形成九组结果。先平均生成种子，再按帧、窗口、序列及训练种子等权汇总，不采用 best-of-three。表 S13 和表 S14 每格为均值 ± 三个训练种子均值的样本 SD，括号内为生成种子的平均样本 SD。w/o GCM 的零波动对应固定共享恢复模块和 codec 后的确定性推理。

每条测试序列取一个 29 时刻窗口，共 202 个。$\mathcal{T}_2 = \{0, 28\}$、$\mathcal{T}_4 = \{0, 8, 20, 28\}$、$\mathcal{T}_8 = \{0, 4, \ldots, 28\}$ 共享 $\{2, 6, \ldots, 26\}$ 七个目标时刻及三相机，每组共 4,242 张目标图像。两个学习版本、三个 T、九个种子组合共 54 组、229,068 张预测图像。w/o GCM 另有 4,242 张，总计 233,310 张。

不可渲染数为学习版本 0/10,908 个窗口实例、w/o GCM 0/202。低质量、空洞和接触错误均保留计分。所有变体共享图像预处理、240 × 160 分辨率、标注动态掩码以及按序列等权的汇总方式。训练均匀采样 $T \in \{2, 4, 8\}$，推理均使用 24 步 Euler 积分；超参数只在开发集选择。

在 $T = 2, 4, 8$ 时，CCM 分别将全图 PSNR 提高 1.104、0.738 和 0.627 dB，LPIPS 降低 0.041、0.028 和 0.018（表 S14）。输入最稀疏时收益最大。

H. 轨迹外渲染与补全分析

每个偏移方向渲染 $2,020 \times 3 \times 20 = 121,200$ 张图像及 6,060 段视频。每段 20 帧、10 Hz，不跨片段拼接。参考集合是同一测试片段、相机和时间戳的原轨迹记录。FID 使用固定 Inception-v3 的 2,048 维特征，FVD 使用固定 I3D 的 1,024 维特征。左右方向分别计算再平均，不先混合左右样本。主文离轨图中的 GT 为原轨迹记录图像。

100 个合成测试场景另行提供输入始终未覆盖区域的配对评价（表 S15），代表偏移为 ±2 m。FID/FVD 描述分布质量，隐藏区域指标描述场景对应补全。

预测表面与几何指标。 采用渲染与融合构造表面。不透明度至少为 0.01 的高斯在 3σ 内求值，在共同评价域分块渲染六轴正交视图，块内投影像素尺度不超过 1 mm。沿射线累计不透明度，首次达到 0.5 的位置定义表面深度；累计不足阈值时记为无预测表面。深度经 2 mm 体素、8 mm 截断距离的稀疏 TSDF 融合，在有效

Table S8. 单个完整 checkpoint 的训练资源，包含方法专用目标预处理。Ours 和 w/o CCM 均计入共享恢复模块与 codec 的成本。

方法	训练目标	更新步数	全局 batch	GPU 小时
STORM	原生重建及同源合成视图	234,816	16	916.7
DGGT	原生几何 / 渲染及同源合成视图	212,672	16	1,128.4
StreetForward	原生场景重建及同源合成视图	246,144	8	1,036.9
Ours	完整四阶段	287,360	分阶段	1,001.5
w/o CCM	共享 R/C，重训 GCM 先验及适配	287,360	同 Ours	977.1

Table S9. 转为固定规范资产对重建的影响，PSNR 单位为 dB。

方法	原生	适配后	差值
STORM	26.492	26.380	−0.112
DGGT	27.538	27.410	−0.128
StreetForward	27.094	27.010	−0.084

支撑体素中提取网格，未知区域保持开放。原生神经场采用相同累计不透明度阈值、融合和距离评价。

预测与参考网格分别按面积均匀采样 65,536 点，通过 BVH 计算各样本到对方三角网格的最近距离。坐标单位为米，距离采用非平方欧氏距离，评价保持原始米制尺度和对齐。令 P 和 G 分别为评价区域内的预测与参考样本，对应表面为 S_{pred}、S_{GT}，则

$$P_\tau = \frac{1}{|P|}\sum_{p\in P}\mathbf{1}[d(p, S_{\text{GT}}) < \tau], \tag{S19}$$

$$R_\tau = \frac{1}{|G|}\sum_{g\in G}\mathbf{1}[d(g, S_{\text{pred}}) < \tau], \tag{S20}$$

$$F_\tau = \frac{2P_\tau R_\tau}{P_\tau + R_\tau}. \tag{S21}$$

覆盖率为参考表面召回率 R_τ。各指标先逐场景、逐种子计算，再取均值。资产覆盖使用归属于该参与者的预测表面，车辆 / 人体阈值为 2 / 1 cm。完整参考几何与输入可见性定义新增可见面，查询支撑之外的参考表面仍计入覆盖分母。

真实视图对应。 独立参考几何建立记录视图与离轨视图的对应，动态参与者按共享状态变换。参考评价器统一排除遮挡不确定的对应，各方法的有效性由有限输出和渲染覆盖确定。测试 LiDAR 专用于评价器。线性 RGB MAE 同时在各自有效区域及其交集上计算，共有区域占参考集合的 58.7%（表 S16）。相对 w/o CCM，CCM 将共有区域 MAE 从 0.028 降至 0.019，总覆盖率从 86.9% 提高至 92.4%。

任务适配的补全机制。 场景潜码对照适配 Complete-Splat 的场景级高斯潜码生成机制 [2]，对象耦合对照适配 JRM 的跨对象潜码耦合 [4]。两者使用共享恢复模块、codec、查询布局和状态接口，替换补全交互机制，输入证据、训练数据、监督及 24 步采样设置相同。共享恢复模块与 codec 保持冻结，补全训练日程见附录 B；三个训练种子与三个生成种子全部平均，不选择最优样本。这些任务适配对照检验异构交互对本文重建任务的贡献。

表 S15 使用相同的 100 个合成测试场景，每组种子含 12,000 张偏移目标图像。每个学习版本的九组种子共生成 108,000 张输出，场景统计保留全部视角、帧和种子结果。相对对象耦合对照，CCM 将 PSNR 提高 0.67 dB、LPIPS 降低 0.020，覆盖率与 F-score 分别提高 2.6 和 3.6 个百分点；相对场景潜码对照，PSNR 提高 0.94 dB。表面评价在原始米制坐标中进行，预测与参考网格各取 65,536 个面积均匀采样点，采用相同的 2 cm 点到三角网格距离阈值。

合成可见率分组评价。 表 S17 与配对隐藏区域评价共享 100 个合成测试场景、±2 m 横移、输入、checkpoint 和生成样本。每场景取一个 20 帧、三相机片段，在 $\{0, 5, 10, 15\}$ 输入 12 张图像。目标覆盖两个偏移方向、全部 20 时刻和三相机，每种子组合共 12,000 张图像。输入时刻也参与评价，因为横移相机不同于输入相机。三个训练种子和三个生成种子直接复用已训练权重，不在这些场景上适配。

可见率 v 是固定参考表面区域被输入视图并集覆盖的面积比例。充分可见为覆盖率 $\geq 80\%$，严重缺失为 $\leq 20\%$，中间可见为 $20\% < v < 80\%$。按参考表面对应关系将目标像素分到背景、车辆、人体及可见率组，方法间采用相同有效掩码；先计算组内帧均值，再对场景等权平均。分组 PSNR 与全图 PSNR 独立计算。隐藏区域测试要求输入覆盖率恰为 0%，严重缺失组则允许覆盖率达到 20%。

CCM 在严重缺失的背景、车辆和人体区域分别增加 1.02、1.28 和 1.54 dB（表 S17），充分观测区域分别增加 0.04、0.04 和 0.03 dB，收益主要集中在输入覆盖不足的区域。

Waymo 读取范围干预。 表 S18 沿用主消融 $T = 8$ 的 202 个 Waymo 窗口。每个 29 时刻窗口以三相机输入 $\{0, 4, 8, 12, 16, 20, 24, 28\}$（24 张），目标为 $\{2, 6, 10, 14, 18, 22, 26\}$（每种子组合 4,242 张）。训练种子 $\{0, 1, 2\}$ 与生成种子 $\{7, 17, 27\}$ 形成九组，恢复模块、codec、查询布局、目标状态及 24 步采样均固定。

Table S10. DriveCompose、STORM、DGGT 和 StreetForward 的共同测试条件。

条件	统一设置
上下文 RGB	相同四时刻、三相机
相机与自车状态	统一给定内外参及自车位姿
测试深度/LiDAR	不作为输入；深度由 RGB 估计
身份、车辆框与根轨迹	统一给定
人体体型与绑定	上下文恢复，统一绑定接口
目标人体关节	独立离线标注/拟合，统一给定
测试场景优化	全部关闭

Table S11. 时间插值与条件外推。全图和动态区域为 PSNR/SSIM，深度为逐帧尺度对齐的 AbsRel/δ_1。

方法	时间组	全图	动态区域	深度
STORM	插值	26.800/0.838	22.600/0.640	0.170/0.753
STORM	外推	25.120/0.790	20.600/0.576	0.202/0.705
DGGT	插值	27.800/0.806	23.200/0.667	0.237/0.680
DGGT	外推	26.240/0.758	21.240/0.603	0.285/0.632
StreetForward	插值	27.400/0.830	21.500/0.608	0.185/0.771
StreetForward	外推	25.840/0.782	19.176/0.544	0.233/0.723
Ours	插值	**28.900/0.909**	**25.500/0.870**	**0.091/0.885**
Ours	外推	**27.556/0.877**	**23.700/0.838**	**0.107/0.853**

Table S12. 逐帧尺度对齐与未对齐深度评价。

	逐帧尺度对齐		未对齐	
方法	AbsRel ↓	δ_1 ↑	AbsRel ↓	δ_1 ↑
STORM	0.178	0.741	0.226	0.683
DGGT	0.249	0.668	0.327	0.572
StreetForward	0.197	0.759	0.254	0.694
Ours	**0.095**	**0.877**	**0.121**	**0.842**

仅背景、仅其他车辆和仅其他人体均为同一组 Ours checkpoint 的推理期读取遮罩，不分别重训；局部注意力和全局日志条件保持不变。w/o CCM 仍使用同预算重训的独立记忆对照。因此 28.286 和 28.913 dB 复用主消融端点，28.721、28.574 和 28.352 dB 来自该 Waymo 协议的读取干预。Waymo 读取干预与合成可见率结果分别报告，各组件收益重叠。

I. 状态驱动资产复用

合成场景配对编辑。 20 个身份隔离合成测试场景各含一辆车和一个人体，相机平移 1 m、车辆旋转 30° 及人体换姿均复用固定完成资产。联合补全在新增可见表面的 PSNR、LPIPS 和覆盖率上均取得最优结果（表 S19）。

20 个真实和 20 个身份隔离的合成测试场景各含一个受测车辆与人体。评价原始状态、相机横移 1 m、车辆绕根位置与世界竖直轴旋转 30°，以及根位置固定的人体换姿。各操作在固定照明下复用相同完成资产与生成种子，并保持外观固定。完整参考几何按附录 H 定义新增可见表面。

真实场景编辑判定。 训练种子 0、生成种子 7 共形成四十次编辑（表 S20）。两名不知方法身份的评估者独立检查预设目标视图，分歧由第三人裁决。评价分辨率下，连续空洞、表面脱离或关节撕裂达到五像素即判结构完整性失败。Ours 的二十次车辆旋转全部成功，人体编辑成功十七次；三次人体失败涉及大幅肘弯、腿部自遮挡和宽松衣物边界。车辆尺寸与人体体型参数保持固定，人体原已见纹理经规范对应后的线性 RGB MAE 为 0.014。

种子波动与场景聚类。 三个训练种子 $\{0, 1, 2\}$ 与三个生成种子 $\{7, 17, 27\}$ 在相同二十个真实场景上形成 360 次编辑（表 S21）。车辆成功 177/180 次（98.33%），人体 157/180 次（87.22%），总体 334/360 次（92.78%）。三个训练种子结构完整性均值的样本 SD 为 0.48 个百分点。场景聚类 bootstrap 每次保留被抽中场景的全部十八次编辑，结构完整性的 95% 区间为 85.28–99.17%。26 次失败集中在四个场景，分别为 9、8、6 和 3 次。

新增纹理、身份与几何。 新增可见表面在全部输入观测中不可见，在编辑后变得可见；通过规范表面对应与可见性测试确定。五名独立评审检查新增表面纹理、外观身份与局部几何，每项至少四人判断通过才计为通过。纹理评价检查模糊、重复、拉伸和接缝；身份评价检查车辆形态与涂装，以及人体服饰、体型和可见身份特征；几何评价检查车轮与车体连接、肢体体积、关节弯折和穿插。

Table S13. 组件消融的完整种子统计。

指标	w/o GCM	w/o CCM	Ours
全图 PSNR	27.137 ± 0	28.286 ± 0.074 (0.032)	**28.913 ± 0.061 (0.028)**
全图 SSIM	0.867 ± 0	0.893 ± 0.001 (0.0006)	**0.911 ± 0.001 (0.0005)**
全图 LPIPS	0.183 ± 0	0.147 ± 0.002 (0.0013)	**0.129 ± 0.002 (0.0011)**
动态 PSNR	23.431 ± 0	24.683 ± 0.112 (0.048)	**25.617 ± 0.095 (0.041)**
动态 SSIM	0.811 ± 0	0.849 ± 0.002 (0.0010)	**0.873 ± 0.002 (0.0008)**

Table S14. 固定权重的输入时刻数量敏感性；$T = 8$ 复用组件表结果。

T	版本	PSNR ↑	SSIM ↑	LPIPS ↓
2	w/o CCM	25.237 ± 0.103 (0.055)	0.817 ± 0.003 (0.0011)	0.254 ± 0.004 (0.0023)
2	Ours	**26.341 ± 0.089 (0.047)**	**0.851 ± 0.002 (0.0009)**	**0.213 ± 0.003 (0.0019)**
4	w/o CCM	27.126 ± 0.086 (0.041)	0.869 ± 0.002 (0.0008)	0.187 ± 0.003 (0.0018)
4	Ours	**27.864 ± 0.072 (0.035)**	**0.891 ± 0.001 (0.0006)**	**0.159 ± 0.002 (0.0014)**
8	w/o CCM	28.286 ± 0.074 (0.032)	0.893 ± 0.001 (0.0006)	0.147 ± 0.002 (0.0013)
8	Ours	**28.913 ± 0.061 (0.028)**	**0.911 ± 0.001 (0.0005)**	**0.129 ± 0.002 (0.0011)**

Table S15. 合成隐藏区域的配对评价。

版本	PSNR	LPIPS	覆盖率	F-score@2 cm
w/o GCM	16.82	0.401	61.5%	51.7%
w/o CCM	21.56	0.236	89.7%	81.3%
Scene latent	22.24	0.221	91.8%	84.1%
Object coupling	22.51	0.212	92.4%	85.0%
Ours	**23.18**	**0.192**	**95.0%**	**88.6%**

Table S16. 线性 RGB 重投影误差及覆盖率，共有支持集占参考集合的 58.7%。

变体	共有 MAE	自身 MAE	覆盖率
w/o GCM	0.022	0.024	62.1%
w/o CCM	0.028	0.041	86.9%
Ours	**0.019**	0.029	**92.4%**

Table S17. 按组件和可见性分组的 PSNR。

组件及可见性	w/o CCM	Ours	增益
背景，充分可见	30.20	30.24	+0.04 dB
背景，严重缺失	22.10	23.12	**+1.02 dB**
车辆，充分可见	28.30	28.34	+0.04 dB
车辆，严重缺失	21.10	22.38	**+1.28 dB**
人体，充分可见	26.90	26.93	+0.03 dB
人体，严重缺失	19.70	21.24	**+1.54 dB**

表 S22 评价二十个场景、九组种子的 360 次演员编辑，相机平移不增加演员编辑分母。联合通过按四项判据的逐例交集计算，共通过 298 次（82.78%）。62 次失败包括 26 次结构失败，以及 36 次结构完整但未通过至少一项其他质量检查的编辑。

Table S18. CCM 读取范围诊断。

额外可读组件	全图 PSNR
无跨组件交换，即 w/o CCM	28.286
背景	28.721
其他车辆	28.574
其他人体	28.352
全部组件	**28.913**

Table S19. **编辑后新增可见资产表面**。合成配对测试中的补全消融，车辆 / 人体覆盖阈值为 2 / 1 cm。

变体	车辆（2 cm）			人体（1 cm）		
	PSNR↑	LPIPS↓	Cov.↑	PSNR↑	LPIPS↓	Cov.↑
w/o GCM	17.80	0.362	63.4%	17.12	0.391	60.8%
w/o CCM	22.46	0.218	91.8%	21.38	0.247	88.6%
Ours	**24.18**	**0.176**	**96.1%**	**23.06**	**0.201**	**94.3%**

Table S20. 训练种子 0、生成种子 7 的真实参与者编辑结构完整性。各资产列表示通过数量。

变体	车辆	人体	总成功率
w/o GCM	14/20	10/20	60.0%
w/o CCM	18/20	15/20	82.5%
Ours	**20/20**	**17/20**	**92.5%**

Table S21. 跨训练与生成种子的结构完整性通过数量。每行评价二十辆车和二十个人体。

训练	生成	车辆	人体	合计
0	7	20	17	37/40
0	17	20	18	38/40
0	27	19	17	36/40
1	7	20	18	38/40
1	17	19	17	36/40
1	27	20	18	38/40
2	7	20	17	37/40
2	17	20	18	38/40
2	27	19	17	36/40
全部组合		177/180	157/180	334/360

扩展状态与视角协议。 360 次编辑质量评价使用固定目标状态与视角清单。扩展协议设置车辆偏航角变化 30°、60°、90°，人体最大非根关节旋转差 15°、30°、45°，根放置固定。二十个场景与九组种子共形成 $20 \times 9 \times (3+3) = 1,080$ 次演员编辑，每次三个预定义目标视角，共 3,240 幅图像。每个种子在全部状态中复用同一完成资产，五像素判据在 240×160 分辨率下计算。

J. 观测一致性

固定原始相机、参与者状态及评价像素，以 observed-only 场景为补全前参考（表 S23）。已见高斯参数严格保持，但新增高斯会通过遮挡和透明度混合改变渲染。每序列固定 10,000 条射线，总计 2,020,000 条。新增遮挡定义为新增内容在观测表面前 5 cm 之外产生大于 0.01 的累积不透明度；严格自由射线违规要求在表面前 10 cm 之外产生大于 0.05 的累积不透明度。

Ours 的 0.18% 新增遮挡对应 3,636 条射线，0.07% 严格违规对应 1,414 条。相对补全前，输入视角 PSNR 下降 0.029 dB，深度 MAE 增加 2 mm。去掉自由射线损失后，两类射线比例升至 1.34% 和 0.91%，说明该损失约束了查询级参数保持之外的渲染影响。

K. 效率与复用成本

训练硬件为 8× A100 80 GB。推理计时使用单张 RTX 4090 24 GB，FP16、batch 1、输出 240×160，平均每场景保留 140 万非透明高斯。预热 20 次后测量 100 次，包含 CPU–GPU 传输与同步，不含磁盘读取及首次模型加载。构建耗时为 2.66 ± 0.11 s，状态装配与单相机渲染为 7.8 ± 0.4 ms（约 128.2 FPS），峰值显存 14.2 GB。

令 $Q = Q_b + \sum_a Q_a^{\text{vehicle}} + \sum_h Q_h^{\text{human}}$ 为非天空查询总数。解码生成 $4Q$ 个候选高斯，非透明输出数量以此为上界，因此平均 140 万非透明高斯对应每场景平均至少 350,000 个非天空查询。天空由独立 cubemap 头输出。

表 S24 分解构建时间。w/o CCM 为 2.53 s，CCM 增加 0.13 s，约 5.1%。表 S25 按 $2.66 + 0.0078N$ 计算含一次构建的总时间；N 是单相机输出次数，三相机查询计三次渲染。

仅将自由空间规则改为 F，相同硬件、输入与采样条件下构建耗时从 2.66 增至 2.86 s（7.5%）。主计时分解与摊销成本采用 C。

Table S22. **C 规则下的真实演员编辑质量**。二十个场景、九组训练 / 生成种子、360 次演员编辑；联合通过为四项判据的逐例交集。

判据	车辆（180 次）	人体（180 次）	合计（360 次）
结构完整性	177（98.33%）	157（87.22%）	334（92.78%）
新增表面纹理	166（92.22%）	154（85.56%）	320（88.89%）
外观身份	174（96.67%）	170（94.44%）	344（95.56%）
局部几何	164（91.11%）	152（84.44%）	316（87.78%）
四项同时通过	156（86.67%）	142（78.89%）	298（82.78%）

Table S23. C 规则下的输入观测保持，深度误差单位为 m。匹配的 C/F 对照见附录 D。

配置	参数差	PSNR	RGB MAE	深度 MAE	新增遮挡	严格违规
补全前	0	30.420	0.0187	0.120 m	0	0
w/o CCM	0	30.368	0.0190	0.123 m	0.24%	0.09%
Ours	**0**	**30.391**	**0.0189**	**0.122 m**	**0.18%**	**0.07%**
Ours 去掉自由射线损失	0	29.970	0.0208	0.134 m	1.34%	0.91%

Table S24. 构建时间分解。

阶段	时间
图像预处理	0.18 s
视觉恢复	0.64 s
查询构造与规范聚合	0.17 s
24 步生成补全	1.38 s
高斯解码	0.26 s
初始场景注册	0.03 s
合计	**2.66 s**

Table S25. 固定完成资产的摊销查询成本。

N	总时间	每次查询
1	2.6678 s	2.6678 s
10	2.738 s	273.8 ms
100	3.440 s	34.4 ms
1,000	10.460 s	10.46 ms

References

[1] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. In *International Conference on Learning Representations (ICLR)*, 2021. 3

[2] Ziwei Liao, Mohamed Sayed, Steven L. Waslander, Sara Vicente, Daniyar Turmukhambetov, and Michael Firman. Complete Gaussian Splats from a Single Image with Denoising Diffusion Models. *arXiv preprint arXiv:2508.21542*, 2025. 6

[3] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Ł ukasz Kaiser, and Illia Polosukhin. Attention is All you Need. In *Advances in Neural Information Processing Systems*, 2017. 3

[4] Qirui Wu, Yawar Siddiqui, Duncan Frost, Samir Aroudj, Armen Avetisyan, Richard Newcombe, Angel X. Chang, Jakob Engel, and Henry Howard-Jenkins. JRM: Joint Reconstruction Model for Multiple Objects without Alignment. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 307–316, 2026. 6