DriveCompose：通过联合补全实现驾驶场景的可组合生成式重建

Anonymous CVPR submission

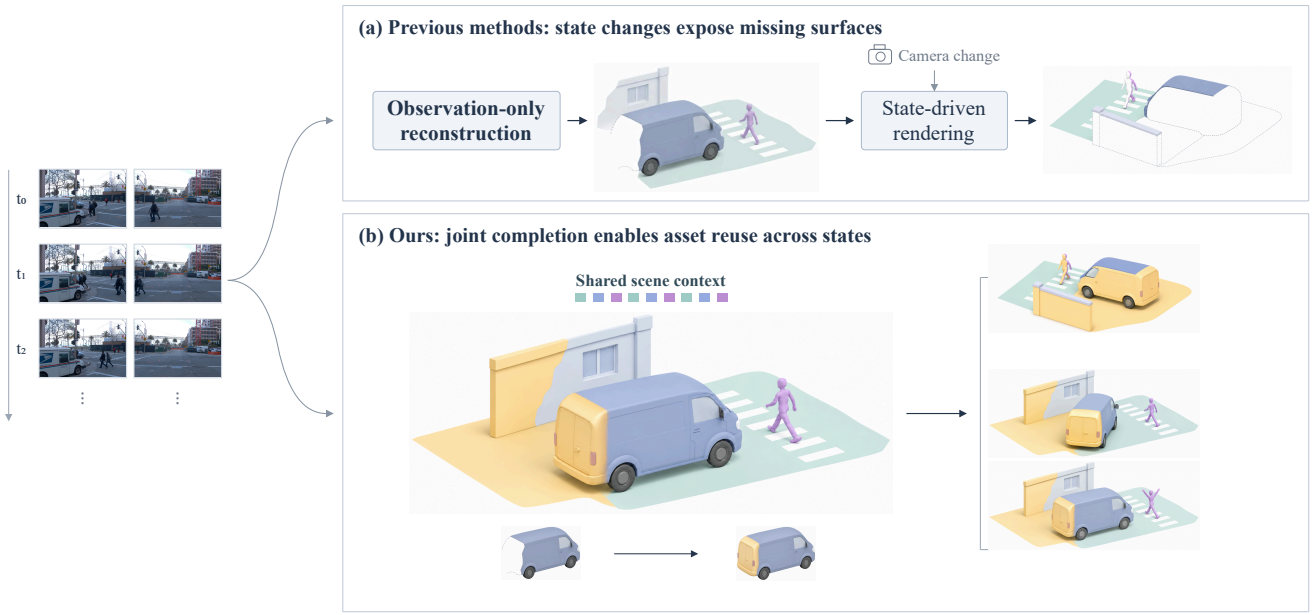

Figure 1. **从观测到可复用的完成资产**。上：视角或参与者状态变化会暴露观测重建中的缺失表面。下：DriveCompose 通过结构化编码和联合补全构建背景、规范车辆与人体，并在不同状态下复用。金色表示补全区域；所有场景与资产画面均为机制示意。

Abstract

相机视点与参与者姿态的变化会显露输入驾驶图像中从未观测到的表面。面向仿真与编辑的场景重建需要补全这些表面，同时保留对参与者运动的控制。我们提出 *DriveCompose*，从有标定的驾驶图像序列中生成式重建可组合场景。视觉证据分别在背景的世界坐标系和车辆、人体的规范坐标系中聚合。条件流模型通过跨组件记忆共享场景上下文，在组件潜表示中联合补全缺失的几何与外观。补全后的潜表示被解码为具有刚体和骨架绑定的高斯组件，使生成表面随对应参与者运动。同一组背景与参与者资产随后可在新的相机视点和参与者状态下装配与渲染。*Waymo* 实验表明，相比前馈重建基线，*DriveCompose* 获得了更高的重建精度和更好的轨迹外渲染质量。参与者编辑实验进一步验证了补全车辆与人体在运动和姿态变化下的复用能力。

1. 引言

驾驶仿真与场景编辑需要能够支持相机移动、车辆运动和人体姿态变化的三维场景 [50, 53]。然而，驾驶日志中的图像只提供采集视角和当时参与者状态下的可见表面 [1, 35]。移动相机、转动车辆或改变行人姿态，都会暴露此前未观测的区域（图 1）。因此，场景重建需要补全这些区域的几何与外观，并使补全后的车辆和人体表面能够随所属对象运动。

近期前馈方法通过融合多帧图像，直接预测驾驶场景的三维几何与高斯表示 [5, 8, 49, 52]。运动与可见性估计对齐动态对象，聚合输入序列中可见的表面。整个序列都未观测到的表面，需要通过几何与外观的生成先验推断。

生成式重建通过资产先验、高斯补全或生成视图推断未观测内容 [21, 48, 51, 55]。可组合重建将背景与运动对象分开表示，支持车辆移动和人体姿态控制 [7, 47, 53]。在这些组件表示中进行补全，可以使生成表面保留所属对象的运动绑定。可见背景与其他对象则为部分可见组件的补全提供场景上下文。

我们提出 DriveCompose，将背景、车辆与人体联合

补全为可复用的高斯组件（图 2）。背景采用世界坐标，刚体资产采用各自的局部坐标，人体则在参考姿态下表示并保留骨架绑定 [7, 47]。跨组件记忆共享这些组件的特征，为流式补全提供条件 [22]。高斯解码器保留组件归属与绑定 [18]，使补全表面能在新的相机与参与者状态下随所属对象运动（第 3.1、3.4 节）。

Waymo 实验表明，相比前馈重建基线，DriveCompose 获得了更高的重建精度和更好的轨迹外渲染质量。合成配对测试将联合补全与场景级生成、跨对象耦合进行比较，真实参与者编辑则验证同一组补全资产的复用（第 4 节）。

本文的贡献包括：

- 提出 DriveCompose，从图像序列联合补全背景、车辆与人体，构建在相机、刚体和骨架状态变化时可复用的可组合高斯资产。
- 设计基于条件流匹配的跨组件潜空间补全模型。通过局部注意力建模各组件内部的空间关系，通过跨组件记忆汇集背景与参与者的特征，为各组件的缺失内容生成提供场景上下文。
- 通过匹配补全机制和可见率分组评价，验证共享场景上下文的作用，并通过真实参与者编辑验证状态驱动复用。

2. 相关工作

驾驶场景重建。 城市重建采用 NeRF 与高斯辐射表示 [18, 26]，NeuRAD 和 SplatAD 进一步发展面向驾驶场景的渲染 [13, 37]。前馈方法直接从图像预测场景几何与高斯 [3, 6, 14, 39, 40]。STORM 通过场景流聚合动态高斯，DGGT 则结合相机恢复、可见性和运动引导插值 [5, 49]。DrivingForward、StreetForward、PointForward 和 Instant NuRec 探索环视输入、时序处理、点对齐表示及面向仿真的重建 [8, 16, 36, 52]。TokenGS 通过可学习 token 解耦像素与高斯预测 [33]。

可组合场景表示。 Neural Scene Graphs、Street Gaussians 和 DrivingGaussian 通过分离背景与运动组件支持参与者控制 [27, 47, 54]。OmniRe 在规范坐标系中表示刚体与关节化参与者，UniSim 和 HUGSIM 则将重建内容接入闭环仿真 [7, 50, 53]。在资产层面，基于 SMPL 的人体模型和可驱动高斯方法提供规范表面与运动绑定 [15, 19, 24, 29, 31]；LHM 与 IDOL 推断可驱动人体，UrbanCAD 面向可控车辆 [25, 32, 56]。这些坐标系与绑定为重建或补全后表面的复用提供接口。

生成式重建与补全。 生成式重建通过生成视图 [11, 23, 34] 或结构化潜表示 [45, 46] 推断未观测的几何与外观。GenAssets 学习驾驶资产先验，CompleteSplat 生成隐藏高斯表面，JRM 则通过对象潜码耦合聚合未对齐观测 [21, 44, 51]。LatentWorld 围绕实体和背景潜变量组织语义占据生成 [28]。DriveCompose 联合补全世界空间背景与规范刚体、人体潜码，保留其几何、外观和运动绑定，用于状态驱动渲染。

驾驶场景生成。 MagicDrive、DriveDreamer 和 Vista 以场景结构或控制为条件生成驾驶图像 [10, 12, 41]。StreetCrafter 用生成视图监督动态高斯重建，Horizon-Forge 将场景编辑与视频扩散结合 [42, 48]。WorldSplat 生成高斯并细化其渲染视频，DIFIX3D+ 则通过扩散模型细化图像 [43, 55]。FreeGen 将前馈重建与扩散生成协同训练，把生成先验蒸馏进重建模型以改善离轨渲染 [4]。DriveCompose 保存补全后的背景与规范资产，在新的相机和参与者状态下渲染同一份三维内容。

3. 方法

DriveCompose 在世界与规范坐标系中聚合观测，联合补全潜码，再解码为可复用高斯资产，在新的状态下渲染（图 2）。

3.1. 问题定义

输入是同步图像日志 $\mathbf{I}_{t,v}$、时间戳、相机内参及相机到传感器支架的标定。受控评价给定支架位姿、实例身份、车辆框与根轨迹，以及目标人体关节。人体体型与绑定由上下文恢复，重建不使用目标 RGB 或测试 LiDAR。

输出为可组合高斯场景

$$\mathcal{W} = \big(\mathcal{G}_b, C_{\text{sky}}, V_{\text{sky}}, \{\mathcal{A}_a\}, \mathcal{B}, \xi\big), \tag{1}$$

其中，$\mathcal{G}_b$ 是世界空间背景，C_{sky} 是天空立方体贴图，V_{sky} 表示其有效方向，$\mathcal{A}_a$ 是身份 a 对应的规范资产，$\mathcal{B}$ 是有限空间支撑，ξ 是采样种子。这些组件通过高斯泼溅渲染 [18]。车辆表示为局部几何与尺寸固定的刚体资产，人体另存静止骨架和蒙皮权重。场景状态控制这些固定组件的放置与关节运动。

我们通过条件生成建模缺失内容。令 $\mathcal{Q}$ 为恢复得到的查询布局，C 为其观测证据。补全模型采样未知潜码 $\mathbf{z}_u$，编解码器 D_ψ 将组合后的潜码解码为场景内容：

$$\mathbf{z}_u \sim p_\theta(\mathbf{z}_u \mid C, \mathcal{Q}), \qquad \mathcal{W} = D_\psi(\mathbf{z}^{\text{obs}}, \mathbf{z}_u; \mathcal{Q}). \tag{2}$$

查询布局为每个潜码指定空间位置和所属组件。补全在这一布局中生成未知潜码，解码后仍保留其组件身份与运动绑定。

3.2. 视觉恢复与规范聚合

Driving Log Encoder 从各图像提取 patch 特征，并在相机与时间戳之间交换池化上下文 [9, 38]。几何预测头输出相机光轴深度、法线、置信度、语义和实例归属，将图像特征关联到三维表面及其所属组件。轨迹级身份槽将持久身份、尺寸和人体体型与逐帧变化的根位姿、关节旋转分开表示。

空间支撑。 每个查询存储规范位置 $\mathbf{q}_i$、单元尺度 $\boldsymbol{\delta}_i$、类型 k_i、局部注意力组 g_i 和参考世界坐标 $\mathbf{q}_i^w$。可靠深度样本提供表面锚点。背景锚点与有限世界网格结合；

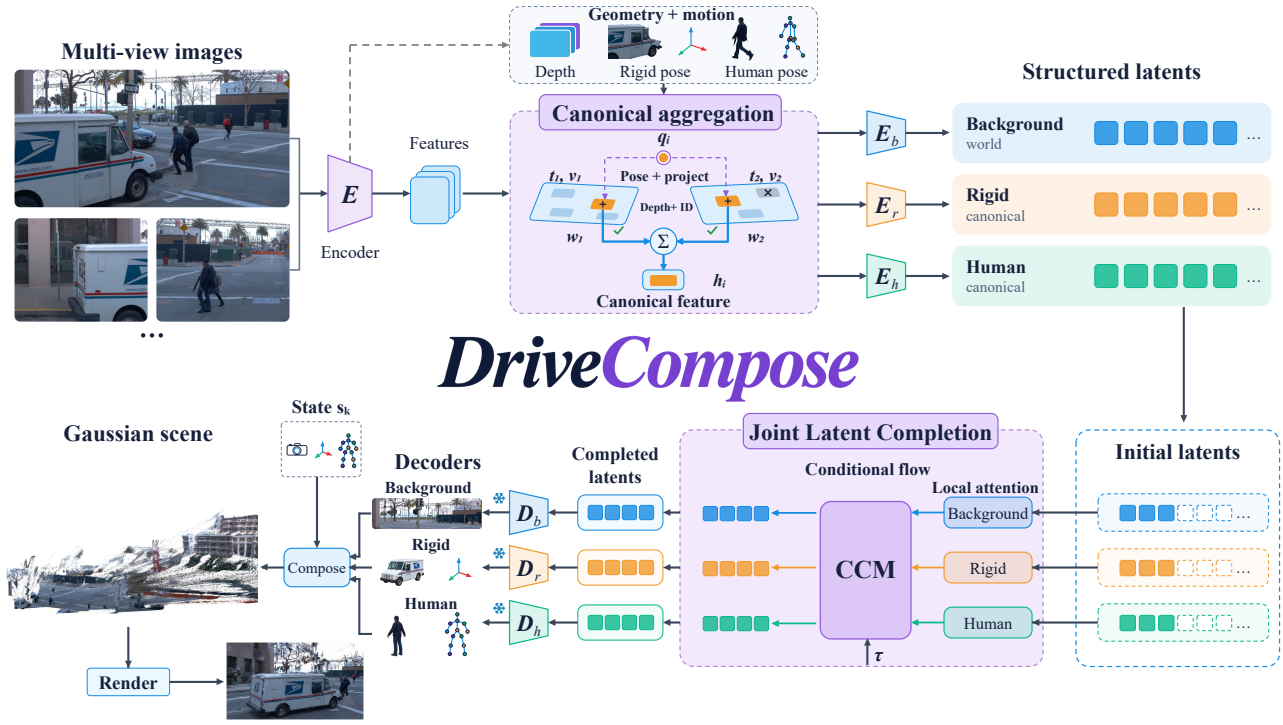

Figure 2. **DriveCompose 总览**。视觉编码与规范聚合恢复组件特征，类型专属编码器映射结构化潜码，联合补全和高斯解码生成背景、车辆与人体，用于状态驱动组合。场景与资产画面均为机制示意。

刚体锚点经逆 SE(3) 变换对齐后，与局部包围体中的网格结合。人体查询位于规范模板表面，天空查询为按立方体贴图面分组的单位方向。这些支撑为已见与缺失内容提供明确位置。

布局保留规范坐标以标识组件表面，并以首个输入时刻的世界坐标 $\mathbf{q}_i^w$（包括人体蒙皮）确定其相对背景与其他参与者的位置。

运动感知证据聚合。 为跨时刻聚合同一表面的证据，我们先将规范查询放到对应的资产状态：

$$\mathbf{p}_i(t) = \begin{cases} \mathbf{q}_i, & k_i = \text{background}, \\ \text{xyz}(\mathbf{T}_a^w(t)\bar{\mathbf{q}}_i), & k_i = \text{rigid}, \\ \text{xyz}(\mathbf{T}_h^w(t)\mathbf{A}_i(t)\bar{\mathbf{q}}_i), & k_i = \text{human}. \end{cases} \tag{3}$$

其中，$\bar{\mathbf{q}}_i$ 为齐次坐标，xyz 提取欧氏坐标，$\mathbf{A}_i(t)$ 为加权蒙皮变换。投影得到查询深度 $z_{i,t,v}$，并采样图像特征 $\boldsymbol{\phi}_{i,t,v}$、深度 $d_{i,t,v}$ 和置信度 $c_{i,t,v}$，按置信度及归一化深度残差 $r = (d - z)/(\eta_{\text{abs}} + \eta_{\text{rel}} d)$ 为观测赋权。指示量 $a_{i,t,v}$ 选择同一实例中可见且深度一致的观测：

$$w_{i,t,v} = a_{i,t,v} c_{i,t,v} \exp(-r_{i,t,v}^2/2), \tag{4}$$

$$\mathbf{h}_i = \frac{\sum_{t,v} w_{i,t,v} [\boldsymbol{\phi}_{i,t,v}; r_{i,t,v}]}{\max(\varepsilon, \sum_{t,v} w_{i,t,v})}. \tag{5}$$

掩码 m_i、f_i 和 u_i 区分已见表面、射线标记的自由空间和未知内容，满足 $m_i + f_i + u_i = 1$。置信度取有效观测中的最大值；两条可靠深度射线投票确立自由空间标签。主协议采用中心射线规则 C，足迹规则 F 检查单元的完整投影范围。天空特征利用相机旋转与天空语义，按观察方向聚合。

3.3. 联合潜空间补全

潜码编码。 类型专属编码器将 129 维聚合特征及空间支撑 $[\mathbf{h}_i; \mathbf{q}_i; \boldsymbol{\delta}_i]$ 输入带 LayerNorm 的 $135 \to 128 \to 128$ MLP。各类型均使用 $D = 128$ 维潜码，以便联合补全，同时保留查询类型、归属和坐标系。部分与完整分支共享此映射，掩码和置信度单独作为补全条件。未观测潜码置零，已见码记为 $\mathbf{z}^{\text{obs}}$。

跨组件记忆。 生成式补全模块（Generative Completion Module，GCM）由场景条件流 Transformer 与约束采样组成（图 3）。我们采用 DiT 风格的 Transformer [30] 参数化补全速度场，并通过流匹配训练 [22]。输入结合

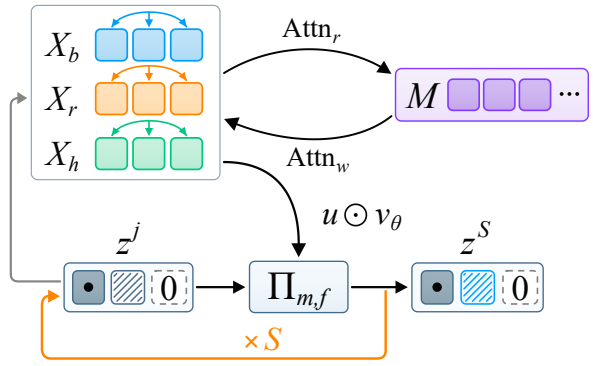

Figure 3. **联合潜空间补全**。CCM 读入局部特征并回写共享上下文，投影约束流更新只改变未知码。

当前潜码、已见潜码、掩码、置信度、类型、两种坐标描述、单元尺度和池化日志特征。背景按空间邻域分组，每个资产构成一个局部组，天空方向按立方体贴图面分组。局部自注意力分别处理各组，跨组件记忆（Cross-Component Memory，CCM）随后沿用诱导集合注意力 [17, 20]，通过可学习记忆 token 在各组之间交换上下文：

$$\mathbf{M}' = \mathbf{M} + \mathrm{Attn}_r(\mathbf{M}, \widetilde{\mathbf{X}}, \widetilde{\mathbf{X}}), \tag{6}$$

$$\mathbf{U} = \widetilde{\mathbf{X}} + \mathrm{Attn}_w(\mathrm{LN}(\widetilde{\mathbf{X}}), \mathbf{M}', \mathbf{M}'). \tag{7}$$

其中，$\widetilde{\mathbf{X}}$ 拼接局部 token，注意力参数依次为查询、键和值。记忆先读取全部局部组，再将更新后的场景上下文传回各组的 token。$\mathbf{U}$ 后接残差前馈更新。流时间调制局部归一化，记忆由可学习 token 与日志摘要初始化。

流训练与约束采样。 令 $\mathbf{z}_1$ 为同一查询布局上的完整目标，$\boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I})$ 为高斯噪声。在流时间 $\tau \in [0, 1]$，我们仅对未知内容插值：

$$\mathbf{z}_\tau = m \odot \mathbf{z}^{\mathrm{obs}} + u \odot [(1-\tau)\boldsymbol{\epsilon} + \tau \mathbf{z}_1]. \tag{8}$$

已见潜码固定，自由空间潜码保持为零。未知查询的目标速度为 $\mathbf{z}_1 - \boldsymbol{\epsilon}$。引入可选损失选择器 s_i，目标为

$$\mathcal{L}_{\mathrm{flow}} = \frac{\sum_i u_i s_i \|\mathbf{v}_\theta(\mathbf{z}_\tau, \tau, C)_i - (\mathbf{z}_{1,i} - \boldsymbol{\epsilon}_i)\|_2^2}{D \max(1, \sum_i u_i s_i)}. \tag{9}$$

先验学习使用全部未知查询均具有有效目标的样本，s_i 在这些目标中选择损失项（第 3.5 节）。

推理时，以噪声初始化未知潜码，并执行 S 次 Euler 步，步长为 $\Delta\tau = 1/S$：

$$\mathbf{z}^{j+1} = \Pi_{m,f}\left[\mathbf{z}^j + \Delta\tau\, u \odot \mathbf{v}_\theta(\mathbf{z}^j, j/S, C)\right]. \tag{10}$$

每步后 $\Pi_{m,f}$ 恢复已见潜码、清零自由空间潜码。种子确定一次补全，解码一次后跨状态复用。

分类型高斯解码。 背景、刚体和人体高斯解码器分别将每个查询独立映射为中心位于其支撑单元内的 $K = 4$ 个子高斯。人体子高斯继承查询的蒙皮权重；刚体子高斯共用所属资产的刚体变换。不透明度乘以 $1 - f_i$，使自由空间查询不能产生可见高斯。独立天空头在观测支持的方向域 V_{sky} 内预测立方体贴图颜色。

各查询独立解码，因此冻结编解码器并保留已见潜码即可保持已见高斯参数。自由射线损失约束新增高斯对可见性与透明度混合的影响，第 4.4 节给出实测。

3.4. 状态驱动场景组合

时刻 k 的状态 s_k 指定自车位姿、活动资产、刚体变换，以及人体根位姿与关节姿态。刚体变换更新规范高斯的中心和协方差，人体关节姿态通过存储的蒙皮权重使高斯变形，补全表面因此随相应身体部位运动。渲染器合成背景、活动资产和有效天空：

$$o_k = \mathcal{R}(\mathrm{Compose}(\mathcal{W}, s_k), \mathcal{C}_k). \tag{11}$$

背景与规范资产保持固定，新相机及参与者状态复用同一份完成内容。

3.5. 训练流程

训练先进行视觉恢复与潜表示拟合，再学习补全先验并通过渲染适配 GCM。完整目标沿用部分输入的查询布局 $\mathcal{Q}$，包括单元尺度、组件归属及人体绑定。完整网格提供各单元内的表面样本，多视图渲染与冻结视觉编码器得到 $\mathbf{h}_i^{\mathrm{full}}$，再由共享的类型专属编码器映射为 $\mathbf{z}_{1,i} = E_{k_i}([\mathbf{h}_i^{\mathrm{full}}; \mathbf{q}_i; \boldsymbol{\delta}_i])$。无表面单元采用零特征和不透明度监督。

潜表示拟合结束后，恢复模块和 codec 保持冻结。阶段三使用每个未知查询均具有完整目标的合成样本；阶段四仅更新 GCM，以 1:3 混合完整合成样本和 740 条真实训练日志。四阶段共更新 287,360 步，目标构造、网络规模和训练设置详见附录 B。

4. 实验

Waymo 实验评价重建精度与轨迹外渲染质量，隐藏表面配对测试与参与者编辑则评价联合补全及固定资产复用。主结果采用中心射线规则 C；补充材料比较足迹规则 F，并报告 nuScenes 零样本迁移。

4.1. 实验设置

数据与监督。 Waymo 的 798 条训练序列拆为 740 条训练和 58 条开发序列，202 条验证序列用于测试。合成训练使用 10,000 个场景、80 张地图、10,000 辆车和 2,500 个人体身份。源地图、车辆基础模型与人体身份先划分，再生成外观 / 动作变体；真实日志按路段、采集片段及可识别身份隔离。

基线。 STORM、DGGT 和 StreetForward [5, 49, 52] 均随机初始化，在相同真实日志、合成场景和完整资产上重训。各方法使用自身监督目标，Ours 另用单元空域及模板绑定监督。统一状态适配器为预测高斯分配归属并转入规范坐标，用于刚体和骨架放置。所有方法共享上下文 RGB、标定、自车位姿、车辆框 / 根轨迹及目标人体关节，体型与绑定来自上下文，测试权重固定。DGGT 指高斯分支 DGGT-G。

采样与指标。 每条测试序列取 200 帧，共形成 2,020 个互不重叠的 20 帧、10 Hz 片段。三个前向相机在 $\{0, 5, 10, 15\}$ 提供上下文 [49]，其余 12 帧插值与四帧外推共形成 96,960 张目标图像，外推使用给定状态。以 240×160 图像 [16] 计算全图 / 动态 PSNR 和 SSIM，并在有效 LiDAR 点计算深度 AbsRel/δ_1。深度逐帧尺度对齐后评价；指标按帧、片段、序列依次平均，各序列等权。

4.2. 动态场景重建

DriveCompose 在 Waymo 的六项指标上均领先（表 1），全图与动态区域 PSNR 分别比 DGGT 高 1.28 和 1.68 dB。改用由上下文预测的参与者状态时，动态区域 PSNR 降至 23.83 dB，仍比 DGGT 高 1.14 dB（附录 F）。图 4 显示更清晰的参与者轮廓与道路结构。

Table 1. **Waymo 条件重建**。插值与外推以 3:1 汇总。

	完整图像		动态区域		逐帧尺度对齐深度	
方法	PSNR ↑	SSIM ↑	PSNR ↑	SSIM ↑	AbsRel ↓	δ_1 ↑
STORM	25.79	0.782	22.38	0.617	0.194	0.733
DGGT	27.35	0.875	23.49	0.643	0.238	0.702
StreetForward	25.88	0.819	21.34	0.604	0.216	0.721
Ours	**28.63**	**0.903**	**25.17**	**0.867**	**0.093**	**0.881**

4.3. 轨迹外渲染

相机横向偏移 ±1、±2、±4 m，方向、内参和时间戳固定 [8, 55]，比较高斯分支及完整生成式管线。每个方向包含 121,200 张图像和 6,060 段 20 帧、10 Hz 视频，参考为相同片段、相机与时刻的原轨迹记录。左右方向分别计算 FID 和 FVD 后取均值（表 2）。

完整生成式对照包括 DGGT-Full 和 STORM+Difix [43]。Ours 在全部六项指标上领先（表 2），在固定参考区域评价中 MAE / LPIPS 也最低（附录 H）；图 5 给出离轨样例。

4.4. 状态驱动资产复用

资产编辑。 我们在 20 个真实场景上测试固定资产复用，每个场景各含一辆车和一个人体。相机平移 1 m、车辆旋转 30° 及人体换姿均复用固定完成资产。九组训练 / 生成种子共形成 360 次车辆与人体编辑；相机平移单独计分。结构完整性通过 334 / 360 次（92.78%），结构、新增表面纹理、身份与几何四项联合通过 298 / 360 次（82.78%）；Asset Harvester [2] 的联合通过率为 80.28%，其身份保持高 0.83 个百分点。扩展六档编辑的联合通过率为 74.54%，比 Asset Harvester 高 4.91 个百分点（附录 I）。

Table 2. **离轨视图分布质量**。左右方向分别计算 FID/FVD 后取均值。

方法	偏移 ±1 m		偏移 ±2 m		偏移 ±4 m	
	FID ↓	FVD ↓	FID ↓	FVD ↓	FID ↓	FVD ↓
STORM	65.27	756.43	87.63	1074.81	136.41	1762.37
DGGT-G	70.13	914.73	90.47	1135.81	127.69	1593.27
StreetForward	84.67	883.29	103.79	1103.67	125.31	1589.43
DGGT-Full	36.47	592.63	46.81	743.17	69.23	997.41
STORM+Difix	33.19	578.43	42.87	723.61	65.31	945.27
Ours	**28.52**	**544.27**	**37.43**	**673.17**	**58.19**	**817.13**

观测保持。 在固定相机与参与者状态下，相对仅已见场景，Ours 严格保持已见高斯参数，输入视角 PSNR 下降 0.03 dB，深度 MAE 增加 2 mm。人体原已见纹理的规范对应线性 RGB MAE 为 0.014。

效率。 RTX 4090 上（FP16、batch 1、C 规则），构建耗时 2.66 ± 0.11 s，单相机装配与 240×160 渲染耗时 7.8 ± 0.4 ms，峰值显存 14.2 GB。复用已构建资产，1,000 次输出的总成本摊销为每图 10.46 ms。480×320 输入与输出下，Ours 的全图 PSNR 比所有外部方法至少高 1.49 dB，单图渲染耗时 13.71 ms，DGGT-Full 为 161.87 ms（附录 K）。

Figure 4. **动态场景条件重建**。每行一个样例，依次为真实目标、DGGT、STORM、StreetForward 与 Ours。

Figure 5. **相机左移 2 m 的离轨渲染**。各列依次为 GT、STORM、DGGT、StreetForward 与 Ours。GT 为原轨迹记录图像。

4.5. 消融实验

Waymo 消融从每条测试序列取一个 29 时刻窗口，使用三相机与七个共享目标时刻。

补全组件。 w/o GCM 关闭非已见、非天空高斯。w/o CCM 使用各组件独立记忆，保留相同参数与全局日志条件，重新训练阶段三、四。变体共享恢复模块、codec、状态、数据和优化预算。训练均匀采样 T，推理使用 24 步 Euler 积分。生成版本平均三个训练种子与三个生成种子的全部输出；w/o GCM 为确定性对照。在 $T = 8$ 时，交换组件上下文使全图 / 动态 PSNR 分别提高 0.627 / 0.934 dB（表 3）。图 6 中，完整模型的信号灯杆轮廓更清晰，树冠纹理更鲜明。行人轮廓与车窗区域的局部形变和重影也更少。在具有配对隐藏表面参考的 100 个合成场景上，共享上下文的隐藏区域 PSNR 分别比任务适配的对象耦合与场景潜码补全高 0.67 和 0.94 dB，其增益从充分观测表面的 0.03–0.05 dB 增至严重缺失表面的 1.02–1.53 dB。查询数相同时，稠密注意力高 0.05 dB，而 CCM 补全速度快 1.93×，峰值显存低 42.71%（附录 H）。

Table 3. **Waymo 组件消融**。$T = 8$ 个时刻（24 张图像），恢复模块、codec 与目标视图相同。完整指标与 SD 见附录 G。

变体	全图			动态区域
	PSNR ↑	SSIM ↑	LPIPS ↓	PSNR ↑
w/o GCM	27.137	0.867	0.183	23.431
w/o CCM	28.286	0.893	0.147	24.683
Ours	**28.913**	**0.911**	**0.129**	**25.617**

(a) Ours (b) w/o CCM (c) w/o GCM

Figure 6. **补全组件消融**。每行一个场景，各列依次为 Ours、w/o CCM 和 w/o GCM。彩色框标记各图下方对应的放大区域。

输入时刻数量敏感性。 固定 checkpoint，在相同时间跨度与目标视图上使用 $T = 2, 4, 8$ 嵌套输入（6 / 12 / 24 张图像），每档均从所给输入重新构建证据与查询。CCM 的 PSNR 增益分别为 1.104、0.738 和 0.627 dB，LPIPS 分别降低 0.041、0.028 和 0.018（表 4），输入最稀疏时收益最大。

Table 4. **输入时刻数量敏感性**。固定 checkpoint、时间跨度与目标视图；T 为时间戳数，每时刻含三路图像。

T	变体	PSNR ↑	SSIM ↑	LPIPS ↓
2	w/o CCM	25.237	0.817	0.254
2	Ours	**26.341**	**0.851**	**0.213**
4	w/o CCM	27.126	0.869	0.187
4	Ours	**27.864**	**0.891**	**0.159**
8	w/o CCM	28.286	0.893	0.147
8	Ours	**28.913**	**0.911**	**0.129**

5. 讨论

DriveCompose 在固定照明下重建有限区域，车辆采用刚体表示，人体绑定固定骨架和衣物体积。深度、身份与规范姿态的精度决定补全继承的已见锚点。图 4 的行人和停放皮卡附近存在残余重建伪影，编辑失败集中于大幅肘弯、腿部自遮挡和宽松衣物边界。重光照与衣物几何变化需要更丰富的外观和形变模型。

6. 结论

DriveCompose 联合补全世界空间背景与规范参与者潜码，保留组件身份和运动绑定，实现状态驱动复用。在合成配对测试中，共享场景上下文相对任务适配的场景潜码和对象耦合对照，改善隐藏几何与外观。固定高斯资产支持相机平移、车辆旋转和人体换姿。Waymo 重建、配对表面指标及多维真实编辑评价验证了补全质量与状态复用。

LLM Usage Statement

OpenAI Codex 用于辅助论文修订、翻译、LaTeX 编辑与一致性检查。OpenAI Image Gen 辅助概念场景与方法插图设计。总览图采用作者提供的 PDF，联合补全机制图通过 draw.io 重建为可编辑矢量图。这些图件均为机制示意。报告的实验数值由作者提供，作者对科学内容负责。

References

[1] Holger Caesar, Varun Bankiti, Alex H. Lang, Sourabh Vora, Venice Erin Liong, Qiang Xu, Anush Krishnan, Yu Pan, Giancarlo Baldan, and Oscar Beijbom. nuScenes: A Multimodal Dataset for Autonomous Driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 11621–11631, 2020. 1

[2] Tianshi Cao, Jiawei Ren, Yuxuan Zhang, Jaewoo Seo, Jiahui Huang, Shikhar Solanki, Haotian Zhang, Mingfei Guo,

Haithem Turki, Muxingzi Li, Yue Zhu, Sipeng Zhang, Zan Gojcic, Sanja Fidler, and Kangxue Yin. Asset harvester: Extracting 3d assets from autonomous driving logs for simulation. *arXiv preprint arXiv:2604.18468*, 2026. 5

[3] David Charatan, Sizhe Lester Li, Andrea Tagliasacchi, and Vincent Sitzmann. pixelSplat: 3D Gaussian Splats from Image Pairs for Scalable Generalizable 3D Reconstruction. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 19457–19467, 2024. 2

[4] Shijie Chen and Peixi Peng. Freegen: Feed-forward reconstruction–generation co-training for free-viewpoint driving scene synthesis. In *Computer Vision – ECCV 2026*, pages 682–699. Springer, 2026. 2

[5] Xiaoxue Chen, Ziyi Xiong, Yuantao Chen, Gen Li, Nan Wang, Hongcheng Luo, Long Chen, Haiyang Sun, Bing Wang, Guang Chen, Hongyang Li, Ya-Qin Zhang, Hangjun Ye, and Hao Zhao. DGGT: Feedforward 4D Reconstruction of Dynamic Driving Scenes using Unposed Images. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 1265–1276, 2026. 1, 2, 5

[6] Yuedong Chen, Haofei Xu, Chuanxia Zheng, Bohan Zhuang, Marc Pollefeys, Andreas Geiger, Tat-Jen Cham, and Jianfei Cai. MVSplat: Efficient 3D Gaussian Splatting from Sparse Multi-View Images. In *European Conference on Computer Vision (ECCV)*, 2024. 2

[7] Ziyu Chen, Jiawei Yang, Jiahui Huang, Riccardo de Lutio, Janick Martinez Esturo, Boris Ivanovic, Or Litany, Zan Gojcic, Sanja Fidler, Marco Pavone, Li Song, and Yue Wang. OmniRe: Omni Urban Scene Reconstruction. In *International Conference on Learning Representations*, pages 85508–85527, 2025. 1, 2

[8] Cheng Chi, Xianqi Wang, Hongcheng Luo, Mingfei Tu, Gangwei Xu, Zehan Zhang, Bing Wang, Guang Chen, Hangjun Ye, Sida Peng, Xin Yang, and Haiyang Sun. PointForward: Feedforward Driving Reconstruction through Point-Aligned Representations. *arXiv preprint arXiv:2605.11594*, 2026. 1, 2, 5

[9] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. In *International Conference on Learning Representations (ICLR)*, 2021. 2

[10] Ruiyuan Gao, Kai Chen, Enze Xie, Lanqing HONG, Zhenguo Li, Dit-Yan Yeung, and Qiang Xu. MagicDrive: Street View Generation with Diverse 3D Geometry Control. In *International Conference on Learning Representations*, pages 22841–22860, 2024. 2

[11] Ruiqi Gao, Aleksander Hołyński, Philipp Henzler, Arthur Brussee, Ricardo Martin-Brualla, Pratul Srinivasan, Jonathan T. Barron, and Ben Poole. CAT3D: Create Anything in 3D with Multi-View Diffusion Models. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 75468–75494, 2024. 2

[12] Shenyuan Gao, Jiazhi Yang, Li Chen, Kashyap Chitta, Yihang Qiu, Andreas Geiger, Jun Zhang, and Hongyang Li. Vista: A Generalizable Driving World Model with High Fidelity and Versatile Controllability. In *Advances in Neural Information Processing Systems*, pages 91560–91596, 2024. 2

[13] Georg Hess, Carl Lindström, Maryam Fatemi, Christoffer Petersson, and Lennart Svensson. SplatAD: Real-Time Lidar and Camera Rendering with 3D Gaussian Splatting for Autonomous Driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 11982–11992, 2025. 2

[14] Yicong Hong, Kai Zhang, Jiuxiang Gu, Sai Bi, Yang Zhou, Difan Liu, Feng Liu, Kalyan Sunkavalli, Trung Bui, and Hao Tan. LRM: Large Reconstruction Model for Single Image to 3D. In *International Conference on Learning Representations*, pages 50678–50702, 2024. 2

[15] Shoukang Hu, Tao Hu, and Ziwei Liu. GauHuman: Articulated Gaussian Splatting from Monocular Human Videos. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 20418–20431, 2024. 2

[16] Jiahui Huang, Jiawei Ren, Michal Tyszkiewicz, Bjoern Haefner, Michael Shelley, Xin Kang, Seung Wook Kim, Ning Xu, Qi Wu, Janick Martinez Esturo, Shengyu Huang, Nick Schneider, Laura Leal-Taixé, Zan Gojcic, and Sanja Fidler. Instant NuRec: Feed-Forward 3D Gaussian Reconstruction for Driving Scene Simulation. *arXiv preprint arXiv:2607.14203*, 2026. 2, 5

[17] Andrew Jaegle, Felix Gimeno, Andy Brock, Oriol Vinyals, Andrew Zisserman, and Joao Carreira. Perceiver: General Perception with Iterative Attention. In *Proceedings of the 38th International Conference on Machine Learning (ICML)*, pages 4651–4664, 2021. 4

[18] Bernhard Kerbl, Georgios Kopanas, Thomas Leimkühler, and George Drettakis. 3D Gaussian Splatting for Real-Time Radiance Field Rendering. *ACM Transactions on Graphics*, 42(4), 2023. 2

[19] Muhammed Kocabas, Jen-Hao Rick Chang, James Gabriel, Oncel Tuzel, and Anurag Ranjan. HUGS: Human Gaussian Splats. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 505–515, 2024. 2

[20] Juho Lee, Yoonho Lee, Jungtaek Kim, Adam Kosiorek, Seungjin Choi, and Yee Whye Teh. Set Transformer: A Framework for Attention-based Permutation-Invariant Neural Networks. In *Proceedings of the 36th International Conference on Machine Learning (ICML)*, pages 3744–3753, 2019. 4

[21] Ziwei Liao, Mohamed Sayed, Steven L. Waslander, Sara Vicente, Daniyar Turmukhambetov, and Michael Firman. Complete Gaussian Splats from a Single Image with Denoising Diffusion Models. *arXiv preprint arXiv:2508.21542*, 2025. 1, 2

[22] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow Matching for Generative Modeling. In *International Conference on Learning Representations*, 2023. 2, 3

[23] Ruoshi Liu, Rundi Wu, Basile Van Hoorick, Pavel Tokmakov, Sergey Zakharov, and Carl Vondrick. Zero-1-to-3: Zero-shot One Image to 3D Object. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 9298–9309, 2023. 2

[24] Matthew Loper, Naureen Mahmood, Javier Romero, Gerard Pons-Moll, and Michael J. Black. SMPL: A Skinned Multi-Person Linear Model. *ACM Trans. Graphics (Proc. SIGGRAPH Asia)*, 34(6):248:1–248:16, 2015. 2

[25] Yichong Lu, Yichi Cai, Shangzhan Zhang, Hongyu Zhou, Haoji Hu, Huimin Yu, Andreas Geiger, and Yiyi Liao. UrbanCAD: Towards Highly Controllable and Photorealistic 3D Vehicles for Urban Scene Simulation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 27519–27530, 2025. 2

[26] Ben Mildenhall, Pratul P. Srinivasan, Matthew Tancik, Jonathan T. Barron, Ravi Ramamoorthi, and Ren Ng. NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis. In *European Conference on Computer Vision (ECCV)*, 2020. 2

[27] Julian Ost, Fahim Mannan, Nils Thuerey, Julian Knodt, and Felix Heide. Neural Scene Graphs for Dynamic Scenes. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2856–2865, 2021. 2

[28] Jinhyung Park, Navyata Sanghvi, Erica Weng, Shawn Hunt, Shinya Tanaka, Hironobu Fujiyoshi, and Kris Kitani. Grounded Latents for Entity-Centric 4D Scene Generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 21420–21430, 2026. 2

[29] Georgios Pavlakos, Vasileios Choutas, Nima Ghorbani, Timo Bolkart, Ahmed A. A. Osman, Dimitrios Tzionas, and Michael J. Black. Expressive Body Capture: 3D Hands, Face, and Body From a Single Image. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 10975–10985, 2019. 2

[30] William Peebles and Saining Xie. Scalable Diffusion Models with Transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 4195–4205, 2023. 3

[31] Zhiyin Qian, Shaofei Wang, Marko Mihajlovic, Andreas Geiger, and Siyu Tang. 3DGS-Avatar: Animatable Avatars via Deformable 3D Gaussian Splatting. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 5020–5030, 2024. 2

[32] Lingteng Qiu, Xiaodong Gu, Peihao Li, Qi Zuo, Weichao Shen, Junfei Zhang, Kejie Qiu, Weihao Yuan, Guanying Chen, Zilong Dong, and Liefeng Bo. LHM: Large Animatable Human Reconstruction Model for Single Image to 3D in Seconds. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 14184–14194, 2025. 2

[33] Jiawei Ren, Michal Jan Tyszkiewicz, Jiahui Huang, and Zan Gojcic. TokenGS: Decoupling 3D Gaussian Prediction from Pixels with Learnable Tokens. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 15365–15375, 2026. 2

[34] Yichun Shi, Peng Wang, Jianglong Ye, Long Mai, Kejie Li, and Xiao Yang. MVDream: Multi-view Diffusion for 3D Generation. In *International Conference on Learning Representations*, pages 39838–39859, 2024. 2

[35] Pei Sun, Henrik Kretzschmar, Xerxes Dotiwalla, Aurelien Chouard, Vijaysai Patnaik, Paul Tsui, James Guo, Yin Zhou, Yuning Chai, Benjamin Caine, Vijay Vasudevan, Wei Han, Jiquan Ngiam, Hang Zhao, Aleksei Timofeev, Scott Ettinger, Maxim Krivokon, Amy Gao, Aditya Joshi, Sheng Zhao, Shuyang Cheng, Yu Zhang, Jonathon Shlens, Zhifeng Chen, and Dragomir Anguelov. Scalability in Perception for Autonomous Driving: Waymo Open Dataset. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2446–2454, 2020. 1

[36] Qijian Tian, Xin Tan, Yuan Xie, and Lizhuang Ma. DrivingForward: Feed-forward 3D Gaussian Splatting for Driving Scene Reconstruction from Flexible Surround-view Input. In *Proceedings of the AAAI Conference on Artificial Intelligence*, pages 7374–7382, 2025. 2

[37] Adam Tonderski, Carl Lindström, Georg Hess, William Ljungbergh, Lennart Svensson, and Christoffer Petersson. NeuRAD: Neural Rendering for Autonomous Driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14895–14904, 2024. 2

[38] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Ł ukasz Kaiser, and Illia Polosukhin. Attention is All you Need. In *Advances in Neural Information Processing Systems*, 2017. 2

[39] Jianyuan Wang, Minghao Chen, Nikita Karaev, Andrea Vedaldi, Christian Rupprecht, and David Novotny. VGGT: Visual Geometry Grounded Transformer. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 5294–5306, 2025. 2

[40] Shuzhe Wang, Vincent Leroy, Yohann Cabon, Boris Chidlovskii, and Jerome Revaud. DUSt3R: Geometric 3D Vision Made Easy. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 20697–20709, 2024. 2

[41] Xiaofeng Wang, Zheng Zhu, Guan Huang, Xinze Chen, Jiagang Zhu, and Jiwen Lu. DriveDreamer: Towards Real-world-driven World Models for Autonomous Driving. In *European Conference on Computer Vision (ECCV)*, 2024. 2

[42] Yifan Wang, Francesco Pittaluga, Zaid Tasneem, Chenyu You, Manmohan Chandraker, and Ziyu Jiang. HorizonForge: Driving Scene Editing with Any Trajectories and Any Vehicles. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026. 2

[43] Jay Zhangjie Wu, Yuxuan Zhang, Haithem Turki, Xuanchi Ren, Jun Gao, Mike Zheng Shou, Sanja Fidler, Zan Gojcic, and Huan Ling. DIFIX3D+: Improving 3D Reconstructions with Single-Step Diffusion Models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 26024–26035, 2025. 2, 5

[44] Qirui Wu, Yawar Siddiqui, Duncan Frost, Samir Aroudj, Armen Avetisyan, Richard Newcombe, Angel X. Chang, Jakob Engel, and Henry Howard-Jenkins. JRM: Joint Reconstruc-

tion Model for Multiple Objects without Alignment. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 307–316, 2026. 2

[45] Jianfeng Xiang, Zelong Lv, Sicheng Xu, Yu Deng, Ruicheng Wang, Bowen Zhang, Dong Chen, Xin Tong, and Jiaolong Yang. Structured 3D Latents for Scalable and Versatile 3D Generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 21469–21480, 2025. 2

[46] Jianfeng Xiang, Xiaoxue Chen, Sicheng Xu, Ruicheng Wang, Zelong Lv, Yu Deng, Hongyuan Zhu, Yue Dong, Hao Zhao, Nicholas Jing Yuan, and Jiaolong Yang. Native and Compact Structured Latents for 3D Generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14419–14429, 2026. 2

[47] Yunzhi Yan, Haotong Lin, Chenxu Zhou, Weijie Wang, Haiyang Sun, Kun Zhan, Xianpeng Lang, Xiaowei Zhou, and Sida Peng. Street Gaussians: Modeling Dynamic Urban Scenes with Gaussian Splatting. In *European Conference on Computer Vision (ECCV)*, 2024. 1, 2

[48] Yunzhi Yan, Zhen Xu, Haotong Lin, Haian Jin, Haoyu Guo, Yida Wang, Kun Zhan, Xianpeng Lang, Hujun Bao, Xiaowei Zhou, and Sida Peng. StreetCrafter: Street View Synthesis with Controllable Video Diffusion Models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 822–832, 2025. 1, 2

[49] Jiawei Yang, Jiahui Huang, Boris Ivanovic, Yuxiao Chen, Yan Wang, Boyi Li, Yurong You, Apoorva Sharma, Maximilian Igl, Peter Karkus, Danfei Xu, Yue Wang, and Marco Pavone. STORM: Spatio-TempOral Reconstruction Model For Large-Scale Outdoor Scenes. In *International Conference on Learning Representations*, pages 50446–50465, 2025. 1, 2, 5

[50] Ze Yang, Yun Chen, Jingkang Wang, Sivabalan Manivasagam, Wei-Chiu Ma, Anqi Joyce Yang, and Raquel Urtasun. UniSim: A Neural Closed-Loop Sensor Simulator. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 1389–1399, 2023. 1, 2

[51] Ze Yang, Jingkang Wang, Haowei Zhang, Sivabalan Manivasagam, Yun Chen, and Raquel Urtasun. GenAssets: Generating in-the-wild 3D Assets in Latent Space. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 22392–22403, 2025. 1, 2

[52] Zhongrui Yu, Zhao Wang, Yijia Xie, Yida Wang, Xueyang Zhang, Yifei Zhan, and Kun Zhan. StreetForward: Perceiving Dynamic Street with Feedforward Causal Attention. *arXiv preprint arXiv:2603.19552*, 2026. 1, 2, 5

[53] Hongyu Zhou, Longzhong Lin, Jiabao Wang, Yichong Lu, Dongfeng Bai, Bingbing Liu, Yue Wang, Andreas Geiger, and Yiyi Liao. HUGSIM: A Real-Time, Photo-Realistic and Closed-Loop Simulator for Autonomous Driving. *arXiv preprint arXiv:2412.01718*, 2024. 1, 2

[54] Xiaoyu Zhou, Zhiwei Lin, Xiaojun Shan, Yongtao Wang, Deqing Sun, and Ming-Hsuan Yang. DrivingGaussian: Composite Gaussian Splatting for Surrounding Dynamic Autonomous Driving Scenes. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 21634–21643, 2024. 2

[55] Ziyue Zhu, Zhanqian Wu, Zhenxin Zhu, Lijun Zhou, Haiyang Sun, Bing Wan, Kun Ma, Guang Chen, Hangjun Ye, Jin Xie, and Jian Yang. WorldSplat: Gaussian-Centric Feed-Forward 4D Scene Generation for Autonomous Driving. *arXiv preprint arXiv:2509.23402*, 2025. 1, 2, 5

[56] Yiyu Zhuang, Jiaxi Lv, Hao Wen, Qing Shuai, Ailing Zeng, Hao Zhu, Shifeng Chen, Yujiu Yang, Xun Cao, and Wei Liu. IDOL: Instant Photorealistic 3D Human Creation from a Single Image. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 26308–26319, 2025. 2