DriveCompose：通过联合补全实现驾驶场景的可组合生成式重建

Anonymous CVPR submission

Paper ID *****

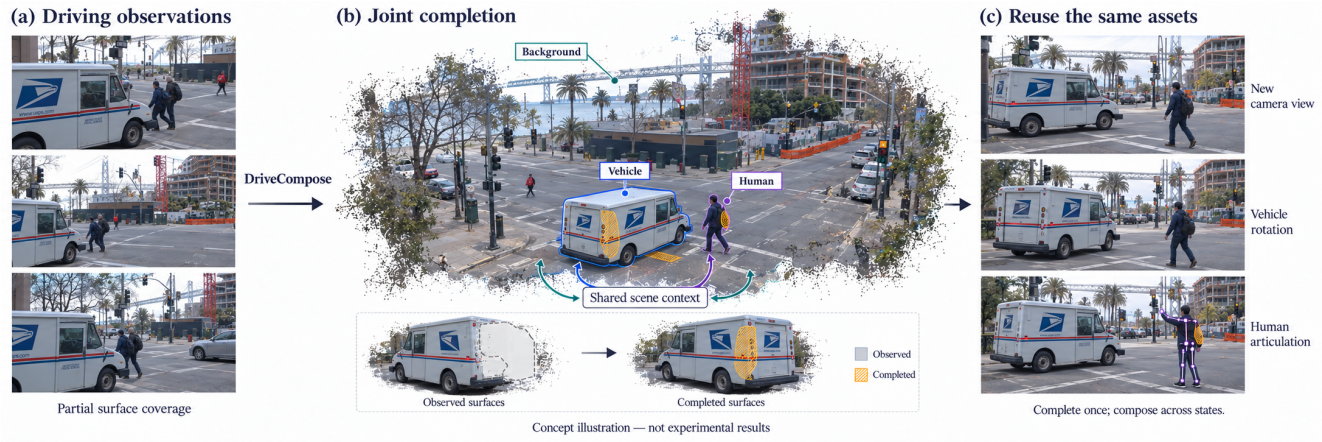

Figure 1. **DriveCompose 概念示意**。从驾驶图像中联合补全背景、车辆与人体的内容，构建可组合高斯场景。同一组资产可在相机视角、车辆位姿和人体姿态变化时复用。金色标注表示补全区域。

Abstract

驾驶仿真与场景编辑需要重建场景在相机和参与者偏离记录状态后仍可使用。相机移动或参与者运动会暴露此前未被拍摄的表面，因此需要补全这些表面的几何与外观，并使补全内容保持归属于相应的背景、刚体或人体。我们提出 *DriveCompose*，从图像序列中生成式地重建可组合驾驶场景。视觉特征在背景的世界坐标系与刚体、人体各自的规范坐标系中聚合，再编码为对应组件的潜表示。通过流匹配训练的条件生成模型利用跨组件记忆共享场景上下文，联合补全这些表示中的缺失潜码。补全过程受输入观测约束，以保持已观测表面的几何与外观。在 *Waymo* 上，*DriveCompose* 的动态场景重建和轨迹外视图合成效果优于所评估的基线。分类型解码器将补全潜码转换为高斯组件，其刚体与骨架绑定支持在不同相机和参与者状态下组合场景。

1. 引言

驾驶仿真与场景编辑需要能够支持相机移动、车辆运动和人体姿态变化的三维场景 [46, 49]。然而，驾驶日志中的图像只提供采集视角和当时参与者状态下的可见表面 [1, 31]。移动相机、转动车辆或改变行人姿态，都会暴露此前未观测的区域（图 2）。因此，场景重建需要补全这些区域的几何与外观，并使补全后的车辆和人体表面能够随所属对象运动。

近期前馈方法通过融合多帧图像，直接预测驾驶场景的三维几何与高斯表示 [3, 6, 45, 48]。运动估计与可见性建模进一步帮助这些方法对齐动态对象，并整合不同时刻的观测。多帧融合增加了对输入序列中可见表面的覆盖。当新视角或对象运动暴露出整个序列都未曾拍摄的表面时，重建需要推断其几何与外观。

生成式重建通过资产先验、高斯补全或生成视图推断未观测内容 [17, 44, 47, 51]。与此同时，可组合重建将背景与运动对象分开表示，支持车辆移动和人体姿态控制 [5, 43, 49]。将生成补全用于这类场景，需要使补出的表面随所属对象运动。当对象仅被部分观测时，背景与其他对象的信息可为推断其缺失内容提供补充上下文。

为此，我们提出 DriveCompose，从驾驶图像序列中构建可独立控制、并经过生成补全的三维场景。我们在世界坐标系中表示背景，在刚体资产自身的坐标系中表示其表面，并在参考姿态下表示人体、保留其骨架绑定 [5, 43]。补全直接在这些表示中进行，使生成的刚体和人体表面能够随所属对象运动或改变姿态（第 3.1 节）。在此基础上，模型通过共享场景上下文，联合补

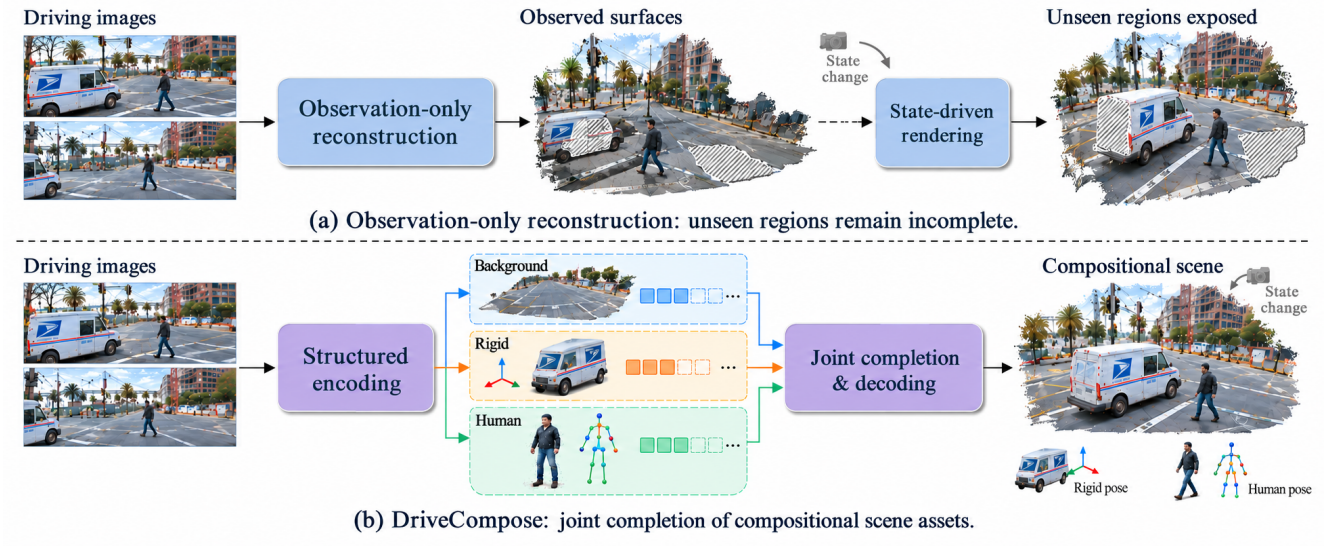

Figure 2. **从观测表面到可组合场景资产**。(a) 仅依赖观测的重建在视角或参与者状态变化时暴露未补全表面。(b) DriveCompose 联合补全背景与规范刚体、人体资产，再按指定状态组合场景。场景画面均为机制示意。

全背景与各对象的缺失内容。

图 3 展示完整重建流程。视觉编码器提取图像特征，并估计场景几何与参与者运动。运动感知聚合将跨视角、跨时刻特征对齐到背景和规范资产坐标系，类型专属编码器再将其映射为维度统一的潜码。局部注意力建模各组件内部的结构，跨组件记忆汇集背景与参与者特征，并将共享场景上下文传回各组件，使缺失表面能够同时依据局部观测与周围场景推断。模型通过流匹配学习联合补全 [18]，并在补全过程中保留已见潜码。

分类型高斯解码器将补全潜码转换为背景、规范刚体和关节化人体 [15]。刚体几何随资产位姿移动，人体几何通过蒙皮权重随骨架运动。场景组合按照指定的相机与参与者状态，将这些组件放置到世界坐标系，在状态变化时复用同一份补全内容（第 3.7 节）。

在 Waymo 上，DriveCompose 在动态场景重建和轨迹外视图合成中优于所评估的基线（第 4 节）。

本文的贡献包括：

- 提出面向闭环驾驶仿真的生成式重建框架 DriveCompose。从图像序列中恢复并补全背景、车辆与人体，构建可组合的高斯场景资产。所得场景可在相机位姿、车辆位姿和人体姿态变化时，复用同一组补全资产进行组合与渲染。
- 设计基于条件流匹配的跨组件潜空间补全模型。通过局部注意力建模各组件内部的空间关系，通过跨组件记忆汇集背景与参与者的特征，为各组件的缺失内容生成提供场景上下文。
- 通过动态重建、轨迹外视图合成与组件消融评估框架及其关键机制。实验表明，DriveCompose 在动态场景重建和轨迹外视图合成中优于所评估的基线。

2. 相关工作

驾驶场景重建。 NeRF 与高斯泼溅为城市重建提供辐射表示 [15, 22]，NeuRAD 和 SplatAD 进一步发展面向驾驶场景的渲染 [11, 33]。前馈方法从图像学习几何恢复与高斯预测 [2, 4, 12, 35, 36]。对于驾驶日志，STORM 通过场景流聚合动态高斯，DGGT 则结合相机恢复、时间可见性和运动引导插值 [3, 45]。DrivingForward、StreetForward、PointForward 和 Instant NuRec 进一步探索环视输入、时序处理、点对齐表示及面向仿真的重建 [6, 14, 32, 48]。TokenGS 也通过可学习 token 解耦像素与高斯预测 [29]。DriveCompose 将恢复的证据聚合到背景与规范资产支撑上，再通过条件生成补全缺失内容并解码为高斯。

可组合场景与可控资产。 Neural Scene Graphs、Street Gaussians 和 DrivingGaussian 将场景分为背景与运动组件 [23, 43, 50]。OmniRe 包含刚体与关节化参与者的规范表示，UniSim 和 HUGSIM 则将重建内容接入闭环仿真 [5, 46, 49]。在资产层面，基于 SMPL 的人体模型和可驱动高斯方法提供规范表面与运动绑定 [13, 16, 20, 25, 27]；LHM 与 IDOL 推断可驱动人体，UrbanCAD 面向可控车辆 [21, 28, 52]。这些工作建立了操控场景组件所需的表示与控制机制。本文的补全变量保留这一组件结构，使生成表面继承资产身份、坐标系和运动绑定。

生成式重建与补全。 图像条件三维生成可通过生成视图 [9, 19, 30] 或编码几何与外观的结构化潜变量实现 [41, 42]。GenAssets 学习驾驶资产先验，CompleteSplat 补全隐藏的高斯内容，JRM 通过潜空间流匹配聚合未对齐的对象观测 [17, 40, 47]。LatentWorld 围绕实体和

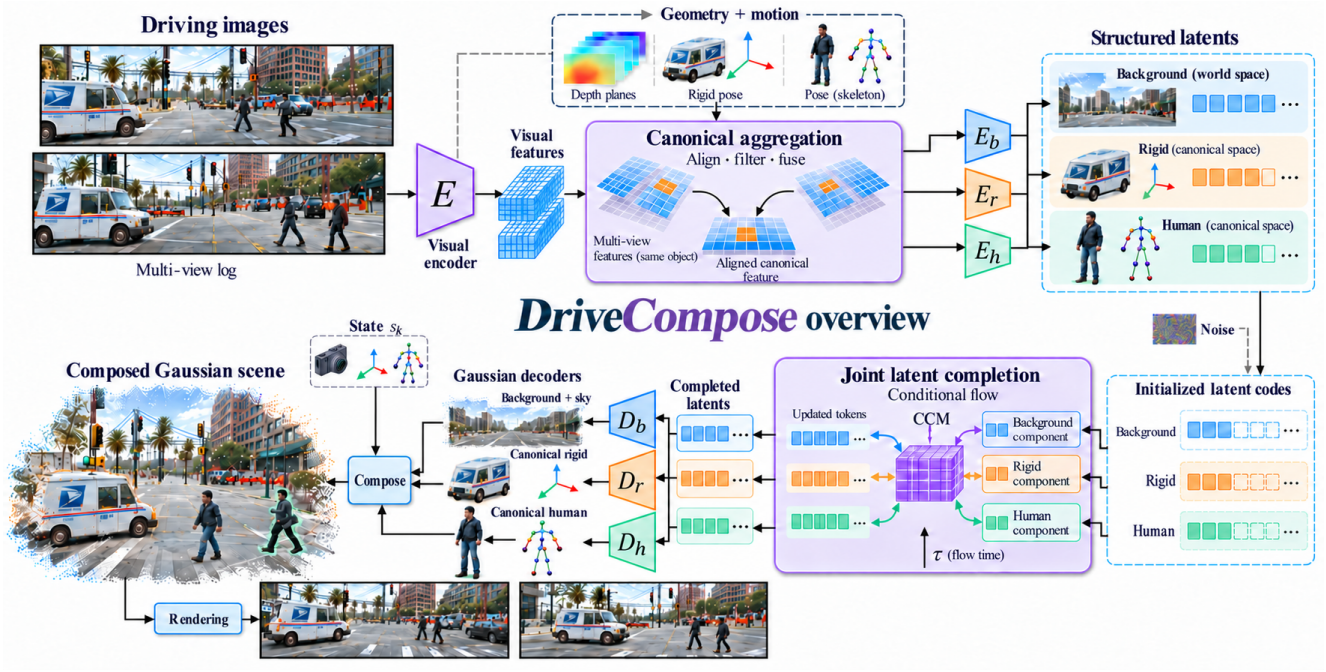

Figure 3. **DriveCompose 总览**。视觉编码与运动感知的规范聚合恢复组件特征，类型专属编码器将其映射为结构化潜码。条件流补全通过跨组件上下文推断未知内容，高斯解码器生成背景、刚体与人体组件，用于状态驱动的场景组合和渲染。场景与资产画面均为机制示意。

背景潜变量组织语义占据生成 [24]。DriveCompose 面向以驾驶日志为条件、可供 RGB 渲染的重建：共享补全模型在世界空间背景与规范刚体、人体潜码之间交换上下文。已见潜码和已知自由空间为补全提供条件，分类型解码器保留各组件的空间坐标系与运动绑定。

驾驶场景与视频生成。 MagicDrive、DriveDreamer 和 Vista 以场景结构或控制为条件生成驾驶图像 [8, 10, 37]。StreetCrafter 用生成视图监督动态高斯重建，HorizonForge 将场景编辑与视频扩散结合 [38, 44]。WorldSplat 生成高斯并细化其渲染视频，DIFIX3D+ 则通过扩散模型细化图像 [39, 51]。这些方法在不同阶段连接生成图像与三维场景表示。DriveCompose 在场景构建阶段完成补全并保存背景与规范资产，后续相机、刚体与骨架状态均渲染同一份补全内容。

3. 方法

DriveCompose 从多视角图像序列出发，依次经过视觉编码、规范空间特征聚合、潜表示编码、联合潜空间补全、分类型高斯解码与场景组合，得到可组合高斯场景（图 3）。规范聚合将各组件在不同时刻的观测对齐，联合补全则利用周围场景推断其缺失的几何与外观。

3.1. 问题定义与可组合表示

输入是同步图像日志 $\mathbf{I}_{t,v}$、时间戳、相机内参及相机到传感器支架的标定。支架位姿由日志提供，或以第一帧为参考估计。坐标约定与图像预处理见补充材料附录 D。

输出为可组合高斯场景

$$\mathcal{W} = \big(\mathcal{G}_b, C_{\text{sky}}, V_{\text{sky}}, \{\mathcal{A}_a\}, \mathcal{B}, \xi\big), \tag{1}$$

其中，$\mathcal{G}_b$ 是世界空间背景，C_{sky} 是天空立方体贴图，V_{sky} 表示其有效方向，$\mathcal{A}_a$ 是身份 a 对应的规范资产，$\mathcal{B}$ 是有限空间支撑，ξ 是采样种子。这些组件通过高斯泼溅渲染 [15]。车辆表示为局部几何与尺寸固定的刚体资产，人体另存静止骨架和蒙皮权重。场景状态控制这些固定组件的放置与关节运动。

我们通过条件生成建模缺失内容。令 $\mathcal{Q}$ 为恢复得到的查询布局，C 为其观测证据。补全模型采样未知潜码 $\mathbf{z}_u$，编解码器 D_ψ 将组合后的潜码解码为场景内容：

$$\mathbf{z}_u \sim p_\theta(\mathbf{z}_u \mid C, \mathcal{Q}), \qquad \mathcal{W} = D_\psi(\mathbf{z}^{\text{obs}}, \mathbf{z}_u; \mathcal{Q}). \tag{2}$$

查询布局为每个潜码指定空间位置和所属组件。补全在这一布局中生成未知潜码，解码后仍保留其组件身份与运动绑定。

3.2. 视觉编码

Driving Log Encoder 从各图像提取 patch 特征，并在相机与时间戳之间交换池化上下文 [7, 34]。几何预测头输出相机光轴深度、法线、置信度、语义和实例归属，将图像特征关联到三维表面及其所属组件。轨迹级身份

槽将持久身份、尺寸和人体体型与逐帧变化的根位姿、关节旋转分开表示。网络结构与状态参数化细节见补充材料附录 D。

3.3. 规范空间特征聚合

空间支撑。 每个查询存储规范位置 $\mathbf{q}_i$、单元尺度 $\boldsymbol{\delta}_i$、类型 k_i、局部注意力组 g_i 和参考世界坐标 $\mathbf{q}_i^w$。可靠深度样本提供表面锚点。背景锚点与有限世界网格结合；刚体锚点经逆 SE(3) 变换对齐后，与局部包围体中的网格结合。人体查询位于规范模板表面，天空查询为按立方体贴图面分组的单位方向。这些支撑为已见与缺失内容提供明确位置。

补全过程中布局保持固定。我们将查询放到第一帧的配置中以得到 $\mathbf{q}_i^w$，其中人体包含蒙皮变换。规范坐标标识组件内部的内容，参考世界坐标则使生成器能够联系该组件与周围场景。

运动感知证据聚合。 对于每份观测，我们将规范查询放到对应的资产状态：

$$\mathbf{p}_i(t) = \begin{cases} \mathbf{q}_i, & k_i = \text{background}, \\ \mathrm{xyz}(\mathbf{T}_a^w(t)\bar{\mathbf{q}}_i), & k_i = \text{rigid}, \\ \mathrm{xyz}(\mathbf{T}_h^w(t)\mathbf{A}_i(t)\bar{\mathbf{q}}_i), & k_i = \text{human}. \end{cases} \tag{3}$$

其中，$\bar{\mathbf{q}}_i$ 为齐次坐标，xyz 提取欧氏坐标，$\mathbf{A}_i(t)$ 为加权蒙皮变换。投影得到查询深度 $z_{i,t,v}$，并采样图像特征 $\boldsymbol{\phi}_{i,t,v}$、深度 $d_{i,t,v}$ 和置信度 $c_{i,t,v}$，按置信度及归一化深度残差 $r = (d - z)/(\eta_{\text{abs}} + \eta_{\text{rel}} d)$ 为观测赋权。指示量 $a_{i,t,v}$ 选择同一实例中可见且深度一致的观测（附录 D）：

$$w_{i,t,v} = a_{i,t,v} c_{i,t,v} \exp(-r_{i,t,v}^2/2), \tag{4}$$

$$\mathbf{h}_i = \frac{\sum_{t,v} w_{i,t,v} [\boldsymbol{\phi}_{i,t,v}; r_{i,t,v}]}{\max(\varepsilon, \sum_{t,v} w_{i,t,v})}. \tag{5}$$

掩码 m_i、f_i 和 u_i 区分已见表面、已知自由空间和未知内容，满足 $m_i + f_i + u_i = 1$。置信度取有效观测的最大值，自由空间由可靠深度射线确定。天空特征依据相机旋转和天空语义，按观察方向聚合。可见性与自由空间判定式见附录 D。

3.4. 潜表示编码

类型专属编码器将聚合特征及其空间支撑 $[\mathbf{h}_i; \mathbf{q}_i; \boldsymbol{\delta}_i]$ 压缩为潜码 $\mathbf{z}_i \in \mathbb{R}^D$。统一的潜码维度使补全模型能够在背景、刚体和人体表示之间交换信息。各潜码维度相同，但查询仍保留类型、归属和坐标系。可见性掩码与置信度单独提供给补全模型，使部分观测与完整观测使用同一潜码编码映射。作为条件输入之前，未观测潜码置零；已见子集记为 $\mathbf{z}^{\text{obs}}$。

3.5. 联合潜空间补全

生成式补全模块。 生成式补全模块（Generative Completion Module，GCM）由场景条件流 Transformer 与约束采样组成（图 4）。我们采用 DiT 风格的 Transformer [26] 参数化补全速度场，并通过流匹配训练 [18]。输入结合当前潜码、已见潜码、掩码、置信度、类型、两种坐标描述、单元尺度和池化日志特征。背景按空间邻域分组，每个资产构成一个局部组，天空方向按立方体贴图面分组。局部自注意力分别处理各组，跨组件记忆模块（Cross-Component Memory，CCM）随后通过共享记忆交换上下文：

$$\mathbf{M}' = \mathbf{M} + \mathrm{Attn}_r(\mathbf{M}, \widetilde{\mathbf{X}}, \widetilde{\mathbf{X}}), \tag{6}$$

$$\mathbf{U} = \widetilde{\mathbf{X}} + \mathrm{Attn}_w(\mathrm{LN}(\widetilde{\mathbf{X}}), \mathbf{M}', \mathbf{M}'). \tag{7}$$

其中，$\widetilde{\mathbf{X}}$ 拼接局部更新后的 token，注意力的三个参数依次为查询、键和值。$\mathbf{U}$ 后接残差前馈更新。流时间调制进入局部归一化，记忆由可学习 token 和日志摘要初始化。这一结构保留各类支撑的局部组织，同时使刚体或人体查询能够使用周围场景的信息。

流训练与约束采样。 令 $\mathbf{z}_1$ 为同一查询布局上的完整目标，$\boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I})$ 为高斯噪声。在流时间 $\tau \in [0, 1]$，我们仅对未知内容插值：

$$\mathbf{z}_\tau = m \odot \mathbf{z}^{\text{obs}} + u \odot [(1 - \tau)\boldsymbol{\epsilon} + \tau \mathbf{z}_1]. \tag{8}$$

已见潜码固定，自由空间潜码保持为零。未知查询的目标速度为 $\mathbf{z}_1 - \boldsymbol{\epsilon}$。引入可选损失选择器 s_i，目标为

$$\mathcal{L}_{\text{flow}} = \frac{\sum_i u_i s_i \|\mathbf{v}_\theta(\mathbf{z}_\tau, \tau, C)_i - (\mathbf{z}_{1,i} - \boldsymbol{\epsilon}_i)\|_2^2}{D \max(1, \sum_i u_i s_i)}. \tag{9}$$

完整场景或资产样本为未知查询提供目标潜码 $\mathbf{z}_1$，s_i 则选择其对训练损失的贡献（第 3.8 节）。

推理时，以噪声初始化未知潜码，并执行 S 次 Euler 步，步长为 $\Delta\tau = 1/S$：

$$\mathbf{z}^{j+1} = \Pi_{m,f}\left[\mathbf{z}^j + \Delta\tau\, u \odot \mathbf{v}_\theta(\mathbf{z}^j, j/S, C)\right]. \tag{10}$$

投影 $\Pi_{m,f}$ 在每步后恢复已见潜码，并清零自由空间潜码。种子确定一次采样补全。采样完成后再解码；相机或资产状态改变时复用得到的场景。

3.6. 分类型高斯解码

背景、刚体和人体高斯解码器分别将每个查询独立映射为限制在其支撑单元内的 K 个子高斯。人体子高斯继承查询的蒙皮权重；刚体子高斯共用所属资产的刚体变换。不透明度乘以 $1 - f_i$，使自由空间查询不能产生可见高斯。独立天空头在观测支持的方向域 V_{sky} 内

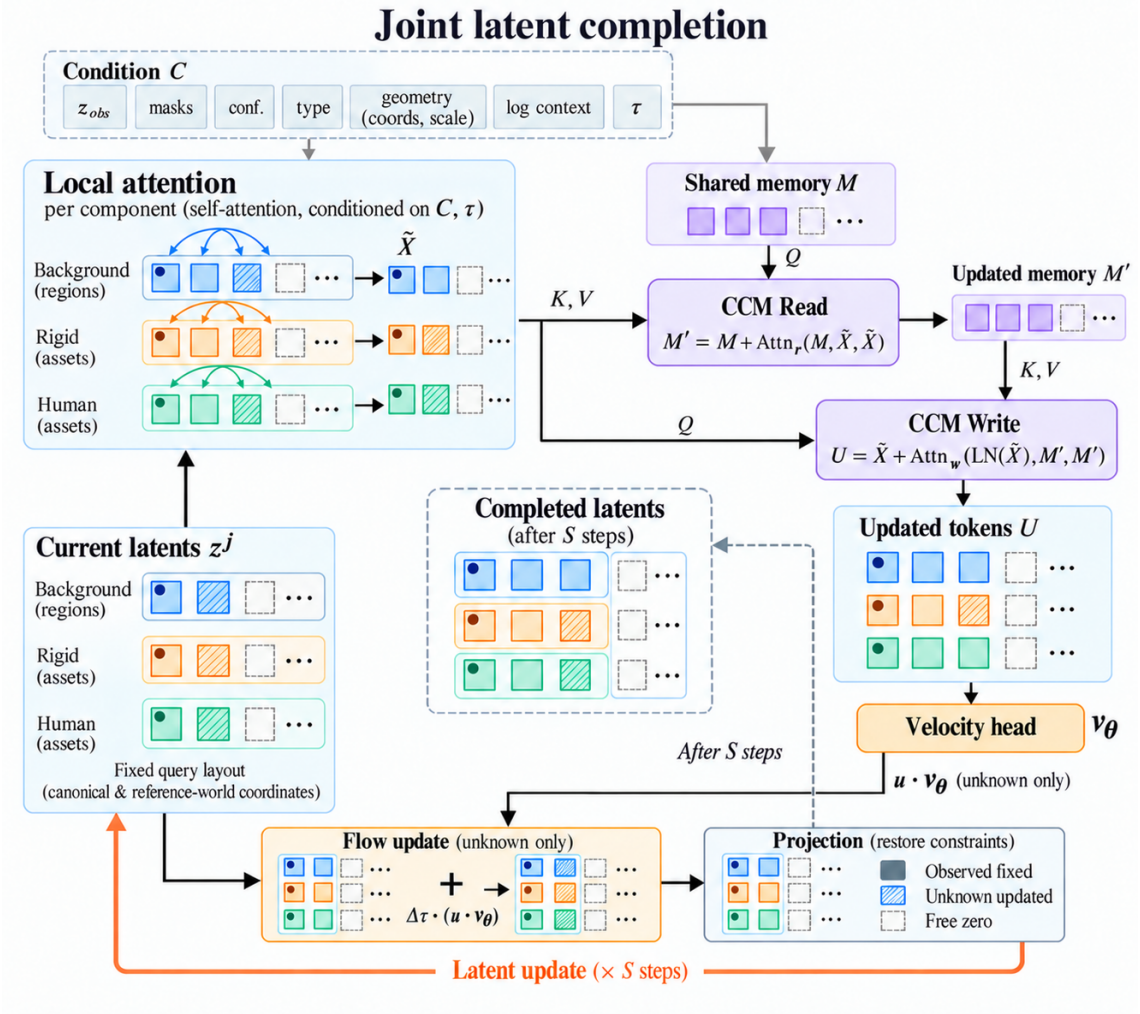

Figure 4. **联合潜空间补全**。组内局部注意力更新组件特征；CCM 将其读入共享记忆，再把上下文写回各组件。速度头驱动未知潜码更新，每步更新后通过投影恢复已见潜码并清零自由空间潜码，查询布局始终固定。最终补全潜码从最后一次投影后取得。

预测立方体贴图颜色。高斯与外观参数化详见补充材料附录 E。

各查询独立解码。冻结编解码器并保留已见潜码，使已观测表面的高斯参数保持不变。

3.7. 场景组合

状态驱动渲染。 时刻 k 的状态 s_k 指定自车位姿、活动资产、刚体变换，以及人体根位姿与关节姿态。刚体位姿对规范高斯的中心和协方差施加刚体变换，人体关节姿态通过存储的蒙皮权重使高斯变形，补全表面因此随相应身体部位运动。具体变换见补充材料附录 C。渲染器合成背景、活动资产和有效天空：

$$o_k = \mathcal{R}(\mathrm{Compose}(\mathcal{W}, s_k), \mathcal{C}_k). \tag{11}$$

改变相机得到组合场景的新视角，改变参与者状态则移动其已补全的规范资产。背景与规范内容在这些操作中保持固定，使同一重建结果可以沿不同轨迹复用。

Table 1. 训练阶段。R：恢复模块；C：编解码器；G：GCM。T：训练；F：冻结；–：未使用。

阶段	R	C	G	监督
视觉恢复	T	–	–	几何、语义、身份、状态
表示拟合	F	T	–	部分与完整观测
补全先验	F	F	T	完整目标
渲染适配	F	F	T	真实日志渲染与场景约束

3.8. 训练流程

我们依次训练视觉恢复模块、潜表示编解码器和补全模型，再通过渲染观测适配补全模型（表 1）。补全训练期间冻结编解码器，使目标潜空间保持固定。

编解码器拟合时，部分输入与更完整观测共享相同的查询位置、类型、顺序和归属。随后冻结恢复模块与整个编解码器，使用为每个未知查询提供有效目标的完整场景或资产样本，以式 9 训练 GCM。真实日志适配通过流积分、解码和渲染反向传播，仅更新 GCM。完整目标样本可交替使用以保留先验，各损失项仅作用于具备所需目标的样本。已见锚点由冻结解码和潜码硬恢复维持。详细监督、损失和条件扰动见补充材料附录 B。

4. 实验

我们从三个方面评价方法：(*i*) Waymo Open Dataset 上的动态场景重建质量（第 4.2 节）；(*ii*) 横向相机偏移下的轨迹外视图合成（第 4.3 节）；(*iii*) 主要设计的消融分析（第 4.4 节）。跨数据集泛化结果见补充材料。

4.1. 实验设置

数据集与协议。 我们使用 Waymo Open Dataset 的 798 条训练序列和 202 条验证序列。遵循 STORM，将每条验证序列划分为不重叠的 2 秒片段，每段包含以 10 Hz 采样的 20 帧 [45]。FRONT、FRONT_LEFT 和 FRONT_RIGHT 相机在从零计数的帧索引 $\{0, 5, 10, 15\}$ 提供观测，其余 16 帧用于评价，其中 12 帧对应时间插值，4 帧位于最后一次观测之后。评价时将预测与参考图像缩放至 240×160 像素 [14]。

基线。 我们比较 STORM、DGGT 和 StreetForward [3, 45, 48]。各方法使用相同输入时刻和目标视图，并采用各自的预处理。相机参数、额外几何输入与渲染适配器随实现设置记录。空间外推遵循 PointForward，比较扩散细化前的高斯渲染 [6]。

指标。 我们在完整图像与共享标注区域上报告 PSNR 和 SSIM。深度评价在有效 LiDAR 投影点上计算逐帧尺度对齐后的 AbsRel 和 δ_1 [14]。分数先在片段内按帧平均，再在序列内按片段平均，最后对各序列等权汇总。新轨迹渲染使用固定真实图像与视频参考集合计算 FID 和 FVD。

实现细节。 DriveCompose 从运动对齐的观测中重建各类型参与者资产，并与静态背景组合。重建耗时包括预处理、资产生成和场景组合；渲染耗时单独测量，资产复用通过重复场景查询评价。

4.2. 动态场景重建

我们在记录相机轨迹上的未观测时刻评价重建。表 2 报告完整图像、动态区域及深度质量，图 5 比较五个样例的渲染外观。

定量比较。 DriveCompose 在表 2 的六项指标上均取得最优结果。完整图像和动态区域 PSNR 分别比各自最强基线高 1.154 和 2.340 dB，对应 SSIM 达到 0.901 和 0.862；深度 AbsRel 降至 0.095，δ_1 达到 0.877。

定性比较。 图 5 中，DriveCompose 保留了第一行的行人轮廓和第二行中央车辆的尾部外形，同时恢复周围街道布局。基线渲染在上方样例中出现参与者轮廓偏移或重复，在下方样例中出现道路结构模糊或畸变。DriveCompose 更准确地恢复了这些参考结构。残余伪影集中在第三行行人周围及最后一行停放的皮卡附近。

Table 2. Waymo 动态场景重建。图像质量在完整图像和标注区域上统计，深度在有效 LiDAR 投影点上评价。

	完整图像		动态区域		深度	
方法	PSNR ↑	SSIM ↑	PSNR ↑	SSIM ↑	AbsRel ↓	δ_1 ↑
STORM	26.380	0.826	22.100	0.624	0.178	0.741
DGGT	27.410	0.794	22.710	0.651	0.249	0.668
StreetForward	27.010	0.818	20.919	0.592	0.197	0.759
Ours	**28.564**	**0.901**	**25.050**	**0.862**	**0.095**	**0.877**

4.3. 轨迹外视图合成

我们在相机横向偏移 ±1、±2 和 ±4 米时评价轨迹外渲染，并保持相机朝向、内参和时间戳固定 [6, 51]。

表 3 报告各偏移幅度下分别评价左移和右移后平均的 FID 与 FVD，各方法使用相同的真实参考集合。图 6 展示 Waymo 数据集上相机向左偏移 2 m 的三组场景，比较车辆外形、道路布局与遮挡边界。

4.4. 消融分析

实验协议。 两组消融均在 Waymo 的留出目标图像上评价，共用含 29 个时间戳的窗口。每个窗口使用前向、左前和右前三路同步相机。嵌套输入为 $\mathcal{T}_2 = \{0, 28\}$、$\mathcal{T}_4 = \{0, 8, 20, 28\}$ 和 $\mathcal{T}_8 = \{0, 4, \ldots, 28\}$，共同目标时刻为 $\{2, 6, \ldots, 26\}$。目标图像不参与证据与查询构造；所有变体获得相同的目标相机与资产状态。恢复模块和编解码器冻结，在每档输入下对齐查询布局、数据曝光和优化预算。训练时等概率采样 $T \in \{2, 4, 8\}$，补全采用 24 步 Euler 积分。两个可训练版本使用训练种子 $\{0, 1, 2\}$ 和世界种子 $\{7, 17, 27\}$；w/o GCM 为确定性版本。超参数在内部开发集选定，再评价与训练场景及身份隔离的数据。

指标。 我们在完整留出目标图像上报告 PSNR、SSIM 和 LPIPS，并在组件消融中额外报告动态区域的 PSNR 和 SSIM。所有变体采用与主重建实验相同的图像预处理、评价分辨率和基于标注的动态区域掩码。指标在任何输出筛选前的全部可渲染场景上计算，不可渲染场景单独计数。分数先在窗口内按帧平均，再在序列内按窗口平均，最后对各序列及训练种子等权汇总。

Figure 5. **动态场景重建的定性对比**。每行展示一个样例，从左至右依次为真实图像、DGGT、STORM、StreetForward 和 DriveCompose（Ours）。样例覆盖行人、交通车辆与城市背景，用于比较参与者轮廓、车辆边界以及道路和建筑结构。

Table 3. 横向相机偏移下的新视角合成。FID 与 FVD 为各偏移幅度下左移和右移结果的平均，数值越低越好。

方法	偏移 ±1 m		偏移 ±2 m		偏移 ±4 m	
	FID ↓	FVD ↓	FID ↓	FVD ↓	FID ↓	FVD ↓
STORM	61.97	722.27	83.72	1029.36	132.57	1704.16
DGGT	73.99	984.00	93.36	1197.03	128.01	1661.70
StreetForward	84.30	878.95	103.31	1095.02	123.58	1578.63
Ours	**28.52**	**544.27**	**37.43**	**673.17**	**58.19**	**817.13**

Table 4. **组件消融**。所有版本采用 $T = 8$（24 张图像）、相同的恢复模块与编解码器，以及统一的目标视图和动态区域掩码。全图采用 PSNR、SSIM 和 LPIPS，动态区域采用 PSNR 和 SSIM。

变体	全图			动态区域	
	PSNR ↑	SSIM ↑	LPIPS ↓	PSNR ↑	SSIM ↑
w/o GCM	27.137	0.867	0.183	23.431	0.811
w/o CCM	28.286	0.893	0.147	24.683	0.849
Ours	**28.913**	**0.911**	**0.129**	**25.617**	**0.873**

补全与场景上下文。 表 4 将完整版本 Ours 与两个对照比较。w/o GCM 跳过生成式补全模块，并关闭所有非已见、非天空查询的不透明度。w/o CCM 在每一层将跨组件记忆模块替换为各组件独立的记忆，同时共享参数并保留相同的全局日志条件。可训练对照重新执行阶段三、四，记忆机制引起的计算差异单独记录。Ours 在全部五项指标上取得最优结果。相比 w/o GCM，全图和动态区域 PSNR 分别提高 1.776 和 2.186 dB。相比 w/o CCM，对应增益分别为 0.627 和 0.934 dB，全图 LPIPS 从 0.147 降至 0.129。

输入稀疏度。 表 5 复用 Ours 和 w/o CCM 的权重，在 $T = 2, 4, 8$ 下分别输入 6/12/24 张图像。时间跨度和目标视图固定，证据与查询由各档输入重新构建。这项比较不重新训练模型。随着 T 增大，两个版本的三项指标

Figure 6. **Waymo 数据集上相机向左偏移 2 m 的定性视图外推结果**。每行展示一个场景，各列从左至右依次为参考图像（GT）、STORM、DGGT、StreetForward 和 DriveCompose（Ours）。

Table 5. **输入时刻数量敏感性**。每档 T 比较 w/o CCM 与完整模型，权重、时间跨度和目标视图固定。所有指标均在完整图像上计算。$T = 8$ 的设置与表 4 相同。

T	变体	PSNR ↑	SSIM ↑	LPIPS ↓
2	w/o CCM	25.237	0.817	0.254
	Ours	**26.341**	**0.851**	**0.213**
4	w/o CCM	27.126	0.869	0.187
	Ours	**27.864**	**0.891**	**0.159**
8	w/o CCM	28.286	0.893	0.147
	Ours	**28.913**	**0.911**	**0.129**

均得到改善。Ours 在每档输入设置下均优于 w/o CCM，在 $T = 2, 4, 8$ 时的 PSNR 增益分别为 1.104、0.738 和 0.627 dB。LPIPS 降幅也随输入变稀疏而增大，从 $T = 8$ 时的 0.018 增至 $T = 2$ 时的 0.041。

4.5. 状态驱动复用

以时刻 14、世界种子 7 为参照，各干预分别沿相机局部 $+x$ 轴平移 1 m、绕车辆根位置及世界竖直轴转动 30°，或在根位置固定时施加留出的有效人体姿态 H_1。光照与规范资产保持固定，状态变化不重新采样补全内容。

5. 讨论

DriveCompose 将规范场景内容与相机、参与者状态分开表示。当前表示覆盖固定照明下的有限区域，车辆采用刚体模型，人体绑定固定骨架和衣物体积。深度、身份与规范姿态估计决定补全使用的已见锚点，因此恢复误差会传递到重建几何。人体关节运动遵循模板的几何支撑，接触与碰撞行为由物理仿真器处理。重光照与衣物几何变化需要相应的外观和形变模型。

6. 结论

本文提出 DriveCompose，通过规范特征聚合、潜表示编码与联合补全重建可组合驾驶场景。局部注意力和跨组件记忆结合组件结构与场景上下文，分类型高斯解码保留身份与运动绑定，使补全资产能够在不同相机和参与者状态下组合。在 Waymo 上，DriveCompose 改善了动态重建与轨迹外视图合成。

References

[1] Holger Caesar, Varun Bankiti, Alex H. Lang, Sourabh Vora, Venice Erin Liong, Qiang Xu, Anush Krishnan, Yu Pan, Giancarlo Baldan, and Oscar Beijbom. nuScenes: A Multimodal Dataset for Autonomous Driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 11621–11631, 2020. 1

[2] David Charatan, Sizhe Lester Li, Andrea Tagliasacchi, and Vincent Sitzmann. pixelSplat: 3D Gaussian Splats from Image Pairs for Scalable Generalizable 3D Reconstruction. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 19457–19467, 2024. 2

[3] Xiaoxue Chen, Ziyi Xiong, Yuantao Chen, Gen Li, Nan Wang, Hongcheng Luo, Long Chen, Haiyang Sun, Bing Wang, Guang Chen, Hongyang Li, Ya-Qin Zhang, Hangjun Ye, and Hao Zhao. DGGT: Feedforward 4D Reconstruction of Dynamic Driving Scenes using Unposed Images. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 1265–1276, 2026. 1, 2, 6

[4] Yuedong Chen, Haofei Xu, Chuanxia Zheng, Bohan Zhuang, Marc Pollefeys, Andreas Geiger, Tat-Jen Cham, and Jianfei Cai. MVSplat: Efficient 3D Gaussian Splatting from Sparse Multi-View Images. In *European Conference on Computer Vision (ECCV)*, 2024. 2

[5] Ziyu Chen, Jiawei Yang, Jiahui Huang, Riccardo de Lutio, Janick Martinez Esturo, Boris Ivanovic, Or Litany, Zan Gojcic, Sanja Fidler, Marco Pavone, Li Song, and Yue Wang. OmniRe: Omni Urban Scene Reconstruction. In *International Conference on Learning Representations*, pages 85508–85527, 2025. 1, 2

[6] Cheng Chi, Xianqi Wang, Hongcheng Luo, Mingfei Tu, Gangwei Xu, Zehan Zhang, Bing Wang, Guang Chen, Hangjun Ye, Sida Peng, Xin Yang, and Haiyang Sun. PointForward: Feedforward Driving Reconstruction through Point-Aligned Representations. *arXiv preprint arXiv:2605.11594*, 2026. 1, 2, 6

[7] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. In *International Conference on Learning Representations (ICLR)*, 2021. 3

[8] Ruiyuan Gao, Kai Chen, Enze Xie, Lanqing HONG, Zhenguo Li, Dit-Yan Yeung, and Qiang Xu. MagicDrive: Street View Generation with Diverse 3D Geometry Control. In *International Conference on Learning Representations*, pages 22841–22860, 2024. 3

[9] Ruiqi Gao, Aleksander Hołyński, Philipp Henzler, Arthur Brussee, Ricardo Martin-Brualla, Pratul Srinivasan, Jonathan T. Barron, and Ben Poole. CAT3D: Create Anything in 3D with Multi-View Diffusion Models. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 75468–75494, 2024. 2

[10] Shenyuan Gao, Jiazhi Yang, Li Chen, Kashyap Chitta, Yihang Qiu, Andreas Geiger, Jun Zhang, and Hongyang Li. Vista: A Generalizable Driving World Model with High Fidelity and Versatile Controllability. In *Advances in Neural Information Processing Systems*, pages 91560–91596, 2024. 3

[11] Georg Hess, Carl Lindström, Maryam Fatemi, Christoffer Petersson, and Lennart Svensson. SplatAD: Real-Time Lidar and Camera Rendering with 3D Gaussian Splatting for Autonomous Driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 11982–11992, 2025. 2

[12] Yicong Hong, Kai Zhang, Jiuxiang Gu, Sai Bi, Yang Zhou, Difan Liu, Feng Liu, Kalyan Sunkavalli, Trung Bui, and Hao Tan. LRM: Large Reconstruction Model for Single Image to 3D. In *International Conference on Learning Representations*, pages 50678–50702, 2024. 2

[13] Shoukang Hu, Tao Hu, and Ziwei Liu. GauHuman: Articulated Gaussian Splatting from Monocular Human Videos. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 20418–20431, 2024. 2

[14] Jiahui Huang, Jiawei Ren, Michal Tyszkiewicz, Bjoern Haefner, Michael Shelley, Xin Kang, Seung Wook Kim, Ning Xu, Qi Wu, Janick Martinez Esturo, Shengyu Huang, Nick Schneider, Laura Leal-Taixé, Zan Gojcic, and Sanja Fidler. Instant NuRec: Feed-Forward 3D Gaussian Reconstruction for Driving Scene Simulation. *arXiv preprint arXiv:2607.14203*, 2026. 2, 6

[15] Bernhard Kerbl, Georgios Kopanas, Thomas Leimkühler, and George Drettakis. 3D Gaussian Splatting for Real-Time Radiance Field Rendering. *ACM Transactions on Graphics*, 42(4), 2023. 2, 3

[16] Muhammed Kocabas, Jen-Hao Rick Chang, James Gabriel, Oncel Tuzel, and Anurag Ranjan. HUGS: Human Gaussian Splats. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 505–515, 2024. 2

[17] Ziwei Liao, Mohamed Sayed, Steven L. Waslander, Sara Vicente, Daniyar Turmukhambetov, and Michael Firman. Complete Gaussian Splats from a Single Image with Denoising Diffusion Models. *arXiv preprint arXiv:2508.21542*, 2025. 1, 2

[18] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow Matching for Generative Modeling. In *International Conference on Learning Representations*, 2023. 2, 4

[19] Ruoshi Liu, Rundi Wu, Basile Van Hoorick, Pavel Tokmakov, Sergey Zakharov, and Carl Vondrick. Zero-1-to-3: Zero-shot One Image to 3D Object. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 9298–9309, 2023. 2

[20] Matthew Loper, Naureen Mahmood, Javier Romero, Gerard Pons-Moll, and Michael J. Black. SMPL: A Skinned Multi-Person Linear Model. *ACM Trans. Graphics (Proc. SIGGRAPH Asia)*, 34(6):248:1–248:16, 2015. 2

[21] Yichong Lu, Yichi Cai, Shangzhan Zhang, Hongyu Zhou, Haoji Hu, Huimin Yu, Andreas Geiger, and Yiyi Liao. UrbanCAD: Towards Highly Controllable and Photorealistic 3D Vehicles for Urban Scene Simulation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 27519–27530, 2025. 2

[22] Ben Mildenhall, Pratul P. Srinivasan, Matthew Tancik, Jonathan T. Barron, Ravi Ramamoorthi, and Ren Ng. NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis. In *European Conference on Computer Vision (ECCV)*, 2020. 2

[23] Julian Ost, Fahim Mannan, Nils Thuerey, Julian Knodt, and Felix Heide. Neural Scene Graphs for Dynamic Scenes. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2856–2865, 2021. 2

[24] Jinhyung Park, Navyata Sanghvi, Erica Weng, Shawn Hunt, Shinya Tanaka, Hironobu Fujiyoshi, and Kris Kitani. Grounded Latents for Entity-Centric 4D Scene Generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 21420–21430, 2026. 3

[25] Georgios Pavlakos, Vasileios Choutas, Nima Ghorbani, Timo Bolkart, Ahmed A. A. Osman, Dimitrios Tzionas, and Michael J. Black. Expressive Body Capture: 3D Hands, Face, and Body From a Single Image. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 10975–10985, 2019. 2

[26] William Peebles and Saining Xie. Scalable Diffusion Models with Transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 4195–4205, 2023. 4

[27] Zhiyin Qian, Shaofei Wang, Marko Mihajlovic, Andreas Geiger, and Siyu Tang. 3DGS-Avatar: Animatable Avatars via Deformable 3D Gaussian Splatting. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 5020–5030, 2024. 2

[28] Lingteng Qiu, Xiaodong Gu, Peihao Li, Qi Zuo, Weichao Shen, Junfei Zhang, Kejie Qiu, Weihao Yuan, Guanying Chen, Zilong Dong, and Liefeng Bo. LHM: Large Animatable Human Reconstruction Model for Single Image to 3D in Seconds. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 14184–14194, 2025. 2

[29] Jiawei Ren, Michal Jan Tyszkiewicz, Jiahui Huang, and Zan Gojcic. TokenGS: Decoupling 3D Gaussian Prediction from Pixels with Learnable Tokens. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 15365–15375, 2026. 2

[30] Yichun Shi, Peng Wang, Jianglong Ye, Long Mai, Kejie Li, and Xiao Yang. MVDream: Multi-view Diffusion for 3D Generation. In *International Conference on Learning Representations*, pages 39838–39859, 2024. 2

[31] Pei Sun, Henrik Kretzschmar, Xerxes Dotiwalla, Aurelien Chouard, Vijaysai Patnaik, Paul Tsui, James Guo, Yin Zhou, Yuning Chai, Benjamin Caine, Vijay Vasudevan, Wei Han, Jiquan Ngiam, Hang Zhao, Aleksei Timofeev, Scott Ettinger, Maxim Krivokon, Amy Gao, Aditya Joshi, Sheng Zhao, Shuyang Cheng, Yu Zhang, Jonathon Shlens, Zhifeng Chen, and Dragomir Anguelov. Scalability in Perception for Autonomous Driving: Waymo Open Dataset. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2446–2454, 2020. 1

[32] Qijian Tian, Xin Tan, Yuan Xie, and Lizhuang Ma. DrivingForward: Feed-forward 3D Gaussian Splatting for Driving Scene Reconstruction from Flexible Surround-view Input. In *Proceedings of the AAAI Conference on Artificial Intelligence*, pages 7374–7382, 2025. 2

[33] Adam Tonderski, Carl Lindström, Georg Hess, William Ljungbergh, Lennart Svensson, and Christoffer Petersson. NeuRAD: Neural Rendering for Autonomous Driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14895–14904, 2024. 2

[34] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Ł ukasz Kaiser, and Illia Polosukhin. Attention is All you Need. In *Advances in Neural Information Processing Systems*, 2017. 3

[35] Jianyuan Wang, Minghao Chen, Nikita Karaev, Andrea Vedaldi, Christian Rupprecht, and David Novotny. VGGT: Visual Geometry Grounded Transformer. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 5294–5306, 2025. 2

[36] Shuzhe Wang, Vincent Leroy, Yohann Cabon, Boris Chidlovskii, and Jerome Revaud. DUSt3R: Geometric 3D Vision Made Easy. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 20697–20709, 2024. 2

[37] Xiaofeng Wang, Zheng Zhu, Guan Huang, Xinze Chen, Jiagang Zhu, and Jiwen Lu. DriveDreamer: Towards Real-world-driven World Models for Autonomous Driving. In *European Conference on Computer Vision (ECCV)*, 2024. 3

[38] Yifan Wang, Francesco Pittaluga, Zaid Tasneem, Chenyu You, Manmohan Chandraker, and Ziyu Jiang. HorizonForge: Driving Scene Editing with Any Trajectories and Any Vehicles. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026. 3

[39] Jay Zhangjie Wu, Yuxuan Zhang, Haithem Turki, Xuanchi Ren, Jun Gao, Mike Zheng Shou, Sanja Fidler, Zan Gojcic, and Huan Ling. DIFIX3D+: Improving 3D Reconstructions with Single-Step Diffusion Models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 26024–26035, 2025. 3

[40] Qirui Wu, Yawar Siddiqui, Duncan Frost, Samir Aroudj, Armen Avetisyan, Richard Newcombe, Angel X. Chang, Jakob Engel, and Henry Howard-Jenkins. JRM: Joint Reconstruction Model for Multiple Objects without Alignment. *arXiv preprint arXiv:2603.25985*, 2026. 2

[41] Jianfeng Xiang, Zelong Lv, Sicheng Xu, Yu Deng, Ruicheng Wang, Bowen Zhang, Dong Chen, Xin Tong, and Jiaolong Yang. Structured 3D Latents for Scalable and Versatile 3D Generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 21469–21480, 2025. 2

[42] Jianfeng Xiang, Xiaoxue Chen, Sicheng Xu, Ruicheng Wang, Zelong Lv, Yu Deng, Hongyuan Zhu, Yue Dong, Hao Zhao, Nicholas Jing Yuan, and Jiaolong Yang. Native and Compact Structured Latents for 3D Generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14419–14429, 2026. 2

[43] Yunzhi Yan, Haotong Lin, Chenxu Zhou, Weijie Wang, Haiyang Sun, Kun Zhan, Xianpeng Lang, Xiaowei Zhou, and Sida Peng. Street Gaussians: Modeling Dynamic Urban Scenes with Gaussian Splatting. In *European Conference on Computer Vision (ECCV)*, 2024. 1, 2

[44] Yunzhi Yan, Zhen Xu, Haotong Lin, Haian Jin, Haoyu Guo, Yida Wang, Kun Zhan, Xianpeng Lang, Hujun Bao, Xiaowei Zhou, and Sida Peng. StreetCrafter: Street View Synthesis with Controllable Video Diffusion Models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 822–832, 2025. 1, 3

[45] Jiawei Yang, Jiahui Huang, Boris Ivanovic, Yuxiao Chen, Yan Wang, Boyi Li, Yurong You, Apoorva Sharma, Maximilian Igl, Peter Karkus, Danfei Xu, Yue Wang, and Marco Pavone. STORM: Spatio-TempOral Reconstruction Model For Large-Scale Outdoor Scenes. In *International Conference on Learning Representations*, pages 50446–50465, 2025. 1, 2, 6

[46] Ze Yang, Yun Chen, Jingkang Wang, Sivabalan Manivasagam, Wei-Chiu Ma, Anqi Joyce Yang, and Raquel Urtasun. UniSim: A Neural Closed-Loop Sensor Simulator. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 1389–1399, 2023. 1, 2

[47] Ze Yang, Jingkang Wang, Haowei Zhang, Sivabalan Manivasagam, Yun Chen, and Raquel Urtasun. GenAssets: Generating in-the-wild 3D Assets in Latent Space. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 22392–22403, 2025. 1, 2

[48] Zhongrui Yu, Zhao Wang, Yijia Xie, Yida Wang, Xueyang Zhang, Yifei Zhan, and Kun Zhan. StreetForward: Perceiving Dynamic Street with Feedforward Causal Attention. *arXiv preprint arXiv:2603.19552*, 2026. 1, 2, 6

[49] Hongyu Zhou, Longzhong Lin, Jiabao Wang, Yichong Lu, Dongfeng Bai, Bingbing Liu, Yue Wang, Andreas Geiger, and Yiyi Liao. HUGSIM: A Real-Time, Photo-Realistic and Closed-Loop Simulator for Autonomous Driving. *arXiv preprint arXiv:2412.01718*, 2024. 1, 2

[50] Xiaoyu Zhou, Zhiwei Lin, Xiaojun Shan, Yongtao Wang, Deqing Sun, and Ming-Hsuan Yang. DrivingGaussian: Composite Gaussian Splatting for Surrounding Dynamic Autonomous Driving Scenes. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 21634–21643, 2024. 2

[51] Ziyue Zhu, Zhanqian Wu, Zhenxin Zhu, Lijun Zhou, Haiyang Sun, Bing Wan, Kun Ma, Guang Chen, Hangjun Ye, Jin Xie, and Jian Yang. WorldSplat: Gaussian-Centric Feed-Forward 4D Scene Generation for Autonomous Driving. *arXiv preprint arXiv:2509.23402*, 2025. 1, 3, 6

[52] Yiyu Zhuang, Jiaxi Lv, Hao Wen, Qing Shuai, Ailing Zeng, Hao Zhu, Shifeng Chen, Yujiu Yang, Xun Cao, and Wei Liu. IDOL: Instant Photorealistic 3D Human Creation from a Single Image. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 26308–26319, 2025. 2