DriveCompose：面向可组合高斯驾驶世界的观测锚定联合补全

Anonymous CVPR submission

Paper ID *****

Abstract

驾驶日志只覆盖场景的一部分，仿真中的新相机位姿和资产状态却会暴露未见表面。补全这些表面时，需要协调世界空间中的背景、规范空间中的车辆与关节人体，并保持日志记录的外观。我们提出 *DriveCompose*，通过联合补全分类规范查询，构建可组合的高斯驾驶世界。共享恢复前端提供几何、身份和状态证据；局部查询组保留各类内容的空间结构，全局记忆在背景与资产之间交换上下文。条件流填充未知潜码，每步恢复已见潜码，并抑制已知自由空间。固定的逐查询解码器保持已见高斯参数，独立的渲染检查则识别新增内容造成的退化。候选通过检查后，背景与规范资产保持固定，由相机位姿、刚体变换和骨架姿态驱动不同轨迹的渲染，各条轨迹共享同一次补全结果。该方法将生成过程放在离线世界构建阶段，并通过状态驱动装配明确表达后续场景变化。

1. 引言

驾驶日志记录的是一条轨迹上可见的表面。移动仿真相机，可能看到车辆后方被遮挡的道路；转动车辆，会露出未见的侧面；改变行人姿态，也会使不同部位进入视野。用于这些干预的三维世界既要解释已记录的图像，也要为图像未覆盖的表面提供内容。状态变化后，补全内容仍须属于同一个场景和资产身份。

结构化高斯表示为这一任务提供了基础。Street Gaussians 将跟踪车辆与背景分开建模，OmniRe 将规范表示扩展到关节人体等多类参与者 [2, 10]。HUGSIM 把重建场景接入控制驱动的状态更新 [15]。这些表示区分持久内容与运动：车辆具有一份局部形状，人体具有一份规范表面及骨架绑定。补全也需要遵循这种区分。为某个视角或姿态生成的几何，应在可复用世界中具有明确的位置和归属。

生成方法从不同层面处理缺失观测。StreetCrafter 和 HorizonForge 将三维条件与视频扩散结合，WorldSplat 生成高斯后进一步精修渲染视频 [8, 11, 16]。GenAssets 学习驾驶资产的生成潜空间，CompleteSplat 根据部分图像证据补全高斯场景 [5, 13]。驾驶世界将这些补全问题汇集在一起：背景位于世界坐标中，车辆位于刚体局部坐标中，人体表面依附规范模板。各部分独立补全后，道路、邻近资产与资产放置之间的协调仍需在生成之外完成。

我们的出发点是，一个查询需要两种空间描述。规范坐标标识持续存在的内容，参考世界坐标描述它与周围场景的空间关系。DriveCompose 同时保留两种描述，让异构查询组在补全时交换信息（图 1）。可靠观测形成固定潜码锚点，射线证据标记自由空间，预留支撑承载未见内容。类型专属 codec 将这些支撑映射到统一宽度的潜空间。局部注意力遵循各类支撑的结构，全局记忆在不同组之间传递场景上下文。

联合生成还通过图像形成过程将组件联系起来。未知表面属于某个资产，却可能影响另一个组件已经解释的像素。例如，补全的车辆侧面可能穿过一条射线，而该射线的背景已由日志观测支撑。因此，即使锚点与 codec 都逐查询定义，观测保持仍是场景层面的性质。锁定已见高斯参数不会关闭这条遮挡路径，对这些参数施加惩罚也无法度量新增内容的影响。我们据此分别处理参数保持与渲染一致性。条件流只更新未知潜码，在每步恢复已见潜码、清零自由空间潜码；固定的逐查询解码器把这些约束传递到高斯参数。随后，从原始相机渲染候选内容，并同时与输入图像、仅观测参照比较。检查覆盖局部图像退化、前景侵入、绝对误差和视图覆盖率，候选通过后才进入固定世界。

接受检查划分了构建与使用两个阶段。世界保存一份固定背景，以及每个身份对应的一份规范资产。运行时，当前状态放置相机、对车辆施加刚体变换，并通过固定骨架绑定驱动人体。几何、协方差和观察方向采用一致的变换规则。外部策略与动力学更新状态；重置或分支轨迹时，仍复用同一世界和补全种子。这样，补全的三维内容、当前资产配置以及状态变化的来源具有明确分工。

本文的贡献包括：

- 在背景与分类规范资产上建立联合补全形式，用规范坐标描述持久内容，用参考世界坐标提供场景上下文。
- 将潜码硬约束、自由空间抑制与候选–参照渲染检查结合，形成观测锚定的世界构建过程。
- 建立固定高斯世界表示，按一致规则变换几何、协方差和方向外观，支持不同轨迹中的状态驱动装配。

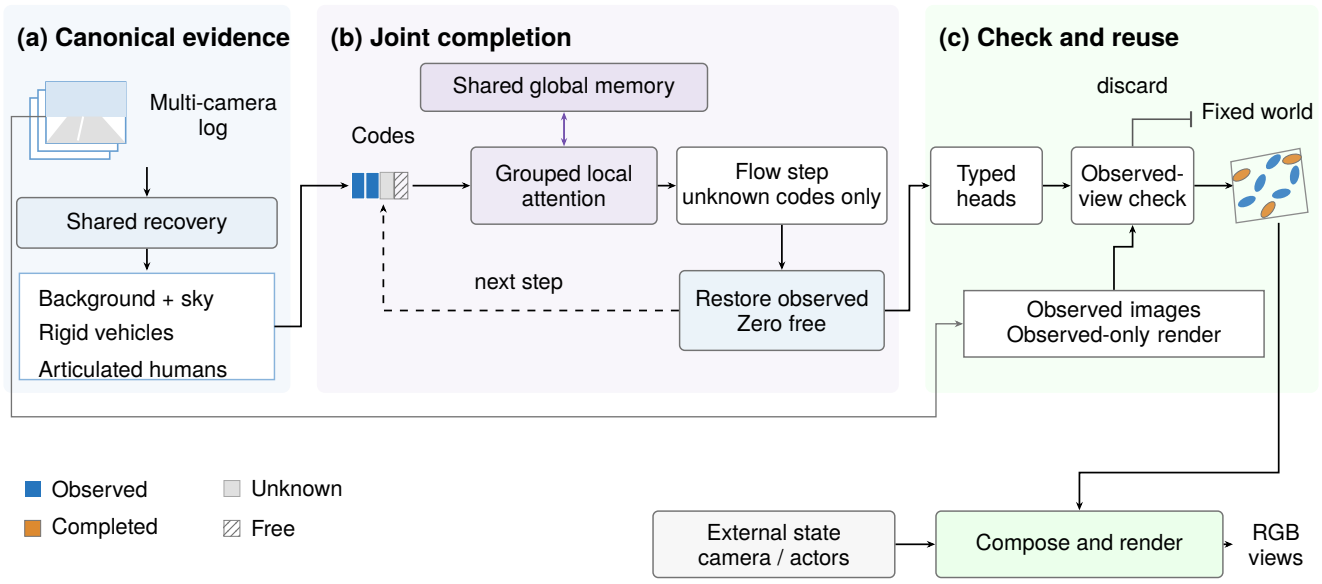


Figure 1. **DriveCompose 的构建与复用**。(a) 共享前端在世界空间与规范支撑上恢复证据。(b) 局部查询组通过全局记忆交换上下文，每个流积分步恢复已见潜码并清零自由空间。(c) 类型专属头解码补全潜码，原视角检查将候选与输入图像、仅观测解码参照比较；被拒绝的候选不进入固定世界。外部策略与动力学提供后续装配和 RGB 渲染所用的状态。图中场景标记均为机制示意。

2. 相关工作

可组合重建与仿真。 Street Gaussians 将背景与跟踪车辆表示为独立的高斯组件 [10]。OmniRe 采用类别相关的规范表示，同时容纳刚体与关节资产 [2]。HUGSIM 将重建内容与交互式状态更新、仿真后端结合 [15]。这些工作建立了内容与状态分离及各类资产运动建模的基础。DriveCompose 沿用这一分离方式来定义补全的输出：一份固定背景，以及跨轨迹保持身份、局部几何和绑定的规范资产。补全变量共同覆盖这些组件，使各组件的未见表面在生成过程中相互关联。

驾驶场景前馈重建。 STORM、DGGT、StreetForward 和 PointForward 从时序观测恢复驾驶场景表示 [1, 3, 12, 14]。我们用时序恢复建立补全所需的条件证据：前端预测几何、身份和状态，固定查询布局随后记录表面支撑、自由空间与未知区域。条件流在离线构建阶段处理未知潜码。此后的渲染读取已接受的内容和当前状态，无须为每条轨迹重新执行潜空间补全。

生成式场景与资产补全。 StreetCrafter 用 LiDAR 渲染条件控制视频扩散，再以生成视图指导高斯重建 [11]；HorizonForge 将可编辑的高斯–网格内容与视频扩散结合 [8]。WorldSplat 在高斯生成后精修渲染视频 [16]。DriveCompose 直接补全状态驱动高斯渲染器使用的三维内容。潜空间方法中，GenAssets 面向驾驶资产，CompleteSplat 面向高斯场景补全，JRM 通过潜空间流匹配聚合共享对象的未对齐观测 [5, 9, 13]。LatentWorld 则提供以实体为中心的语义占据生成控制 [7]。这些方法采用不同的生成单位：单个资产、场景，或由多份观测恢复的共享对象。DriveCompose 让这些单位处于同一查询布局，保留各类变换，并共享原视角检查。本文的变量将世界空间背景与刚体、关节规范资产联合建模；已见与自由空间约束作用于采样和解码，接受检查决定补全组件如何进入同一份可复用的 RGB 渲染世界。

3. 方法

DriveCompose 构建一次世界，再在变化的状态下渲染。离线构建从驾驶日志恢复证据，将其聚合到规范支撑上，补全未知潜码，并在已见视图中检查解码内容。通过检查的背景和资产保持固定，在线装配仅使用当前相机与资产状态（图 1）。

3.1. 问题定义与世界表示

输入为同步日志，包括图像 $\mathbf{I}_{t,v}$、时间戳、相机内参 $\mathbf{K}_v$ 和相机到 rig 的标定 $\mathbf{T}^r_{c_v}$。Rig 世界位姿 $\mathbf{T}^w_r(t)$ 由日志提供，或相对首帧估计。相机世界位姿为 $\mathbf{T}^w_{c_v}(t) = \mathbf{T}^w_r(t)\mathbf{T}^r_{c_v}$。变换作用于列向量，距离单位为米。图像采用线性 RGB 和校正后的针孔模型；畸变、滚动快门与曝光差异在聚合前处理。

我们构建世界

$$\mathcal{W} = \big(\mathcal{G}_b, C_{\text{sky}}, V_{\text{sky}}, \{\mathcal{A}_a\}, \mathcal{B}, \xi\big), \tag{1}$$

其中，$\mathcal{G}_b$ 为世界坐标背景，C_{sky} 为天空立方体贴图，V_{sky} 为其支持方向，$\mathcal{A}_a$ 为身份 a 的规范资产，$\mathcal{B}$ 为有限空间支撑，ξ 为补全种子。每个高斯保存中心 $\boldsymbol{\mu}$、正定协方差 $\boldsymbol{\Sigma}$、不透明度 α 及一阶局部方向外观。车辆保存固定局部几何与尺寸，人体额外保存静止骨架和蒙皮权重。接受候选后，这些参数保持固定。

共享恢复。 Driving Log Encoder 将相机标定、时间与图像特征共同编码，跨视角与跨时间摘要提供场景上下文。轨迹级槽表示资产身份，状态注意力预测各时刻的根位姿与人体关节旋转。几何头恢复相机轴向深度、法线、置信度、语义和实例归属。资产位姿先在 rig 坐标中预测，再用 $\mathbf{T}_r^w(t)$ 映射至世界坐标。每个人体在整条日志中共享一个体型码，用于选择规范支撑与绑定一致的模板。

3.2. 规范查询与证据聚合

查询包含规范位置 $\mathbf{q}_i$、单元尺度 $\boldsymbol{\delta}_i$、类型 k_i、局部分组 g_i 和参考世界坐标 $\mathbf{q}_i^w$。背景支撑结合可靠深度锚点与有限世界网格；车辆支撑结合运动归一化锚点与局部体积网格；人体查询位于身份相关的规范表面；天空查询为按立方体面分组的方向。布局在补全过程中固定。参考世界坐标将查询放置到首个输入时刻，并包含人体蒙皮变换，使局部身份与场景位置分别进入模型。

聚合图像证据时，我们按各帧资产状态放置查询：

$$\mathbf{p}_i(t) = \begin{cases} \mathbf{q}_i, & k_i = \text{background}, \\ \text{xyz}(\mathbf{T}_a^w(t)\bar{\mathbf{q}}_i), & k_i = \text{vehicle}, \\ \text{xyz}(\mathbf{T}_h^w(t)\mathbf{A}_i(t)\bar{\mathbf{q}}_i), & k_i = \text{human}. \end{cases} \tag{2}$$

这里，$\bar{\mathbf{q}}_i$ 为齐次坐标，xyz 提取欧氏坐标，$\mathbf{A}_i(t)$ 为加权蒙皮变换。天空投影仅使用相机旋转。

投影给出相机轴向深度 $z_{i,t,v}$ 与图像位置。令 $\boldsymbol{\phi}_{i,t,v}$、$d_{i,t,v}$ 和 $c_{i,t,v}$ 分别为采样特征、预测深度与置信度。容差为 $\eta = \eta_{\text{abs}} + \eta_{\text{rel}} d$，归一化深度残差为 $r = (d - z)/\eta$。表面观测必须位于图像内，深度与置信度可靠，实例与查询一致，且满足 $|r| \le 1$；背景查询还需满足静态背景语义。对于有效性 $a_{i,t,v}$，

$$w_{i,t,v} = a_{i,t,v} c_{i,t,v} \exp(-r_{i,t,v}^2/2), \tag{3}$$

$$\mathbf{h}_i = \frac{\sum_{t,v} w_{i,t,v}[\boldsymbol{\phi}_{i,t,v}; r_{i,t,v}]}{\max(\varepsilon, \sum_{t,v} w_{i,t,v})}. \tag{4}$$

查询置信度取已接受观测的最大值。仅当整个支撑单元位于已见表面之前时，可靠射线才投出自由空间票：

$$z_{i,t,v} + \tfrac{1}{2}\|\boldsymbol{\delta}_i\|_2 < d_{i,t,v} - \eta. \tag{5}$$

天空特征使用可靠天空语义，深度残差设为零，不进行自由空间投票。聚合质量为正的查询标为已见；其余查询若获得足够的自由空间票则标为自由空间，否则标为未知。互斥掩码 m_i、f_i 和 u_i 满足 $m_i + f_i + u_i = 1$。

类型专属编码器将 $[\mathbf{h}_i; \mathbf{q}_i; \boldsymbol{\delta}_i]$ 映射为已见潜码 $\mathbf{z}_i^{\text{obs}} \in \mathbb{R}^D$。用作条件前，未观测潜码清零。可见性标记与置信度单独进入补全网络，使部分目标与完整目标共享本征 codec 定义。

3.3. 观测锚定联合补全

局部分组与全局记忆。 Joint Completion DiT 接收当前与已见潜码、掩码、置信度、类型、两种坐标描述、单元尺度及日志摘要。背景按空间邻域分组，每个资产形成一组，天空按立方体面分组。局部自注意力更新各组后，共享记忆读取所有组，并将场景上下文写回查询：

$$\mathbf{M}' = \mathbf{M} + \text{Attn}_r(\mathbf{M}, \widetilde{\mathbf{X}}, \widetilde{\mathbf{X}}), \tag{6}$$

$$\mathbf{U} = \widetilde{\mathbf{X}} + \text{Attn}_w(\text{LN}(\widetilde{\mathbf{X}}), \mathbf{M}', \mathbf{M}'). \tag{7}$$

$\widetilde{\mathbf{X}}$ 拼接局部更新后的查询 token；注意力的三个输入依次为 query、key 和 value。$\mathbf{U}$ 之后执行残差前馈更新。流时间调制作用于局部归一化，记忆由可学习 token 和日志摘要初始化。组间由此共享场景条件，查询仍保留各自的坐标与运动模型。

条件流。 我们通过 Flow Matching 学习速度场 [6]。完整目标 $\mathbf{z}_1$ 与高斯噪声 $\boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I})$ 共享固定查询布局。对于流时间 $\tau \in [0, 1]$，

$$\mathbf{z}_\tau = m \odot \mathbf{z}^{\text{obs}} + u \odot [(1 - \tau)\boldsymbol{\epsilon} + \tau \mathbf{z}_1]. \tag{8}$$

自由空间潜码保持为零，未知查询的目标速度为 $\mathbf{z}_1 - \boldsymbol{\epsilon}$。采用可选的损失选择器 s_i，

$$\mathcal{L}_{\text{flow}} = \frac{\sum_i u_i s_i \|\mathbf{v}_\theta(\mathbf{z}_\tau, \tau, C)_i - (\mathbf{z}_{1,i} - \boldsymbol{\epsilon}_i)\|_2^2}{D \max(1, \sum_i u_i s_i)}. \tag{9}$$

C 汇集已见证据和查询条件。式 8 中每个参与插值的未知查询都需要有效完整目标，s_i 在这个有效集合中选择计入损失的项。

从 $\tau = 0$ 开始，我们以步长 $\Delta\tau = 1/S$ 执行 S 个 Euler 步：

$$\mathbf{z}^{j+1} = \Pi_{m,f}\left[\mathbf{z}^j + \Delta\tau\, u \odot \mathbf{v}_\theta(\mathbf{z}^j, j/S, C)\right]. \tag{10}$$

$\Pi_{m,f}$ 在每步后恢复已见潜码并清零自由空间潜码。种子决定一次补全结果。流时间索引离线生成过程，仿真时间索引此后的状态变化。

3.4. 解码与观测检查

按类型解码。 背景、车辆和人体头独立地将每个查询解码为 K 个子高斯，子高斯中心为

$$\boldsymbol{\mu}_{i,k} = \mathbf{q}_i + \tfrac{1}{2}\boldsymbol{\delta}_i \odot \tanh(\mathbf{b}_{i,k}). \tag{11}$$

正尺度与归一化旋转确定协方差。不透明度乘以 $1 - f_i$；人体子高斯继承支撑查询的蒙皮权重。独立头预测天空颜色，有效域仍由观测支撑确定。每个外观通道保存一个恒定 RGB 项与三个局部方向系数。在固定逐查询 codec 下，式 10 不改变已见子高斯参数。关闭非已见查询后，得到仅观测参照。

渲染接受检查。 即使参照参数不变，新增内容仍可能遮挡参照。我们按原始资产状态装配候选和参照，再从输入相机渲染两者。令 $e_{\text{cand}}(p)$ 和 $e_{\text{obs}}(p)$ 为像素 p 处的平均绝对 RGB 误差，在可靠非自车像素上平均正向退化

$$\Delta e(p) = \max\{e_{\text{cand}}(p) - e_{\text{obs}}(p), 0\} \tag{12}$$

使其他位置的改善不能抵消局部退化。检查还约束绝对 RGB 误差、有效深度误差、视图覆盖率与前景侵入。若新增表面位于预测参照深度之前，且未出现在仅观测渲染中，则记为侵入；其比例以可靠非天空几何像素归一化。接受条件结合聚合与最差视图的上界，并要求最低覆盖率。预测深度用于这些一致性检查，独立几何精度采用另外的参照。

3.5. 训练阶段与目标

恢复与 codec 拟合。 第一阶段监督几何、语义、实例归属、身份和状态，一次轨迹级匹配将预测槽分配给目标身份，并用于所有帧。第二阶段冻结恢复模块，训练类型专属 codec。部分观测与更完整观测使用相同的查询位置、类型、顺序和归属。解码表示采用渲染或集合匹配监督；只有已知子高斯对应关系时，才使用直接坐标损失。

补全先验。 第三阶段冻结恢复模块与 codec，用完整场景或资产目标，通过式 9 训练补全网络。第四阶段保持上述模块冻结，通过流积分、解码与渲染反向传播，将补全网络适配到部分真实日志。

基于观测的适配。 记 $\langle \ell \rangle_\Omega$ 为掩码 Ω 中有效元素的均值。RGB 与深度项采用带掩码的 L1 误差：$\mathcal{L}_{\text{rgb}} = \langle \|\widehat{\mathbf{I}} - \mathbf{I}\|_1/3 \rangle_{\Omega_I}$，$\mathcal{L}_{\text{depth}} = \langle |\widehat{d} - d| \rangle_{\Omega_d}$。对于已知自由射线上的累计不透明度 a_r、脚点有符号距离 d_f（地面上方为正）、接触掩码 Ω_c 以及穿透深度 d_p（进入其他资产内部为正），

$$\begin{aligned}\mathcal{L}_{\text{scene}} = {} & \lambda_e \langle a_r^2 \rangle + \lambda_g \langle [-d_f]_+^2 \rangle \\ & + \lambda_c \langle |d_f| \rangle_{\Omega_c} + \lambda_p \langle [d_p]_+^2 \rangle, \end{aligned} \tag{13}$$

$$\mathcal{L}_{\text{adapt}} = \lambda_r \mathcal{L}_{\text{rgb}} + \lambda_d \mathcal{L}_{\text{depth}} + \mathcal{L}_{\text{scene}}. \tag{14}$$

其中，$[x]_+ = \max(x, 0)$；未标掩码的均值在后端提供的射线或几何样本上计算。各项只使用可用观测与后端几何量。自由射线不透明度约束新增内容在射线方向上的影响，补充逐单元自由空间掩码的作用。潜码硬恢复与冻结解码保持已见锚点，适配目标则度量新增内容在图像和几何上的影响。λ 系数控制有效软约束的相对权重。编码器、codec、查询规范与补全版本共同记录，确保目标和采样条件采用相同表示。

3.6. 状态驱动装配与复用

在线第 k 步，状态 s_k 给出自车位姿、活动资产、车辆变换以及人体根与关节位姿。对于车辆，

$$\boldsymbol{\mu}^w = \mathbf{R}\boldsymbol{\mu}^a + \mathbf{t}, \qquad \boldsymbol{\Sigma}^w = \mathbf{R}\boldsymbol{\Sigma}^a\mathbf{R}^\top. \tag{15}$$

对于人体，加权蒙皮变换为 $\mathbf{A}_i = \sum_j w_{ij}\mathbf{P}_j\mathbf{B}_j^{-1}$，其中 $\mathbf{B}_j$ 与 $\mathbf{P}_j$ 为根坐标中的静止与当前全局关节变换。中心变为 $\bar{\boldsymbol{\mu}}_i^w = \mathbf{T}_h^w\mathbf{A}_i\bar{\boldsymbol{\mu}}_i^h$。组合后的局部线性映射 $\mathbf{J}_i$ 给出协方差 $\mathbf{J}_i\boldsymbol{\Sigma}_i\mathbf{J}_i^\top$；外观求值时，用 $\mathbf{J}_i^{-1}$ 将世界观察方向映回局部坐标。接近奇异的蒙皮变换予以拒绝。根位姿控制整体放置，根关节保留静止变换。

渲染器合成背景、活动资产与有效天空，策略动作和外部动力学推进状态：

$$o_k = \mathcal{R}(\text{Compose}(\mathcal{W}, s_k), \mathcal{C}_k), \tag{16}$$

$$s_{k+1} = F_{\text{dyn}}(s_k, \pi(o_k), \Delta t). \tag{17}$$

重置轨迹改变状态，但保留 $\mathcal{W}$ 及其种子。有限空间支撑与受支持天空方向决定覆盖范围。道路网格和碰撞代理与视觉资产共享坐标，由物理后端维护。

4. 实验

我们首先评估稀疏时序观测下的动态场景重建，重点考察运动对象区域的渲染质量。

4.1. Waymo 动态场景重建

数据与协议 我们使用 Waymo Open Dataset 的 798 个训练序列和 202 个验证序列。遵循 STORM，将验证序列划分为互不重叠的 2 秒片段，每段包含以 10 Hz 采集的 20 帧。输入来自前视、左前和右前三个相机，帧索引为 0、5、10 和 15。我们在其余帧上评估，分别报告时间内插与时间外推结果。RGB 预测与参考图像统一缩放至 240×160 像素后计算指标。 [12]

对比方法 我们与 STORM、DGGT、StreetForward、PointForward 和 Instant NuRec 比较，使用相同的上下文图像与目标帧。MOSAIC 接收图像和相机标定，在模型内部预测对象轨迹。我们区分基于图像的重建与使用 LiDAR 或外部对象轨迹的变体，并记录各方法的训练数据及相机位姿需求。 [1, 3, 4, 12, 14]

评价指标 我们在非天空像素和动态区域上报告 PSNR 与 SSIM，各方法使用一致的评测掩码。深度 RMSE 在有效的 LiDAR 投影采样点上计算。此外，分别统计车辆与行人区域，以评估刚体和关节对象的重建质量。指标先在每个序列内平均，再对序列取平均。

4.2. 实现细节

我们从运动对齐的观测中恢复类别专属对象资产，并与静态背景组合。完整重建耗时包含预处理、资产生成与场景组合。

4.3. 外推视角

我们评估 1、2、3、4、6 米的横向相机偏移。具有配对目标图像的视角使用图像指标；无配对真值的离轨视角使用 FID 与跨视角结构一致性，各方法采用相同参考图像集合。对象结果按可见表面覆盖率分组。

Table 1. Waymo 图像与深度评估. 已列数值据 PointForward [3]。

Method	Dynamic PSNR	SSIM	D-RMSE	Full PSNR	SSIM	D-RMSE
EmerNeRF	17.79	0.255	40.88	24.51	0.738	33.99
3DGS	17.13	0.267	13.88	25.13	0.741	19.68
PVG	15.51	0.128	15.91	22.38	0.661	13.01
DeformableGS	17.10	0.266	12.14	25.29	0.761	14.79
LGM	19.58	0.443	9.43	23.59	0.691	8.02
GS-LRM	20.02	0.520	9.95	25.18	0.753	7.94
Depth Anything 3	15.96	0.429	12.20	23.27	0.686	11.66
AnySplat	15.99	0.418	10.45	23.32	0.687	10.31
STORM	22.10	0.624	7.50	26.38	0.794	5.48
DGGT	22.80	0.651	6.55	27.41	0.846	3.47
PointForward	25.01	0.768	6.07	28.48	0.861	3.35
Ours	–	–	–	–	–	–



Figure 2. PointForward 的 Waymo 视角对比. 来源：PointForward [3].

4.4. 消融

我们分别分析运动对齐、类别专属分支、对象空间补全和持久资产复用。各变体使用相同观测和训练预算，按序列及对象类别报告图像质量与运动补偿一致性。

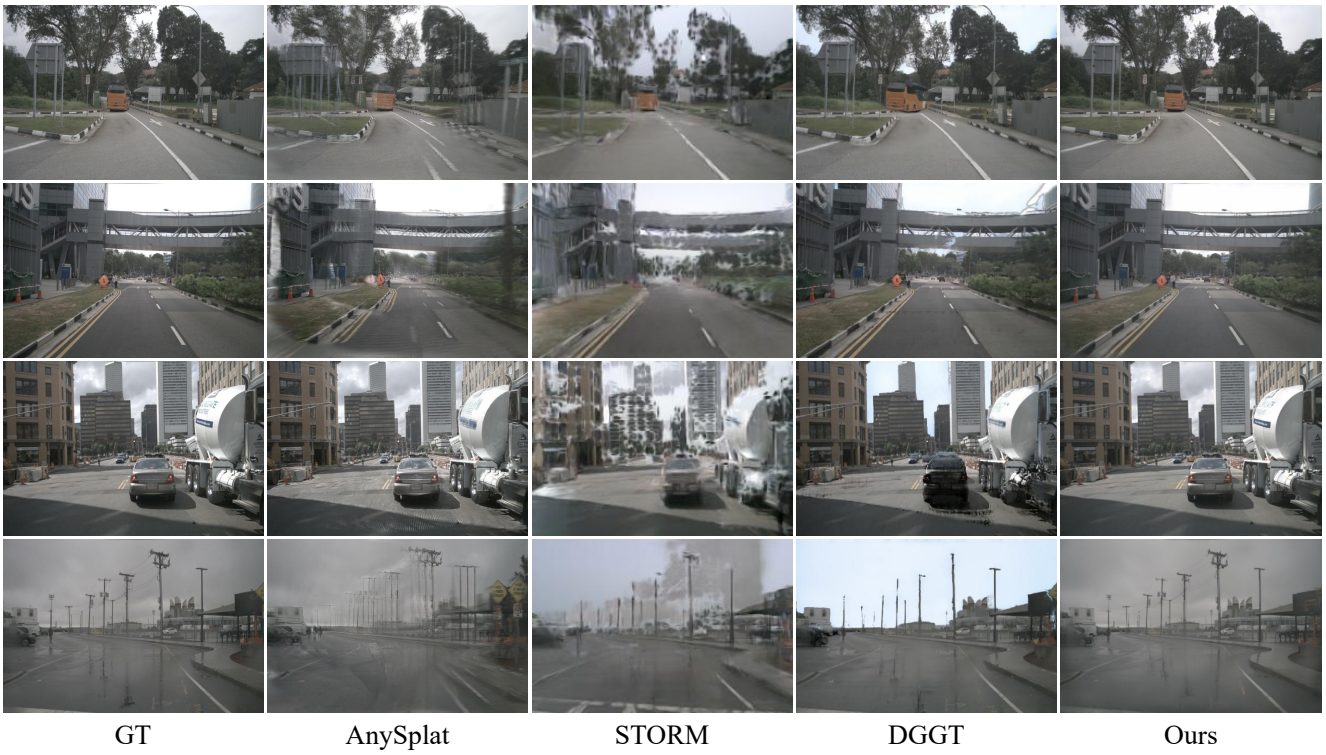


Figure 3. PointForward 在 nuScenes 上的跨数据集视角. 来源： PointForward [3].



Figure 4. PointForward 相机向左偏移 3 米的视角. 来源： PointForward [3].

Table 2. Waymo 上下文帧重建. 已列数值据 PointForward [3]。

Method	PSNR	SSIM
AnySplat	24.59	0.730
STORM	26.55	0.851
DGGT	30.54	0.884
PointForward	33.96	0.951
Ours	–	–

Table 3. nuScenes 零样本迁移与微调. 已列数值据 PointForward [3]。

Method	Zero PSNR	SSIM	Fine PSNR	SSIM
STORM	17.77	0.669	24.54	0.784
DGGT	25.31	0.794	26.63	0.813
PointForward	26.54	0.821	27.50	0.826
Ours	–	–	–	–

Table 4. Waymo 横向相机偏移的 FID. 已列数值据 PointForward [3]。

Shift (m)	STORM	DGGT	PointForward	Ours
1	47.31	49.51	16.95	–
2	63.09	61.35	25.80	–
3	81.54	77.51	33.71	–
4	102.19	96.96	42.63	–
6	140.17	139.79	65.99	–

Table 5. Waymo 组件消融. 已列数值据 PointForward [3]。

Variant	PSNR	SSIM
PF w/o weighted fusion	28.01	0.851
PF w/o depth-aware fusion	28.28	0.855
PF w/o lifespan	27.56	0.840
PF w/o LiDAR depth	28.00	0.847
PointForward (full)	28.48	0.861
Ours w/o motion alignment	–	–
Ours w/o category branches	–	–
Ours w/o completion	–	–
Ours w/o asset reuse	–	–
Ours	–	–

5. 讨论

DriveCompose 覆盖有限区域并采用固定照明。观测锚点会继承深度、身份和规范姿态的恢复误差。车辆保持刚体结构；人体使用固定衣物体积与骨架绑定，超出模板支撑的姿态可能暴露缺失内容。参考世界坐标描述构建时的场景，资产移动后的接触与碰撞有效性由物理后端处理。原视角检查约束补全结果与已记录证据的一致性；观测之外的几何以及新状态下的表现仍需分别评估。

6. 结论

DriveCompose 通过联合补全背景与规范资产潜码，构建可复用的高斯驾驶世界。规范支撑保留各类内容的几何与运动模型，参考世界坐标则让补全网络使用共享场景上下文。潜码硬约束保持已见参数并抑制自由空间，原视角渲染检查在接受候选前评估新增内容的影响。接受后的世界保持固定，相机放置、车辆运动与人体关节变化由显式状态变换驱动。构建与使用的分离，使多条轨迹共享一份补全场景：观测一致性在构建时检查，状态变化在装配时处理。

References

[1] Xiaoxue Chen, Ziyi Xiong, Yuantao Chen, Gen Li, Nan Wang, Hongcheng Luo, Long Chen, Haiyang Sun, Bing Wang, Guang Chen, Hongyang Li, Ya-Qin Zhang, Hangjun Ye, and Hao Zhao. DGGT: Feedforward 4D reconstruction of dynamic driving scenes using unposed images. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026. 2, 4

[2] Ziyu Chen, Jiawei Yang, Jiahui Huang, Riccardo de Lutio, Janick Martinez Esturo, Boris Ivanovic, Or Litany, Zan Gojcic, Sanja Fidler, Marco Pavone, Li Song, and Yue Wang. OmniRe: Omni urban scene reconstruction. In *International Conference on Learning Representations*, 2025. 1, 2

[3] Cheng Chi, Xianqi Wang, Hongcheng Luo, Mingfei Tu, Gangwei Xu, Zehan Zhang, Bing Wang, Guang Chen, Hangjun Ye, Sida Peng, Xin Yang, and Haiyang Sun. PointForward: Feedforward driving reconstruction through point-aligned representations. *arXiv preprint arXiv:2605.11594*, 2026. 2, 4, 5, 6, 7

[4] Jiahui Huang, Jiawei Ren, Michal Tyszkiewicz, Bjoern Haefner, Michael Shelley, Xin Kang, Seung Wook Kim, Ning Xu, Qi Wu, Janick Martinez Esturo, Shengyu Huang, Nick Schneider, Laura Leal-Taixé, Zan Gojcic, and Sanja Fidler. Instant NuRec: Feed-forward 3D gaussian reconstruction for driving scene simulation. *arXiv preprint arXiv:2607.14203*, 2026. 4

[5] Ziwei Liao, Mohamed Sayed, Steven L. Waslander, Sara Vicente, Daniyar Turmukhambetov, and Michael Firman. Complete gaussian splats from a single image with denoising diffusion models. *arXiv preprint arXiv:2508.21542*, 2025. 1, 2

[6] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. *arXiv preprint arXiv:2210.02747*, 2022. 3

[7] Jinhyung Park, Navyata Sanghvi, Erica Weng, Shawn Hunt, Shinya Tanaka, Hironobu Fujiyoshi, and Kris Kitani. Grounded latents for entity-centric 4D scene generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026. 2

[8] Yifan Wang, Francesco Pittaluga, Zaid Tasneem, Chenyu You, Manmohan Chandraker, and Ziyu Jiang. HorizonForge: Driving scene editing with any trajectories and any vehicles. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026. 1, 2

[9] Qirui Wu, Yawar Siddiqui, Duncan Frost, Samir Aroudj, Armen Avetisyan, Richard Newcombe, Angel X. Chang, Jakob Engel, and Henry Howard-Jenkins. JRM: Joint reconstruction model for multiple objects without alignment. *arXiv preprint arXiv:2603.25985*, 2026. 2

[10] Yunzhi Yan, Haotong Lin, Chenxu Zhou, Weijie Wang, Haiyang Sun, Kun Zhan, Xianpeng Lang, Xiaowei Zhou, and Sida Peng. Street gaussians: Modeling dynamic urban scenes with gaussian splatting. In *European Conference on Computer Vision*, 2024. 1, 2

[11] Yunzhi Yan, Zhen Xu, Haotong Lin, Haian Jin, Haoyu Guo, Yida Wang, Kun Zhan, Xianpeng Lang, Hujun Bao, Xiaowei Zhou, and Sida Peng. StreetCrafter: Street view synthesis with controllable video diffusion models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025. 1, 2

[12] Jiawei Yang, Jiahui Huang, Yuxiao Chen, Yan Wang, Boyi Li, Yurong You, Maximilian Igl, Apoorva Sharma, Peter Karkus, Danfei Xu, Boris Ivanovic, Yue Wang, and Marco Pavone. STORM: Spatio-temporal reconstruction model for large-scale outdoor scenes. In *International Conference on Learning Representations*, 2025. 2, 4

[13] Ze Yang, Jingkang Wang, Haowei Zhang, Sivabalan Manivasagam, Yun Chen, and Raquel Urtasun. GenAssets: Generating in-the-wild 3D assets in latent space. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025. 1, 2

[14] Zhongrui Yu, Zhao Wang, Yijia Xie, Yida Wang, Xueyang Zhang, Yifei Zhan, and Kun Zhan. StreetForward: Perceiving dynamic street with feedforward causal attention. *arXiv preprint arXiv:2603.19552*, 2026. 2, 4

[15] Hongyu Zhou, Longzhong Lin, Jiabao Wang, Yichong Lu, Dongfeng Bai, Bingbing Liu, Yue Wang, Andreas Geiger, and Yiyi Liao. HUGSIM: A real-time, photo-realistic and closed-loop simulator for autonomous driving. *arXiv preprint arXiv:2412.01718*, 2024. 1, 2

[16] Ziyue Zhu, Zhanqian Wu, Zhenxin Zhu, Lijun Zhou, Haiyang Sun, Bing Wan, Kun Ma, Guang Chen, Hangjun Ye, Jin Xie, and Jian Yang. WorldSplat: Gaussian-centric feed-forward 4D scene generation for autonomous driving. *arXiv preprint arXiv:2509.23402*, 2025. 1, 2