DriveCompose：通过联合补全实现驾驶场景的可组合生成式重建

Anonymous CVPR submission

Paper ID *****

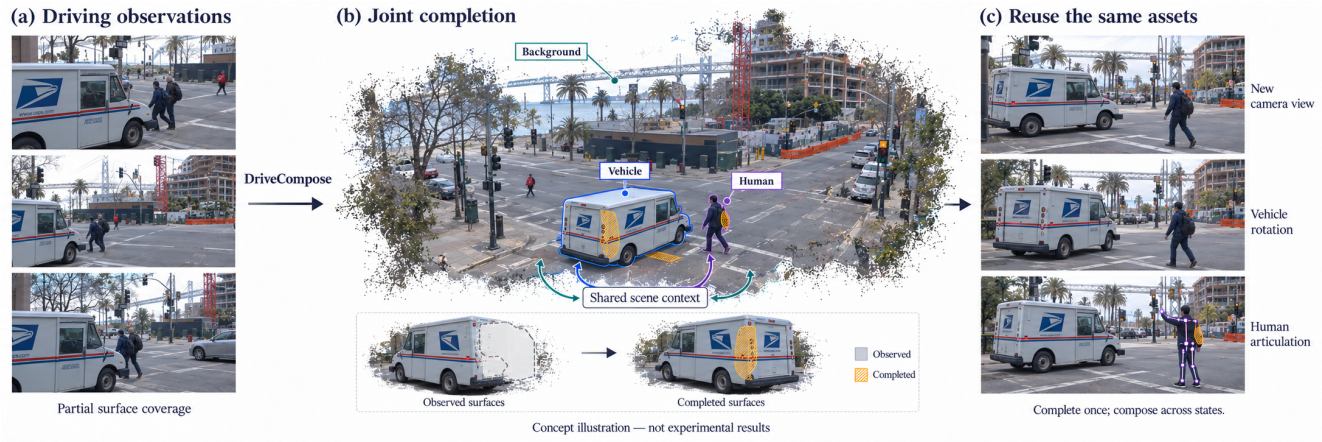

Figure 1. **DriveCompose 概念示意**。从驾驶图像中联合补全背景、车辆与人体的内容，构建可组合高斯场景。同一组资产可在相机视角、车辆位姿和人体姿态变化时复用。金色标注表示补全区域。

Abstract

从局部观测中重建完整、可控的三维场景，是自动驾驶仿真与场景编辑的重要基础。我们提出 *DriveCompose*，从图像序列中生成式地重建可组合驾驶场景。我们在世界坐标系中表示背景，在车辆和人体各自的规范坐标系中表示其内容，使补全表面能够随所属车辆运动或人体姿态变化。基于条件流匹配的生成模型在这些表示中联合补全背景与参与者的缺失内容，并通过跨组件记忆共享场景上下文。为保持与输入观测的一致性，我们在补全时保留已观测表面的几何与外观，并在记录的相机视角和参与者状态下渲染补全后的场景，与输入图像比较。在 *Waymo* 上，*DriveCompose* 的动态场景重建和轨迹外视图合成效果优于所评估的基线。组件消融实验表明，相比不使用跨组件记忆的变体，我们的方法将未观测表面的 *RGB* 平均绝对误差降低了 *20.5%*。补全后的高斯场景可复用同一组资产，在不同相机视角、车辆位姿和人体姿态下组合与渲染。

1. 引言

驾驶仿真与场景编辑需要能够支持相机移动、车辆运动和人体姿态变化的三维场景 [46, 49]。然而，驾驶日志中的图像只提供采集视角和当时参与者状态下的可见表面 [1, 31]。移动相机、转动车辆或改变行人姿态，都会暴露此前未观测的区域。因此，场景重建需要补全这些区域的几何与外观，并使补全后的车辆和人体表面能够随所属对象运动。

近期前馈方法通过融合多帧图像，直接预测驾驶场景的三维几何与高斯表示 [3, 6, 45, 48]。运动估计与可见性建模进一步帮助这些方法对齐动态对象，并整合不同时刻的观测。多帧融合增加了对输入序列中可见表面的覆盖。当新视角或对象运动暴露出整个序列都未曾拍摄的表面时，重建需要借助生成先验推断其几何与外观。

生成式重建通过资产先验、高斯补全或生成视图推断未观测内容 [17, 44, 47, 51]。与此同时，可组合重建将背景与运动对象分开表示，支持车辆移动和人体姿态控制 [5, 43, 49]。将生成补全用于这类场景，需要使补出的表面随所属对象运动，同时让每个对象能够利用周围场景的信息完成补全。

为此，我们提出 DriveCompose，从驾驶图像序列中构建可独立控制、并经过生成补全的三维场景。我们在世界坐标系中表示背景，在车辆自身的坐标系中表示车身，并在参考姿态下表示人体、保留其骨架绑定 [5, 43]。补全直接在这些表示中进行，使生成的车辆和人体表面能够随所属对象运动或改变姿态（第 3.1 节）。在此

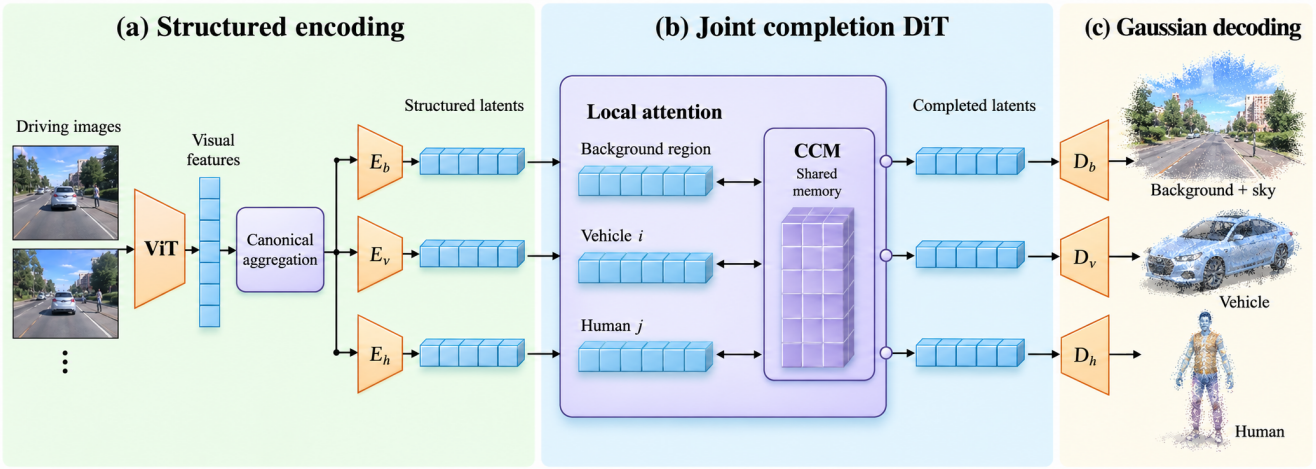

Figure 2. **DriveCompose 总览**。(a) 共享 ViT 提取的视觉证据在背景与规范资产支撑上聚合，再编码为结构化潜码。(b) 联合补全在各组内执行局部注意力，并通过跨组件记忆（CCM）共享上下文。(c) 类型专属解码器输出高斯背景、规范车辆与人体资产，以及天空贴图。

基础上，模型通过共享场景上下文，联合补全背景与各对象的缺失内容。

如图 2 所示，DriveCompose 首先从图像序列中恢复场景几何与参与者运动，将多帧图像特征对齐到背景、车辆和人体各自的表示中。补全模型在每个组件内部建模局部结构，并通过跨组件记忆汇集背景与各对象的信息，再将共享上下文传回各组件。这样，车辆或人体的缺失部分可以结合周围场景的信息进行补全。模型通过流匹配学习生成缺失潜码 [18]，再由各组件的解码器将补全后的表示转化为高斯场景 [15]。

补全时，我们保留由可靠观测确定的表面，并生成缺失部分的几何与外观。新增表面可能遮挡原本可见的区域，因此我们在记录的相机视角和参与者状态下渲染补全后的场景，与输入图像比较，检查补全是否引入观测不一致。通过检查的场景可复用同一份补全内容，在不同相机视角和参与者状态下渲染（第 3.5 节）。

在 Waymo 上，DriveCompose 在动态场景重建和轨迹外视图合成中优于所评估的基线（第 4 节）。组件消融进一步表明，跨组件信息共享能够降低未观测表面的补全误差，且在输入观测较少时带来更大的绝对误差降幅（第 4.3 节）。

本文的贡献包括：

- 提出面向闭环驾驶仿真的生成式重建框架 DriveCompose。从图像序列中恢复并补全背景、车辆与人体，构建可组合的高斯场景资产。所得场景可在相机位姿、车辆位姿和人体姿态变化时，复用同一组补全资产进行组合与渲染。
- 设计基于条件流匹配的跨组件潜空间补全模型。通过局部注意力建模各组件内部的空间关系，通过跨组件记忆汇集背景与参与者的特征，为各组件的缺失内容生成提供场景上下文。
- 通过动态重建、轨迹外视图合成与组件消融评估框架及其关键机制。实验表明，DriveCompose 在动态场景重建和轨迹外视图合成中优于所评估的基线；跨组件信息共享降低了未观测表面的补全误差，并在观测稀疏时带来更大的绝对误差降幅。

第 2 节回顾相关工作，第 3 节介绍方法，第 4 节报告实验，第 5 节和第 6 节分别讨论局限性并总结全文。

2. 相关工作

驾驶场景重建。 NeRF 与高斯泼溅为城市重建提供辐射表示 [15, 22]，NeuRAD 和 SplatAD 进一步发展面向驾驶场景的渲染 [11, 33]。前馈方法从图像学习几何恢复与高斯预测 [2, 4, 12, 35, 36]。对于驾驶日志，STORM 通过场景流聚合动态高斯，DGGT 则结合相机恢复、时间可见性和运动引导插值 [3, 45]。DrivingForward、StreetForward、PointForward 和 Instant NuRec 进一步探索环视输入、时序处理、点对齐表示及面向仿真的重建 [6, 14, 32, 48]。TokenGS 也通过可学习 token 解耦像素与高斯预测 [29]。DriveCompose 将恢复的证据聚合到背景与规范资产支撑上，再通过条件生成补全缺失内容并解码为高斯。

可组合场景与可控资产。 Neural Scene Graphs、Street Gaussians 和 DrivingGaussian 将场景分为背景与运动组件 [23, 43, 50]。OmniRe 包含刚体与关节化参与者的规范表示，UniSim 和 HUGSIM 则将重建内容接入闭环仿真 [5, 46, 49]。在资产层面，基于 SMPL 的人体模型和可驱动高斯方法提供规范表面与运动绑定 [13, 16, 20, 25, 27]；LHM 与 IDOL 推断可驱动人体，UrbanCAD 面向可控车辆 [21, 28, 52]。这些工作建立了操控场景组件所需的表示与控制机制。本文的补全变量保留这一组件结构，使生成表面继承资产身份、坐标系和运动绑定。

生成式重建与补全。 图像条件三维生成可通过生成视图 [9, 19, 30] 或编码几何与外观的结构化潜变量实现 [41, 42]。GenAssets 学习驾驶资产先验，CompleteSplat 补全隐藏的高斯内容，JRM 通过潜空间流匹配聚合未对齐的对象观测 [17, 40, 47]。LatentWorld 围绕实体和背景潜变量组织语义占据生成 [24]，是结构化场景生成的重要比较对象。DriveCompose 面向以驾驶日志为条件、可供 RGB 渲染的重建：共享补全模型在世界空间背景与规范车辆、人体潜码之间交换上下文。已见潜码和已知自由空间约束采样，原始视角渲染在复用前检查装配结果。

驾驶场景与视频生成。 MagicDrive、DriveDreamer 和 Vista 以场景结构或控制为条件生成驾驶图像 [8, 10, 37]。StreetCrafter 用生成视图监督动态高斯重建，HorizonForge 将场景编辑与视频扩散结合 [38, 44]。WorldSplat 生成高斯并细化其渲染视频，DIFIX3D+ 则通过扩散模型细化图像 [39, 51]。这些方法在不同阶段连接生成图像与三维场景表示。DriveCompose 在场景构建阶段完成补全并保存背景与规范资产，后续相机、刚体与骨架状态均渲染同一份补全内容。

3. 方法

DriveCompose 按照后续控制的单位重建驾驶场景。图 2 展示主要重建流程。

3.1. 问题定义与可组合表示

输入是同步图像日志 $\mathbf{I}_{t,v}$、时间戳、相机内参及相机到传感器支架的标定。支架位姿由日志提供，或以第一帧为参考估计。坐标约定与图像预处理见补充材料附录 D。

输出为可组合高斯场景

$$\mathcal{W} = \big(\mathcal{G}_b, C_{\text{sky}}, V_{\text{sky}}, \{\mathcal{A}_a\}, \mathcal{B}, \xi\big), \tag{1}$$

其中，$\mathcal{G}_b$ 是世界空间背景，C_{sky} 是天空立方体贴图，V_{sky} 表示其有效方向，$\mathcal{A}_a$ 是身份 a 对应的规范资产，$\mathcal{B}$ 是有限空间支撑，ξ 是采样种子。这些组件通过高斯泼溅渲染 [15]。车辆保留局部几何与固定尺寸，人体另存静止骨架和蒙皮权重。场景状态控制这些固定组件的放置与关节运动。

我们通过条件生成建模缺失内容。令 $\mathcal{Q}$ 为恢复得到的查询布局，C 为其观测证据。补全模型采样未知潜码 $\mathbf{z}_u$，编解码器 D_ψ 将组合后的潜码解码为场景内容：

$$\mathbf{z}_u \sim p_\theta(\mathbf{z}_u \mid C, \mathcal{Q}), \qquad \mathcal{W} = D_\psi(\mathbf{z}^{\text{obs}}, \mathbf{z}_u; \mathcal{Q}). \tag{2}$$

解码器同时保留式 1 中固定的支撑、身份、绑定和天空有效域元数据。布局由输入日志建立，生成过程填充其中的未知内容。仿真时间改变解码场景的状态，流时间则描述潜码的构建过程。

3.2. 视觉恢复与规范聚合

共享视觉编码。 Driving Log Encoder 使用 Transformer 特征 [7, 34]，从有标定的图像日志预测相机光轴深度、法线、置信度、语义和实例归属。轨迹级身份槽将持久身份、尺寸和人体体型与逐帧变化的根位姿、关节旋转分开表示。网络结构与状态参数化细节见补充材料附录 D。

查询支撑。 每个查询存储规范位置 $\mathbf{q}_i$、单元尺度 $\boldsymbol{\delta}_i$、类型 k_i、局部注意力组 g_i 和参考世界坐标 $\mathbf{q}_i^w$。可靠深度样本提供表面锚点。背景锚点与有限世界网格结合；车辆锚点经运动规范化后，与局部包围体中的网格结合。人体查询位于规范模板表面，天空查询为按立方体贴图面分组的单位方向。这些支撑为已见与缺失内容提供明确位置。

补全过程中布局保持固定。我们将查询放到第一帧的配置中以得到 $\mathbf{q}_i^w$，其中人体包含蒙皮变换。规范坐标标识组件内部的内容，参考世界坐标则使生成器能够联系该组件与周围场景。

运动感知证据聚合。 对于每份观测，我们将规范查询放到对应的资产状态：

$$\mathbf{p}_i(t) = \begin{cases} \mathbf{q}_i, & k_i = \text{background}, \\ \text{xyz}(\mathbf{T}_a^w(t)\bar{\mathbf{q}}_i), & k_i = \text{vehicle}, \\ \text{xyz}(\mathbf{T}_h^w(t)\mathbf{A}_i(t)\bar{\mathbf{q}}_i), & k_i = \text{human}. \end{cases} \tag{3}$$

其中，$\bar{\mathbf{q}}_i$ 为齐次坐标，xyz 提取欧氏坐标，$\mathbf{A}_i(t)$ 为加权蒙皮变换。投影到相机后，得到深度 $z_{i,t,v}$ 以及采样特征、深度和置信度 $(\boldsymbol{\phi}_{i,t,v}, d_{i,t,v}, c_{i,t,v})$。给定容差 $\eta = \eta_{\text{abs}} + \eta_{\text{rel}} d$，定义 $r = (d - z)/\eta$。表面观测需位于图像内、深度有效、置信度足够，与查询的实例身份一致，并满足 $|r| \le 1$。背景查询还要求静态背景语义。令 $a_{i,t,v}$ 表示这一有效性判断，则聚合为

$$w_{i,t,v} = a_{i,t,v} c_{i,t,v} \exp(-r_{i,t,v}^2/2), \tag{4}$$

$$\mathbf{h}_i = \frac{\sum_{t,v} w_{i,t,v} [\boldsymbol{\phi}_{i,t,v}; r_{i,t,v}]}{\max(\varepsilon, \sum_{t,v} w_{i,t,v})}. \tag{5}$$

查询置信度取被接受观测中的最大值。仅当整个支撑单元都位于观测表面之前时，可靠射线才提供自由空间票；具体判定式见补充材料附录 D。

有效观测权重之和大于零时，查询被标为已见。否则，足够的自由空间票将其标为自由空间，其余查询为未知。掩码 m_i、f_i 和 u_i 互斥，满足 $m_i + f_i + u_i = 1$。天空投影仅使用相机旋转，采用可靠天空语义和零深度残差，不接收自由空间票。

3.3. 结构化潜表示与解码

类型专属编码器将 $[\mathbf{h}_i; \mathbf{q}_i; \boldsymbol{\delta}_i]$ 映射为潜码 $\mathbf{z}_i \in \mathbb{R}^D$。各潜码维度相同，但查询仍保留类型、归属和坐标系。可

见性掩码与置信度单独提供给补全模型，使部分观测与完整观测使用同一潜码编码映射。作为条件输入之前，未观测潜码置零；已见子集记为 $\mathbf{z}^{\text{obs}}$。

背景、车辆和人体解码器分别将每个查询独立映射为限制在其支撑单元内的 K 个子高斯。人体子高斯继承查询的蒙皮权重；车辆子高斯共用所属资产的刚体变换。不透明度乘以 $1-f_i$，使自由空间查询不能产生可见高斯。独立天空头在观测支持的方向域 V_{sky} 内预测立方体贴图颜色。高斯与外观参数化详见补充材料附录 E。

解码逐查询执行：编解码器冻结后，不变的已见潜码产生不变的高斯参数。补全网络可以在查询之间交换上下文，同时保留这一解码性质。

3.4. 条件生成式重建

生成式补全模块。 生成式补全模块（Generative Completion Module，GCM）由场景条件流 Transformer 与约束采样组成。我们采用 DiT 风格的 Transformer [26] 参数化补全速度场，并通过流匹配训练 [18]。输入结合当前潜码、已见潜码、掩码、置信度、类型、两种坐标描述、单元尺度和池化日志特征。背景按空间邻域分组，每个资产构成一个局部组，天空方向按立方体贴图面分组。局部自注意力分别处理各组，跨组件记忆模块（Cross-Component Memory，CCM）随后通过共享记忆交换上下文：

$$\mathbf{M}' = \mathbf{M} + \text{Attn}_r(\mathbf{M}, \widetilde{\mathbf{X}}, \widetilde{\mathbf{X}}), \tag{6}$$

$$\mathbf{U} = \widetilde{\mathbf{X}} + \text{Attn}_w(\text{LN}(\widetilde{\mathbf{X}}), \mathbf{M}', \mathbf{M}'). \tag{7}$$

其中，$\widetilde{\mathbf{X}}$ 拼接局部更新后的 token，注意力的三个参数依次为查询、键和值。$\mathbf{U}$ 后接残差前馈更新。流时间调制进入局部归一化，记忆由可学习 token 和日志摘要初始化。这一结构保留各类支撑的局部组织，同时使车辆或人体查询能够使用周围场景的信息。

流训练与约束采样。 令 $\mathbf{z}_1$ 为同一查询布局上的完整目标，$\boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I})$ 为高斯噪声。在流时间 $\tau \in [0,1]$，我们仅对未知内容插值：

$$\mathbf{z}_\tau = m \odot \mathbf{z}^{\text{obs}} + u \odot [(1-\tau)\boldsymbol{\epsilon} + \tau \mathbf{z}_1]. \tag{8}$$

已见潜码固定，自由空间潜码保持为零。未知查询的目标速度为 $\mathbf{z}_1 - \boldsymbol{\epsilon}$。引入可选损失选择器 s_i，目标为

$$\mathcal{L}_{\text{flow}} = \frac{\sum_i u_i s_i \|\mathbf{v}_\theta(\mathbf{z}_\tau, \tau, C)_i - (\mathbf{z}_{1,i} - \boldsymbol{\epsilon}_i)\|_2^2}{D \max(1, \sum_i u_i s_i)}. \tag{9}$$

式 8 中所有参与插值的未知查询都需要有效目标潜码，即使 s_i 将其中一部分排除在损失之外。该要求决定了第 3.6 节中完整目标的构造方式。

推理时，以噪声初始化未知潜码，并执行 S 次 Euler 步，步长为 $\Delta\tau = 1/S$：

Table 1. 训练阶段。R：恢复模块；C：编解码器；G：GCM。T：训练；F：冻结；–：未使用。

阶段	R	C	G	监督
视觉恢复	T	–	–	几何、语义、身份、状态
表示拟合	F	T	–	部分与完整观测
补全先验	F	F	T	完整目标
渲染适配	F	F	T	真实日志渲染与场景约束

$$\mathbf{z}^{j+1} = \Pi_{m,f}\left[\mathbf{z}^j + \Delta\tau\, u \odot \mathbf{v}_\theta(\mathbf{z}^j, j/S, C)\right]. \tag{10}$$

投影 $\Pi_{m,f}$ 在每步后恢复已见潜码，并清零自由空间潜码。种子确定一次采样补全。采样完成后再解码；相机或资产状态改变时复用得到的场景。

3.5. 场景装配与观测一致性

状态驱动渲染。 在线步 k 的状态 s_k 指定自车位姿、活动资产、车辆变换，以及人体根位姿与关节姿态。车辆通过刚体变换放置，人体通过蒙皮变换放置；标准变换和后端细节见补充材料附录 C。渲染器合成背景、活动资产和有效天空：

$$o_k = \mathcal{R}(\text{Compose}(\mathcal{W}, s_k), \mathcal{C}_k). \tag{11}$$

重置或分支轨迹改变状态，同时保留 $\mathcal{W}$ 及其种子。有限空间支撑和有效天空方向决定覆盖范围。

构建场景的检查。 固定已见潜码能够保持解码参数，但新增表面仍可能遮挡这些内容。接受场景之前，我们在原始相机和资产状态下渲染补全候选及仅由已见查询构成的观测参考；参考渲染关闭全部非已见查询。令 $e_{\text{cand}}(p)$ 和 $e_{\text{obs}}(p)$ 为像素 p 处两者的平均绝对 RGB 误差，局部退化定义为

$$\Delta e(p) = \max\{e_{\text{cand}}(p) - e_{\text{obs}}(p), 0\}. \tag{12}$$

在可靠的非自车像素上平均这一量，避免某一区域的改善抵消其他区域的退化。接受条件还限制绝对 RGB 误差、有效深度误差和前景侵入率，并要求最低覆盖率；这些条件同时检查聚合结果和最差视图。前景侵入指新增渲染表面位于预测参考深度之前，且未出现在观测参考渲染中；其比例按可靠的非天空几何像素归一化。预测深度提供观测一致性参照，独立几何评测需要另一份参考。被拒绝的候选不导出复用。

3.6. 训练流程

学习分为四个阶段，使补全目标保持稳定的含义（表 1）。

编解码器拟合时，部分输入与更完整观测共享相同的查询位置、类型、顺序和归属。随后冻结恢复模块与整个编解码器，使用为每个未知查询提供有效目标的完整场景或资产样本，以式 9 训练 GCM。真实日志适配通过流积分、解码和渲染反向传播，仅更新 GCM。

完整目标样本可交替使用以保留先验，各损失项仅作用于具备所需目标的样本。已见锚点由冻结解码和潜码硬恢复维持。详细监督、损失和条件扰动见补充材料附录 B。

推理时，日志只编码一次，补全过程中支撑与证据保持固定；解码后的场景通过检查后，按指定状态复用（第 3.5 节）。

4. 实验

我们从三个方面评价方法：（*i*）Waymo Open Dataset 上的动态场景重建质量（第 4.1 节）；（*ii*）横向相机偏移下的轨迹外视图合成（第 4.2 节）；（*iii*）主要设计的消融分析（第 4.3 节）。跨数据集泛化结果见补充材料。

4.1. 动态场景重建

图 3 展示第一个主实验的五组场景重建对比，比较参与者轮廓、车辆边界和街道结构。

定性比较。 图 3 中，DriveCompose 保留了第一行的行人轮廓和第二行中央车辆的尾部外形，同时恢复周围街道布局。基线渲染在上方样例中出现参与者轮廓偏移或重复，在下方样例中出现道路结构模糊或畸变。DriveCompose 在这些展示样例中更接近参考结构，第三行行人周围及最后一行停放的皮卡附近仍有残余伪影。

4.2. 轨迹外视图合成

图 4 展示 Waymo 数据集上相机向左偏移 2 m 的定性视图外推结果，通过三组场景比较车辆外形、道路布局与遮挡边界。

4.3. 消融分析

实验协议。 隐藏表面的配对评价定义在具有独立完整参考的场景上；Waymo 日志用于记录视角评价。每个窗口含 29 个时间戳，使用前向、左前和右前三路同步相机。嵌套输入为 $\mathcal{T}_2 = \{0, 28\}$、$\mathcal{T}_4 = \{0, 8, 20, 28\}$ 和 $\mathcal{T}_8 = \{0, 4, \ldots, 28\}$，共同目标时刻为 $\{2, 6, \ldots, 26\}$。目标图像不参与证据与查询构造；所有变体获得相同的目标相机与资产状态。恢复模块和编解码器冻结，在每档输入下对齐查询布局、数据曝光和优化预算。训练时等概率采样 $T \in \{2, 4, 8\}$，补全采用 24 步 Euler 积分。两个可训练版本使用训练种子 $\{0, 1, 2\}$ 和世界种子 $\{7, 17, 27\}$；w/o GCM 为确定性版本。超参数和接受阈值在内部开发集选定，再评价与训练场景及身份隔离的数据。

指标。 New-MAE 在独立判定为所有输入均不可见的表面上计算线性 RGB 误差；NVS-MAE 覆盖全部留出目标像素。两项 MAE 指标和 Obs-Reg 均采用 $[0, 1]$ 线性 RGB 尺度。跨输入档位比较时，New-MAE 使用相对 $\mathcal{T}_8$ 仍不可见的共同区域。Obs-Reg 对原始输入视角中式 12 的正退化取平均。Cov. 为目标非天空区域中支撑覆盖度 > 0.5、不透明度 > 0.1 且深度有限为正的像素比例。未覆盖像素统一填零 RGB 后计入误差。Pass 为固定检查器接受的世界占全部申请世界的比例，构建失败保留在分母中。图像指标纳入全部可渲染候选，包括被拒绝的世界；不可渲染数量单独记录。先在场景内平均，再对场景及训练种子汇总。

Table 2. **组件消融**。所有版本采用 $T = 8$（24 张图像）、相同的恢复模块与编解码器及统一评价掩码。质量在接受筛选前计算，Pass 包含全部申请世界。横线表示该指标未报告；粗体表示各列已报告的最优值。

变体	New-MAE ↓	Obs-Reg ↓	Cov. (%) ↑	Pass (%) ↑
w/o GCM	0.186	–	74.6	**95.0**
w/o CCM	0.078	0.005	94.5	87.0
Ours	**0.062**	**0.003**	**96.3**	93.0

补全与场景上下文。 表 2 将完整版本 Ours 与两个对照比较。w/o GCM 跳过生成式补全模块，并关闭所有非已见、非天空查询的不透明度。w/o CCM 在每一层将跨组件记忆模块替换为各组件独立的记忆，同时共享参数并保留相同的全局日志条件。可训练对照均重新执行阶段三、四，记忆机制引起的计算差异单独记录。

关闭生成补全后，New-MAE 从 0.062 升至 0.186，覆盖率从 96.3% 降至 74.6%。w/o GCM 的通过率达到 95.0%，但留下了更多未覆盖的目标像素。CCM 将 New-MAE 从 w/o CCM 的 0.078 降至 Ours 的 0.062，相对降低 20.5%，同时使覆盖率和通过率分别提高 1.8 和 6.0 个百分点。

输入稀疏度。 表 3 复用 Ours 和 w/o CCM 的权重，在 $T = 2, 4, 8$ 下分别输入 6/12/24 张图像。时间跨度、目标视图和共同未见区域掩码固定，证据与查询由各档输入重新构建。这项比较不重新训练模型。对 Ours，将 T 从 2 增至 8 后，NVS-MAE 从 0.043 降至 0.026，New-MAE 从 0.092 降至 0.062，覆盖率从 91.7% 提高至 96.3%。在每档输入下，Ours 的三项指标均优于 w/o CCM。在 $T = 2, 4, 8$ 时，CCM 带来的 New-MAE 绝对降幅分别为 0.027、0.020 和 0.016，覆盖率增益分别为 3.2、2.3 和 1.8 个百分点。输入较少时更大的绝对收益表明，跨组件上下文在观测稀疏时更有帮助。

4.4. 状态驱动复用

以时刻 14、世界种子 7 为参照，各干预分别沿相机局部 $+x$ 轴平移 1 m、绕车辆根位置及世界竖直轴转动 30°，或在根位置固定时施加留出的有效人体姿态 H_1。光照与规范资产保持固定，状态变化不重新采样补全内容。

Figure 3. **动态场景重建的定性对比**。每行展示一个样例，从左至右依次为真实图像、DGGT、STORM、StreetForward 和 DriveCompose（Ours）。样例覆盖行人、交通车辆与城市背景，用于比较参与者轮廓、车辆边界以及道路和建筑结构。

Table 3. **输入时刻数量敏感性**。每档 T 比较 w/o CCM 与完整模型，权重和目标视图固定。New-MAE 使用共同未见区域。$T = 8$ 的结果与表 2 一致；粗体表示每组内的较优值。

T	变体	NVS-MAE ↓	New-MAE ↓	Cov. (%) ↑
2	w/o CCM	0.052	0.119	88.5
	Ours	**0.043**	**0.092**	**91.7**
4	w/o CCM	0.038	0.094	92.3
	Ours	**0.032**	**0.074**	**94.6**
8	w/o CCM	0.030	0.078	94.5
	Ours	**0.026**	**0.062**	**96.3**

5. 局限

DriveCompose 表示固定照明下的有限区域。恢复深度、身份或规范姿态中的错误可能进入已见锚点，并对后续补全施加错误约束。车辆采用刚体模型，人体保留固定衣物体积和骨架绑定；超出模板支撑范围的姿态可能暴露缺失几何。参考世界坐标提供构建时的上下文，编辑后的接触与碰撞有效性则依赖物理后端。观测检查衡量与已记录证据的一致性，证据之外的几何和照明变化下的外观需要额外监督或建模。

6. 结论

本文提出 DriveCompose，用于可组合驾驶场景的生成式重建。结构化潜表示将图像证据汇入背景与规范资产，使缺失内容在生成之前就具有明确的位置、身份和运动模型。条件补全利用场景上下文并保留已观测证据，类型解码输出可复用高斯场景的组成部分。内容构建与状态驱动装配相分离，使后续相机和资产状态变化能够使用同一次补全结果。

Figure 4. **Waymo 数据集上相机向左偏移 2 m 的定性视图外推结果**。每行展示一个场景，各列从左至右依次为参考图像（GT）、STORM、DGGT、StreetForward 和 DriveCompose（Ours）。

References

[1] Holger Caesar, Varun Bankiti, Alex H. Lang, Sourabh Vora, Venice Erin Liong, Qiang Xu, Anush Krishnan, Yu Pan, Giancarlo Baldan, and Oscar Beijbom. nuScenes: A Multimodal Dataset for Autonomous Driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 11621–11631, 2020. 1

[2] David Charatan, Sizhe Lester Li, Andrea Tagliasacchi, and Vincent Sitzmann. pixelSplat: 3D Gaussian Splats from Image Pairs for Scalable Generalizable 3D Reconstruction. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 19457–19467, 2024. 2

[3] Xiaoxue Chen, Ziyi Xiong, Yuantao Chen, Gen Li, Nan Wang, Hongcheng Luo, Long Chen, Haiyang Sun, Bing Wang, Guang Chen, Hongyang Li, Ya-Qin Zhang, Hangjun Ye, and Hao Zhao. DGGT: Feedforward 4D Reconstruction of Dynamic Driving Scenes using Unposed Images. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 1265–1276, 2026. 1, 2

[4] Yuedong Chen, Haofei Xu, Chuanxia Zheng, Bohan Zhuang, Marc Pollefeys, Andreas Geiger, Tat-Jen Cham, and Jianfei Cai. MVSplat: Efficient 3D Gaussian Splatting from Sparse Multi-View Images. In *European Conference on Computer Vision (ECCV)*, 2024. 2

[5] Ziyu Chen, Jiawei Yang, Jiahui Huang, Riccardo de Lutio, Janick Martinez Esturo, Boris Ivanovic, Or Litany, Zan Gojcic, Sanja Fidler, Marco Pavone, Li Song, and Yue Wang. OmniRe: Omni Urban Scene Reconstruction. In *International Conference on Learning Representations*, pages 85508–85527, 2025. 1, 2

[6] Cheng Chi, Xianqi Wang, Hongcheng Luo, Mingfei Tu, Gangwei Xu, Zehan Zhang, Bing Wang, Guang Chen, Hangjun Ye, Sida Peng, Xin Yang, and Haiyang Sun. PointForward: Feedforward Driving Reconstruction through Point-Aligned Representations. *arXiv preprint arXiv:2605.11594*, 2026. 1, 2

[7] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. In *International Conference on Learning Representations (ICLR)*, 2021. 3

[8] Ruiyuan Gao, Kai Chen, Enze Xie, Lanqing HONG, Zhenguo Li, Dit-Yan Yeung, and Qiang Xu. MagicDrive: Street View Generation with Diverse 3D Geometry Control. In *International Conference on Learning Representations*, pages 22841–22860, 2024. 3

[9] Ruiqi Gao, Aleksander Hołyński, Philipp Henzler, Arthur Brussee, Ricardo Martin-Brualla, Pratul Srinivasan, Jonathan T. Barron, and Ben Poole. CAT3D: Create Anything in 3D with Multi-View Diffusion Models. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 75468–75494, 2024. 3

[10] Shenyuan Gao, Jiazhi Yang, Li Chen, Kashyap Chitta, Yihang Qiu, Andreas Geiger, Jun Zhang, and Hongyang Li. Vista: A Generalizable Driving World Model with High Fidelity and Versatile Controllability. In *Advances in Neural Information Processing Systems*, pages 91560–91596, 2024. 3

[11] Georg Hess, Carl Lindström, Maryam Fatemi, Christoffer Petersson, and Lennart Svensson. SplatAD: Real-Time Lidar and Camera Rendering with 3D Gaussian Splatting for Autonomous Driving. In *Proceedings of the IEEE/CVF Confer-*

ence on Computer Vision and Pattern Recognition (CVPR), pages 11982–11992, 2025. 2

[12] Yicong Hong, Kai Zhang, Jiuxiang Gu, Sai Bi, Yang Zhou, Difan Liu, Feng Liu, Kalyan Sunkavalli, Trung Bui, and Hao Tan. LRM: Large Reconstruction Model for Single Image to 3D. In *International Conference on Learning Representations*, pages 50678–50702, 2024. 2

[13] Shoukang Hu, Tao Hu, and Ziwei Liu. GauHuman: Articulated Gaussian Splatting from Monocular Human Videos. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 20418–20431, 2024. 2

[14] Jiahui Huang, Jiawei Ren, Michal Tyszkiewicz, Bjoern Haefner, Michael Shelley, Xin Kang, Seung Wook Kim, Ning Xu, Qi Wu, Janick Martinez Esturo, Shengyu Huang, Nick Schneider, Laura Leal-Taixé, Zan Gojcic, and Sanja Fidler. Instant NuRec: Feed-Forward 3D Gaussian Reconstruction for Driving Scene Simulation. *arXiv preprint arXiv:2607.14203*, 2026. 2

[15] Bernhard Kerbl, Georgios Kopanas, Thomas Leimkühler, and George Drettakis. 3D Gaussian Splatting for Real-Time Radiance Field Rendering. *ACM Transactions on Graphics*, 42(4), 2023. 2, 3

[16] Muhammed Kocabas, Jen-Hao Rick Chang, James Gabriel, Oncel Tuzel, and Anurag Ranjan. HUGS: Human Gaussian Splats. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 505–515, 2024. 2

[17] Ziwei Liao, Mohamed Sayed, Steven L. Waslander, Sara Vicente, Daniyar Turmukhambetov, and Michael Firman. Complete Gaussian Splats from a Single Image with Denoising Diffusion Models. *arXiv preprint arXiv:2508.21542*, 2025. 1, 3

[18] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow Matching for Generative Modeling. In *International Conference on Learning Representations*, 2023. 2, 4

[19] Ruoshi Liu, Rundi Wu, Basile Van Hoorick, Pavel Tokmakov, Sergey Zakharov, and Carl Vondrick. Zero-1-to-3: Zero-shot One Image to 3D Object. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 9298–9309, 2023. 3

[20] Matthew Loper, Naureen Mahmood, Javier Romero, Gerard Pons-Moll, and Michael J. Black. SMPL: A Skinned Multi-Person Linear Model. *ACM Trans. Graphics (Proc. SIGGRAPH Asia)*, 34(6):248:1–248:16, 2015. 2

[21] Yichong Lu, Yichi Cai, Shangzhan Zhang, Hongyu Zhou, Haoji Hu, Huimin Yu, Andreas Geiger, and Yiyi Liao. UrbanCAD: Towards Highly Controllable and Photorealistic 3D Vehicles for Urban Scene Simulation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 27519–27530, 2025. 2

[22] Ben Mildenhall, Pratul P. Srinivasan, Matthew Tancik, Jonathan T. Barron, Ravi Ramamoorthi, and Ren Ng. NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis. In *European Conference on Computer Vision (ECCV)*, 2020. 2

[23] Julian Ost, Fahim Mannan, Nils Thuerey, Julian Knodt, and Felix Heide. Neural Scene Graphs for Dynamic Scenes. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2856–2865, 2021. 2

[24] Jinhyung Park, Navyata Sanghvi, Erica Weng, Shawn Hunt, Shinya Tanaka, Hironobu Fujiyoshi, and Kris Kitani. Grounded Latents for Entity-Centric 4D Scene Generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026. 3

[25] Georgios Pavlakos, Vasileios Choutas, Nima Ghorbani, Timo Bolkart, Ahmed A. A. Osman, Dimitrios Tzionas, and Michael J. Black. Expressive Body Capture: 3D Hands, Face, and Body From a Single Image. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 10975–10985, 2019. 2

[26] William Peebles and Saining Xie. Scalable Diffusion Models with Transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 4195–4205, 2023. 4

[27] Zhiyin Qian, Shaofei Wang, Marko Mihajlovic, Andreas Geiger, and Siyu Tang. 3DGS-Avatar: Animatable Avatars via Deformable 3D Gaussian Splatting. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 5020–5030, 2024. 2

[28] Lingteng Qiu, Xiaodong Gu, Peihao Li, Qi Zuo, Weichao Shen, Junfei Zhang, Kejie Qiu, Weihao Yuan, Guanying Chen, Zilong Dong, and Liefeng Bo. LHM: Large Animatable Human Reconstruction Model for Single Image to 3D in Seconds. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 14184–14194, 2025. 2

[29] Jiawei Ren, Michal Jan Tyszkiewicz, Jiahui Huang, and Zan Gojcic. TokenGS: Decoupling 3D Gaussian Prediction from Pixels with Learnable Tokens. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 15365–15375, 2026. 2

[30] Yichun Shi, Peng Wang, Jianglong Ye, Long Mai, Kejie Li, and Xiao Yang. MVDream: Multi-view Diffusion for 3D Generation. In *International Conference on Learning Representations*, pages 39838–39859, 2024. 3

[31] Pei Sun, Henrik Kretzschmar, Xerxes Dotiwalla, Aurelien Chouard, Vijaysai Patnaik, Paul Tsui, James Guo, Yin Zhou, Yuning Chai, Benjamin Caine, Vijay Vasudevan, Wei Han, Jiquan Ngiam, Hang Zhao, Aleksei Timofeev, Scott Ettinger, Maxim Krivokon, Amy Gao, Aditya Joshi, Yu Zhang, Jonathon Shlens, Zhifeng Chen, and Dragomir Anguelov. Scalability in Perception for Autonomous Driving: Waymo Open Dataset. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2446–2454, 2020. 1

[32] Qijian Tian, Xin Tan, Yuan Xie, and Lizhuang Ma. DrivingForward: Feed-forward 3D Gaussian Splatting for Driving Scene Reconstruction from Flexible Surround-view Input. In *Proceedings of the AAAI Conference on Artificial Intelligence*, pages 7374–7382, 2025. 2

[33] Adam Tonderski, Carl Lindström, Georg Hess, William Ljungbergh, Lennart Svensson, and Christoffer Petersson.

NeuRAD: Neural Rendering for Autonomous Driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14895–14904, 2024. 2

[34] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Ł ukasz Kaiser, and Illia Polosukhin. Attention is All you Need. In *Advances in Neural Information Processing Systems*, 2017. 3

[35] Jianyuan Wang, Minghao Chen, Nikita Karaev, Andrea Vedaldi, Christian Rupprecht, and David Novotny. VGGT: Visual Geometry Grounded Transformer. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 5294–5306, 2025. 2

[36] Shuzhe Wang, Vincent Leroy, Yohann Cabon, Boris Chidlovskii, and Jerome Revaud. DUSt3R: Geometric 3D Vision Made Easy. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 20697–20709, 2024. 2

[37] Xiaofeng Wang, Zheng Zhu, Guan Huang, Chen Xinze, Jiagang Zhu, and Jiwen Lu. DriveDreamer: Towards Real-world-driven World Models for Autonomous Driving. In *European Conference on Computer Vision (ECCV)*, 2024. 3

[38] Yifan Wang, Francesco Pittaluga, Zaid Tasneem, Chenyu You, Manmohan Chandraker, and Ziyu Jiang. HorizonForge: Driving Scene Editing with Any Trajectories and Any Vehicles. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026. 3

[39] Jay Zhangjie Wu, Yuxuan Zhang, Haithem Turki, Xuanchi Ren, Jun Gao, Mike Zheng Shou, Sanja Fidler, Zan Gojcic, and Huan Ling. DIFIX3D+: Improving 3D Reconstructions with Single-Step Diffusion Models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 26024–26035, 2025. 3

[40] Qirui Wu, Yawar Siddiqui, Duncan Frost, Samir Aroudj, Armen Avetisyan, Richard Newcombe, Angel X. Chang, Jakob Engel, and Henry Howard-Jenkins. JRM: Joint Reconstruction Model for Multiple Objects without Alignment. *arXiv preprint arXiv:2603.25985*, 2026. 3

[41] Jianfeng Xiang, Zelong Lv, Sicheng Xu, Yu Deng, Ruicheng Wang, Bowen Zhang, Dong Chen, Xin Tong, and Jiaolong Yang. Structured 3D Latents for Scalable and Versatile 3D Generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 21469–21480, 2025. 3

[42] Jianfeng Xiang, Xiaoxue Chen, Sicheng Xu, Ruicheng Wang, Zelong Lv, Yu Deng, Hongyuan Zhu, Yue Dong, Hao Zhao, Nicholas Jing Yuan, and Jiaolong Yang. Native and Compact Structured Latents for 3D Generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14419–14429, 2026. 3

[43] Yunzhi Yan, Haotong Lin, Chenxu Zhou, Weijie Wang, Haiyang Sun, Kun Zhan, Xianpeng Lang, Xiaowei Zhou, and Sida Peng. Street Gaussians: Modeling Dynamic Urban Scenes with Gaussian Splatting. In *European Conference on Computer Vision (ECCV)*, 2024. 1, 2

[44] Yunzhi Yan, Zhen Xu, Haotong Lin, Haian Jin, Haoyu Guo, Yida Wang, Kun Zhan, Xianpeng Lang, Hujun Bao, Xiaowei Zhou, and Sida Peng. StreetCrafter: Street View Synthesis with Controllable Video Diffusion Models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 822–832, 2025. 1, 3

[45] Jiawei Yang, Jiahui Huang, Boris Ivanovic, Yuxiao Chen, Yan Wang, Boyi Li, Yurong You, Apoorva Sharma, Maximilian Igl, Peter Karkus, Danfei Xu, Yue Wang, and Marco Pavone. STORM: Spatio-TempOral Reconstruction Model For Large-Scale Outdoor Scenes. In *International Conference on Learning Representations*, pages 50446–50465, 2025. 1, 2

[46] Ze Yang, Yun Chen, Jingkang Wang, Sivabalan Manivasagam, Wei-Chiu Ma, Anqi Joyce Yang, and Raquel Urtasun. UniSim: A Neural Closed-Loop Sensor Simulator. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 1389–1399, 2023. 1, 2

[47] Ze Yang, Jingkang Wang, Haowei Zhang, Sivabalan Manivasagam, Yun Chen, and Raquel Urtasun. GenAssets: Generating in-the-wild 3D Assets in Latent Space. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 22392–22403, 2025. 1, 3

[48] Zhongrui Yu, Zhao Wang, Yijia Xie, Yida Wang, Xueyang Zhang, Yifei Zhan, and Kun Zhan. StreetForward: Perceiving Dynamic Street with Feedforward Causal Attention. *arXiv preprint arXiv:2603.19552*, 2026. 1, 2

[49] Hongyu Zhou, Longzhong Lin, Jiabao Wang, Yichong Lu, Dongfeng Bai, Bingbing Liu, Yue Wang, Andreas Geiger, and Yiyi Liao. HUGSIM: A Real-Time, Photo-Realistic and Closed-Loop Simulator for Autonomous Driving. *arXiv preprint arXiv:2412.01718*, 2024. 1, 2

[50] Xiaoyu Zhou, Zhiwei Lin, Xiaojun Shan, Yongtao Wang, Deqing Sun, and Ming-Hsuan Yang. DrivingGaussian: Composite Gaussian Splatting for Surrounding Dynamic Autonomous Driving Scenes. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 21634–21643, 2024. 2

[51] Ziyue Zhu, Zhanqian Wu, Zhenxin Zhu, Lijun Zhou, Haiyang Sun, Bing Wan, Kun Ma, Guang Chen, Hangjun Ye, Jin Xie, and Jian Yang. WorldSplat: Gaussian-Centric Feed-Forward 4D Scene Generation for Autonomous Driving. *arXiv preprint arXiv:2509.23402*, 2025. 1, 3

[52] Yiyu Zhuang, Jiaxi Lv, Hao Wen, Qing Shuai, Ailing Zeng, Hao Zhu, Shifeng Chen, Yujiu Yang, Xun Cao, and Wei Liu. IDOL: Instant Photorealistic 3D Human Creation from a Single Image. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 26308–26319, 2025. 2