DriveCompose：通过联合补全实现驾驶场景的可组合生成式重建

Anonymous CVPR submission

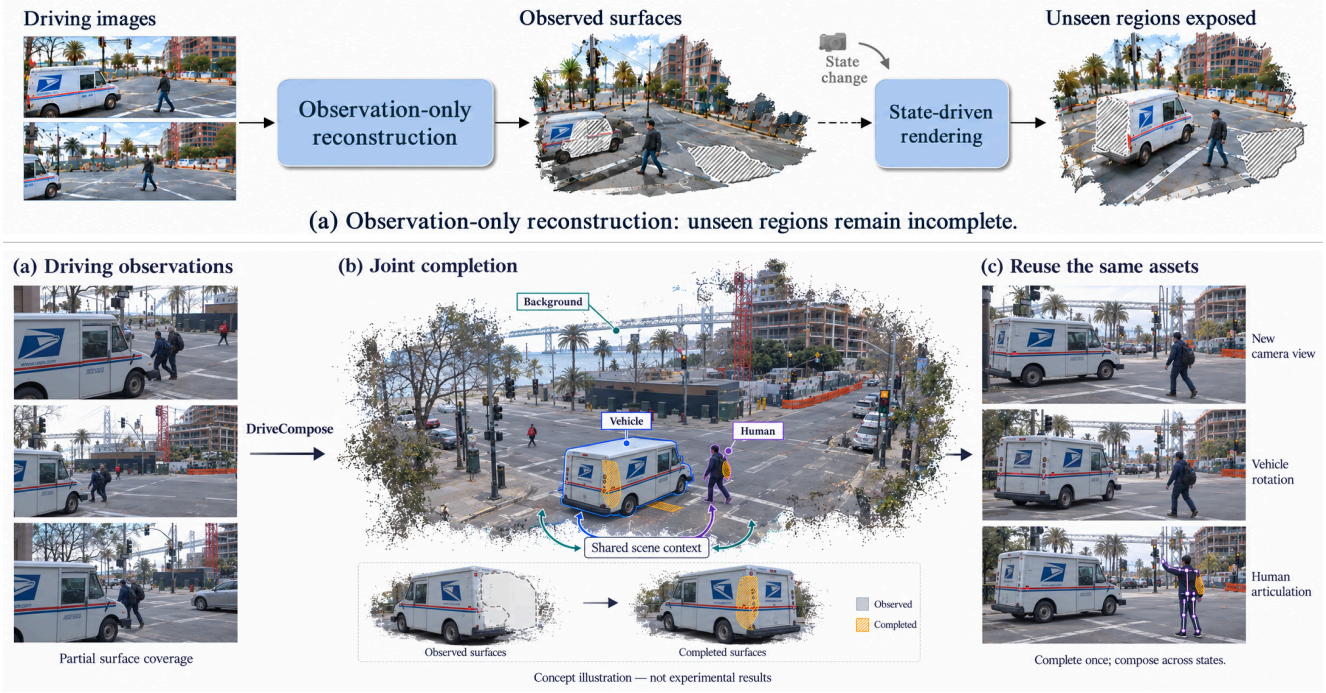

Figure 1. **从观测到可复用的完成资产**。上：视角或参与者状态变化会暴露观测重建中的缺失表面。下：DriveCompose 通过结构化编码和联合补全构建背景、规范车辆与人体，并在不同状态下复用。金色表示补全区域；所有场景与资产画面均为机制示意。

Abstract

驾驶仿真与场景编辑需要重建场景支持相机和参与者偏离记录状态后的运动。这些变化会暴露未见表面，其几何与外观需要在对应的背景、车辆或人体表示中完成补全。我们提出 *DriveCompose*，从驾驶图像序列中生成式地重建可组合场景。视觉特征在背景的世界坐标系和参与者各自的规范坐标系中聚合，再编码为对应组件的潜表示。条件流模型通过跨组件记忆交换场景上下文，联合补全缺失潜码。分类型高斯解码器保留刚体与骨架绑定，使同一份完成资产随新的相机和参与者状态组合。潜码硬恢复保持已见高斯参数，自由射线约束控制新增内容对渲染的影响。在 *Waymo* 的统一状态条件下，*DriveCompose* 的重建与轨迹外渲染优于状态适配后的基线，跨组件记忆使全图 *PSNR* 提高 *0.627 dB*。真实场景编辑在九组训练 / 生成种子下取得 *92.78%* 成功率，固定完成资产可跨状态复用。

1. 引言

驾驶仿真与场景编辑需要能够支持相机移动、车辆运动和人体姿态变化的三维场景 [46, 49]。然而，驾驶日志中的图像只提供采集视角和当时参与者状态下的可见表面 [1, 31]。移动相机、转动车辆或改变行人姿态，都会暴露此前未观测的区域（图 1）。因此，场景重建需要补全这些区域的几何与外观，并使补全后的车辆和人体表面能够随所属对象运动。

近期前馈方法通过融合多帧图像，直接预测驾驶场景的三维几何与高斯表示 [3, 6, 45, 48]。运动与可见性估计对齐动态对象，聚合输入序列中可见的表面。新视角或对象运动暴露出整个序列都未曾拍摄的表面，重建需要推断其几何与外观。

生成式重建通过资产先验、高斯补全或生成视图推断未观测内容 [17, 44, 47, 51]。与此同时，可组合重建将背景与运动对象分开表示，支持车辆移动和人体姿态控制 [5, 43, 49]。将生成补全用于这类场景，需要使补出的表面随所属对象运动。对象仅被部分观测，背景与其他对象的信息可为推断其缺失内容提供补充上下

文。

为此，我们提出 DriveCompose，从驾驶图像序列中构建可独立控制、并经过生成补全的三维场景。我们在世界坐标系中表示背景，在刚体资产自身的坐标系中表示其表面，并在参考姿态下表示人体、保留其骨架绑定 [5, 43]。补全直接在这些表示中进行，使生成的刚体和人体表面能够随所属对象运动或改变姿态（第 3.1 节）。在此基础上，模型通过共享场景上下文，联合补全背景与各对象的缺失内容。

图 2 概括构建与复用流程。视觉编码恢复几何与运动，规范聚合对齐观测，类型专属编码器生成组件潜码。局部注意力建模组件内部结构，跨组件记忆交换场景上下文，通过流匹配补全缺失内容 [18]。高斯解码器保留刚体与骨架绑定 [15]，使状态变化复用同一份完成内容（第 3.6 节）。

在 Waymo 的统一相机与参与者状态条件下，DriveCompose 改善了重建与轨迹外渲染。配对合成测试中，新增可见表面优于独立补全；真实编辑在不同参与者状态下复用同一份完成资产（第 4 节）。

本文的贡献包括：

- 提出 DriveCompose，从图像序列联合补全背景、车辆与人体，构建在相机、刚体和骨架状态变化时可复用的可组合高斯资产。
- 设计基于条件流匹配的跨组件潜空间补全模型。通过局部注意力建模各组件内部的空间关系，通过跨组件记忆汇集背景与参与者的特征，为各组件的缺失内容生成提供场景上下文。
- 通过条件重建、轨迹外渲染、资产编辑与组件消融评估框架及其关键机制。按可见率分组的诊断将联合补全的收益定位到背景与参与者中严重缺失的区域。

2. 相关工作

驾驶场景重建。 NeRF 与高斯泼溅为城市重建提供辐射表示 [15, 22]，NeuRAD 和 SplatAD 进一步发展面向驾驶场景的渲染 [11, 33]。前馈方法从图像学习几何恢复与高斯预测 [2, 4, 12, 35, 36]。对于驾驶日志，STORM 通过场景流聚合动态高斯，DGGT 则结合相机恢复、时间可见性和运动引导插值 [3, 45]。DrivingForward、StreetForward、PointForward 和 Instant NuRec 进一步探索环视输入、时序处理、点对齐表示及面向仿真的重建 [6, 14, 32, 48]。TokenGS 也通过可学习 token 解耦像素与高斯预测 [29]。

可组合场景与可控资产。 Neural Scene Graphs、Street Gaussians 和 DrivingGaussian 将场景分为背景与运动组件 [23, 43, 50]。OmniRe 包含刚体与关节化参与者的规范表示，UniSim 和 HUGSIM 则将重建内容接入闭环仿真 [5, 46, 49]。在资产层面，基于 SMPL 的人体模型和可驱动高斯方法提供规范表面与运动绑定 [13, 16, 20, 25, 27]；LHM 与 IDOL 推断可驱动人体，UrbanCAD 面向可控车辆 [21, 28, 52]。本文的补全变量保留这些既有组件身份、坐标系和运动绑定。

生成式重建与补全。 图像条件三维生成可通过生成视图 [9, 19, 30] 或编码几何与外观的结构化潜变量实现 [41, 42]。GenAssets 学习驾驶资产先验，CompleteSplat 补全隐藏的高斯内容，JRM 通过潜空间流匹配聚合未对齐的对象观测 [17, 40, 47]。LatentWorld 围绕实体和背景潜变量组织语义占据生成 [24]。DriveCompose 面向以驾驶日志为条件、可供 RGB 渲染的重建：共享补全模型在世界空间背景与规范刚体、人体潜码之间交换上下文。

驾驶场景与视频生成。 MagicDrive、DriveDreamer 和 Vista 以场景结构或控制为条件生成驾驶图像 [8, 10, 37]。StreetCrafter 用生成视图监督动态高斯重建，HorizonForge 将场景编辑与视频扩散结合 [38, 44]。WorldSplat 生成高斯并细化其渲染视频，DIFIX3D+ 则通过扩散模型细化图像 [39, 51]。DriveCompose 一次完成并保存背景与规范资产，随后按新相机与参与者状态渲染。

3. 方法

DriveCompose 将多视角观测对齐到规范支撑，联合补全潜码，并按指定状态组合解码资产（图 2）。

3.1. 问题定义与可组合表示

输入是同步图像日志 $\mathbf{I}_{t,v}$、时间戳、相机内参及相机到传感器支架的标定。受控评价给定支架位姿、实例身份、车辆框与根轨迹，以及目标人体关节。人体体型与绑定由上下文恢复，重建不使用目标 RGB 或测试 LiDAR。坐标约定与图像预处理见补充材料附录 D。

输出为可组合高斯场景

$$\mathcal{W} = \big(\mathcal{G}_b, C_{\text{sky}}, V_{\text{sky}}, \{\mathcal{A}_a\}, \mathcal{B}, \xi\big), \tag{1}$$

其中，$\mathcal{G}_b$ 是世界空间背景，C_{sky} 是天空立方体贴图，V_{sky} 表示其有效方向，$\mathcal{A}_a$ 是身份 a 对应的规范资产，$\mathcal{B}$ 是有限空间支撑，ξ 是采样种子。这些组件通过高斯泼溅渲染 [15]。车辆表示为局部几何与尺寸固定的刚体资产，人体另存静止骨架和蒙皮权重。场景状态控制这些固定组件的放置与关节运动。

我们通过条件生成建模缺失内容。令 $\mathcal{Q}$ 为恢复得到的查询布局，C 为其观测证据。补全模型采样未知潜码 $\mathbf{z}_u$，编解码器 D_ψ 将组合后的潜码解码为场景内容：

$$\mathbf{z}_u \sim p_\theta(\mathbf{z}_u \mid C, \mathcal{Q}), \qquad \mathcal{W} = D_\psi(\mathbf{z}^{\text{obs}}, \mathbf{z}_u; \mathcal{Q}). \tag{2}$$

查询布局为每个潜码指定空间位置和所属组件。补全在这一布局中生成未知潜码，解码后仍保留其组件身份与运动绑定。

3.2. 视觉恢复与规范聚合

Driving Log Encoder 从各图像提取 patch 特征，并在相机与时间戳之间交换池化上下文 [7, 34]。几何预测头输出相机光轴深度、法线、置信度、语义和实例归属，将

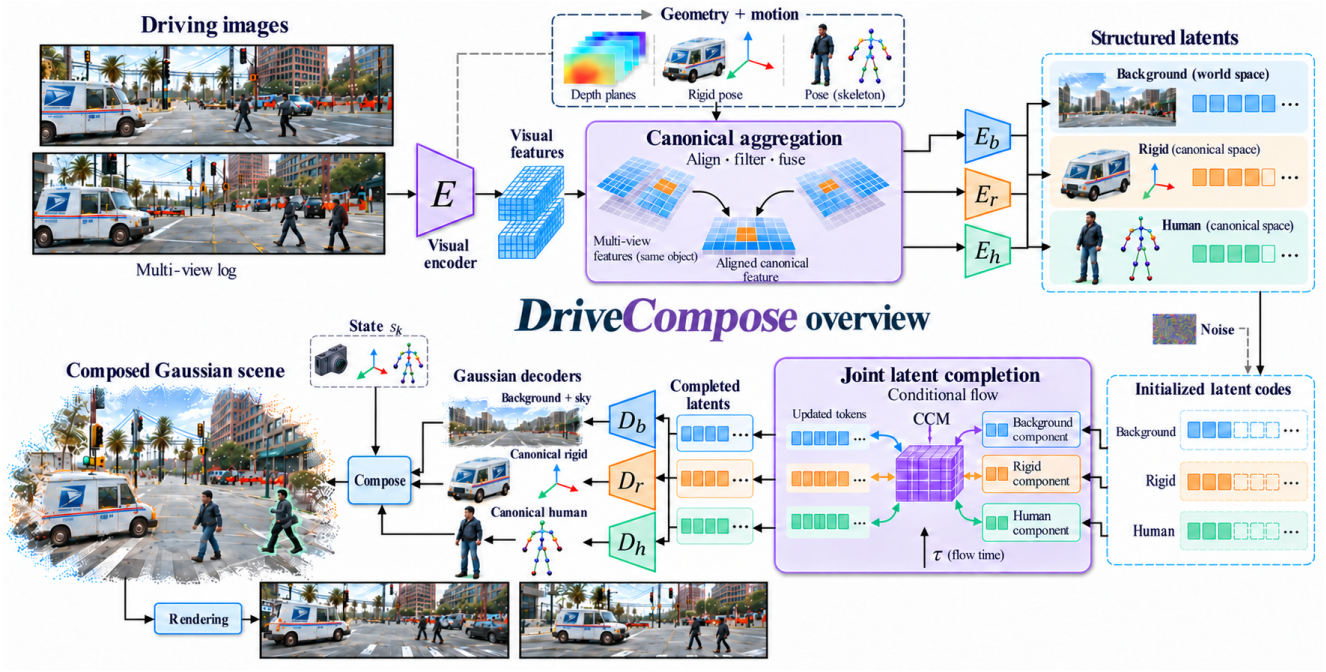

Figure 2. **DriveCompose 总览**。视觉编码与规范聚合恢复组件特征，类型专属编码器映射结构化潜码，联合补全和高斯解码生成背景、车辆与人体，用于状态驱动组合。场景与资产画面均为机制示意。

图像特征关联到三维表面及其所属组件。轨迹级身份槽将持久身份、尺寸和人体体型与逐帧变化的根位姿、关节旋转分开表示。网络结构与状态参数化细节见补充材料附录 D。

空间支撑。 每个查询存储规范位置 $\mathbf{q}_i$、单元尺度 $\boldsymbol{\delta}_i$、类型 k_i、局部注意力组 g_i 和参考世界坐标 $\mathbf{q}_i^w$。可靠深度样本提供表面锚点。背景锚点与有限世界网格结合；刚体锚点经逆 SE(3) 变换对齐后，与局部包围体中的网格结合。人体查询位于规范模板表面，天空查询为按立方体贴图面分组的单位方向。这些支撑为已见与缺失内容提供明确位置。

固定布局以规范坐标标识组件内容，以第一帧世界坐标 $\mathbf{q}_i^w$（包括人体蒙皮）联系组件与周围场景。

运动感知证据聚合。 对于每份观测，我们将规范查询放到对应的资产状态：

$$\mathbf{p}_i(t) = \begin{cases} \mathbf{q}_i, & k_i = \text{background}, \\ \mathrm{xyz}(\mathbf{T}_a^w(t)\bar{\mathbf{q}}_i), & k_i = \text{rigid}, \\ \mathrm{xyz}(\mathbf{T}_h^w(t)\mathbf{A}_i(t)\bar{\mathbf{q}}_i), & k_i = \text{human}. \end{cases} \tag{3}$$

其中，$\bar{\mathbf{q}}_i$ 为齐次坐标，xyz 提取欧氏坐标，$\mathbf{A}_i(t)$ 为加权蒙皮变换。投影得到查询深度 $z_{i,t,v}$，并采样图像特征 $\boldsymbol{\phi}_{i,t,v}$、深度 $d_{i,t,v}$ 和置信度 $c_{i,t,v}$，按置信度及归一化深度残差 $r = (d - z)/(\eta_{\text{abs}} + \eta_{\text{rel}} d)$ 为观测赋权。指示量 $a_{i,t,v}$ 选择同一实例中可见且深度一致的观测（附录 D）：

$$w_{i,t,v} = a_{i,t,v} c_{i,t,v} \exp(-r_{i,t,v}^2/2), \tag{4}$$

$$\mathbf{h}_i = \frac{\sum_{t,v} w_{i,t,v} [\boldsymbol{\phi}_{i,t,v}; r_{i,t,v}]}{\max(\varepsilon, \sum_{t,v} w_{i,t,v})}. \tag{5}$$

掩码 m_i、f_i 和 u_i 区分已见表面、射线标记的自由空间和未知内容，满足 $m_i + f_i + u_i = 1$。置信度取有效观测的最大值，两份可靠深度射线票确定自由空间标签。天空特征依据相机旋转和天空语义，按观察方向聚合。判定式与投影足迹掩码审计见附录 D。

3.3. 潜表示编码

类型专属编码器将 129 维聚合特征及空间支撑 $[\mathbf{h}_i; \mathbf{q}_i; \boldsymbol{\delta}_i]$ 输入带 LayerNorm 的 $135 \to 128 \to 128$ MLP，得到 $D = 128$ 维潜码，并保留查询类型、归属和坐标系。部分与完整分支共享此映射，掩码和置信度单独作为补全条件。未观测潜码置零，已见码记为 $\mathbf{z}^{\text{obs}}$。

3.4. 联合潜空间补全

生成式补全模块。 生成式补全模块（Generative Completion Module，GCM）由场景条件流 Transformer 与约束采样组成（图 3）。我们采用 DiT 风格的 Transformer [26] 参数化补全速度场，并通过流匹配训练 [18]。输入结合当前潜码、已见潜码、掩码、置信度、类型、两种坐标描述、单元尺度和池化日志特征。背景按空间邻域分

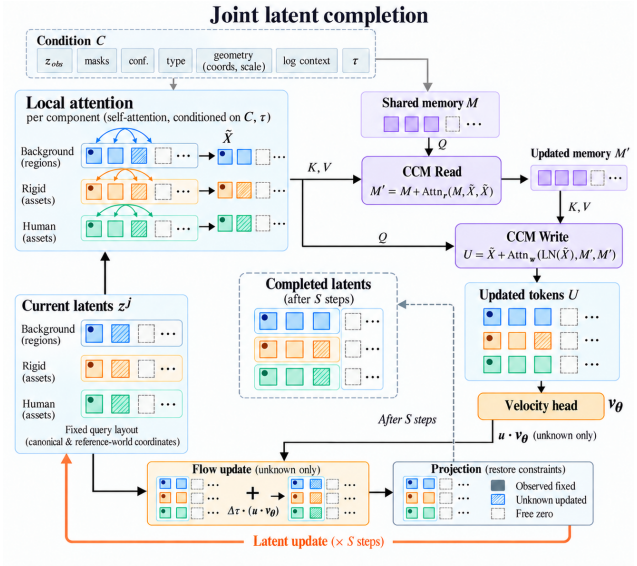

Figure 3. **联合潜空间补全**。CCM 读入局部特征并回写共享上下文，投影约束流更新只改变未知码。附录 L 提供放大图。

组，每个资产构成一个局部组，天空方向按立方体贴图面分组。局部自注意力分别处理各组，跨组件记忆模块（Cross-Component Memory，CCM）随后通过共享记忆交换上下文：

$$\mathbf{M}' = \mathbf{M} + \mathrm{Attn}_r(\mathbf{M}, \widetilde{\mathbf{X}}, \widetilde{\mathbf{X}}), \tag{6}$$

$$\mathbf{U} = \widetilde{\mathbf{X}} + \mathrm{Attn}_w(\mathrm{LN}(\widetilde{\mathbf{X}}), \mathbf{M}', \mathbf{M}'). \tag{7}$$

其中，$\widetilde{\mathbf{X}}$ 拼接局部 token，注意力参数依次为查询、键和值。$\mathbf{U}$ 后接残差前馈更新。流时间调制局部归一化，记忆由可学习 token 与日志摘要初始化。

流训练与约束采样。 令 $\mathbf{z}_1$ 为同一查询布局上的完整目标，$\boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I})$ 为高斯噪声。在流时间 $\tau \in [0, 1]$，我们仅对未知内容插值：

$$\mathbf{z}_\tau = m \odot \mathbf{z}^{\mathrm{obs}} + u \odot [(1-\tau)\boldsymbol{\epsilon} + \tau \mathbf{z}_1]. \tag{8}$$

已见潜码固定，自由空间潜码保持为零。未知查询的目标速度为 $\mathbf{z}_1 - \boldsymbol{\epsilon}$。引入可选损失选择器 s_i，目标为

$$\mathcal{L}_{\mathrm{flow}} = \frac{\sum_i u_i s_i \|\mathbf{v}_\theta(\mathbf{z}_\tau, \tau, C)_i - (\mathbf{z}_{1,i} - \boldsymbol{\epsilon}_i)\|_2^2}{D \max(1, \sum_i u_i s_i)}. \tag{9}$$

先验学习使用全部未知查询均具有有效目标的样本，s_i 在这些目标中选择损失项（第 3.7 节）。

推理时，以噪声初始化未知潜码，并执行 S 次 Euler 步，步长为 $\Delta\tau = 1/S$：

$$\mathbf{z}^{j+1} = \Pi_{m,f}\left[\mathbf{z}^j + \Delta\tau\, u \odot \mathbf{v}_\theta(\mathbf{z}^j, j/S, C)\right]. \tag{10}$$

每步后 $\Pi_{m,f}$ 恢复已见潜码、清零自由空间潜码。种子确定一次补全，解码一次后跨状态复用。

3.5. 分类型高斯解码

背景、刚体和人体高斯解码器分别将每个查询独立映射为中心位于其支撑单元内的 $K = 4$ 个子高斯。人体子高斯继承查询的蒙皮权重；刚体子高斯共用所属资产的刚体变换。不透明度乘以 $1 - f_i$，使自由空间查询不能产生可见高斯。独立天空头在观测支持的方向域 V_{sky} 内预测立方体贴图颜色。高斯与外观参数化详见补充材料附录 E。

各查询独立解码。冻结编解码器并保留已见潜码，使已见高斯参数保持不变。自由射线损失约束新增高斯对可见性与透明度混合的影响，第 4.5 节给出实测。

3.6. 场景组合

状态驱动渲染。 时刻 k 的状态 s_k 指定自车位姿、活动资产、刚体变换，以及人体根位姿与关节姿态。刚体位姿对规范高斯的中心和协方差施加刚体变换，人体关节姿态通过存储的蒙皮权重使高斯变形，补全表面因此随相应身体部位运动。具体变换见补充材料附录 C。渲染器合成背景、活动资产和有效天空：

$$o_k = \mathcal{R}(\mathrm{Compose}(\mathcal{W}, s_k), \mathcal{C}_k). \tag{11}$$

背景与规范资产保持固定，新相机及参与者状态复用同一份完成内容。

3.7. 训练流程

训练依次进行视觉恢复、潜表示拟合、补全先验学习和通过渲染适配。部分输入固定 $\mathcal{Q}$，包括单元尺度、组件归属及人体绑定。完整网格提供各单元内的表面样本，多视图渲染与冻结视觉编码器得到 $\mathbf{h}_i^{\mathrm{full}}$，再由共享的类型专属编码器映射为 $\mathbf{z}_{1,i} = E_{k_i}([\mathbf{h}_i^{\mathrm{full}}; \mathbf{q}_i; \boldsymbol{\delta}_i])$。无表面单元采用零特征和不透明度监督。

潜表示拟合结束后，恢复模块和 codec 保持冻结。阶段三使用每个未知查询均具有完整目标的合成样本；阶段四仅更新 GCM，以 1:3 混合完整合成样本和 740 条真实训练日志。四阶段共更新 287,360 步，目标构造、网络规模和训练设置详见附录 B。

4. 实验

我们评价 Waymo 上的条件重建、轨迹外渲染和完成资产复用，并通过组件、可见性及观测保持测试分析联合补全的收益。补充材料附录 A 报告 nuScenes 零样本迁移。

4.1. 实验设置

数据与监督。 Waymo 的 798 条训练序列拆为 740 条训练和 58 条开发序列，202 条验证序列用于测试。合成训练使用 10,000 个场景、80 张地图、10,000 辆车和 2,500 个人体身份。源地图、车辆基础模型与人体身份先划分，再生成外观 / 动作变体；真实日志按路段、采

集片段及可识别身份隔离。完整划分规模与监督见附录 B。

受控比较。 STORM、DGGT 和 StreetForward [3, 45, 48] 均随机初始化，在相同真实日志、合成场景和完整资产上重训。各方法使用自身监督目标，Ours 另用单元空域及模板绑定监督。统一状态适配器为预测高斯分配归属并转入规范坐标，用于刚体和骨架放置。所有方法共享上下文 RGB、标定、自车位姿、车辆框 / 根轨迹及目标人体关节，体型与绑定来自上下文，测试权重固定。训练成本和适配细节见附录 F。

采样与指标。 每条测试序列取 200 帧，共形成 2,020 个互不重叠的 20 帧、10 Hz 片段。三个前向相机在 $\{0, 5, 10, 15\}$ 提供上下文 [45]，其余 12 帧插值与四帧外推共形成 96,960 张目标图像，外推使用给定状态。以 240×160 图像 [14] 计算全图 / 动态 PSNR 和 SSIM，并在有效 LiDAR 点计算深度 AbsRel/δ_1。深度逐帧尺度对齐后评价，附录 F 同时报未对齐结果；指标按帧、片段、序列依次平均，各序列等权。

4.2. 动态场景重建

表 1 按 3:1 汇总插值与外推。DriveCompose 在六项指标上领先，相对各指标最强适配基线的全图与动态 PSNR 分别提高 1.154 和 2.340 dB。其插值 / 外推全图 PSNR 为 28.900 / 27.556 dB，动态 PSNR 为 25.500 / 23.700 dB。图 4 显示更清晰的参与者轮廓与道路结构。

Table 1. **Waymo 条件重建。**插值与外推以 3:1 汇总；完整分组结果见补充材料附录 F。

	完整图像		动态区域		逐帧尺度对齐深度	
方法	PSNR ↑	SSIM ↑	PSNR ↑	SSIM ↑	AbsRel ↓	δ_1 ↑
STORM	26.380	0.826	22.100	0.624	0.178	0.741
DGGT	27.410	0.794	22.710	0.651	0.249	0.668
StreetForward	27.010	0.818	20.919	0.592	0.197	0.759
Ours	**28.564**	**0.901**	**25.050**	**0.862**	**0.095**	**0.877**

4.3. 轨迹外渲染与缺失表面

相机横向偏移 ±1、±2、±4 m，方向、内参和时间戳固定 [6, 51]，比较扩散精修之前的高斯渲染。每个方向包含 121,200 张图像和 6,060 段 20 帧、10 Hz 视频，参考为相同片段、相机与时刻的原轨迹记录。左右方向分别计算 FID 和 FVD 后取均值（表 2；附录 H）。

图 5 展示偏移渲染及原轨迹参考。100 个合成测试场景提供输入始终未覆盖区域的配对评价。在 ±2 m 下，相对 w/o CCM，Ours 的隐藏区域 PSNR 从 21.56 增至 23.18 dB，LPIPS 从 0.236 降至 0.192，表面覆盖率从 89.7% 增至 95.0%，F-score@2 cm 从 81.3% 增至 88.6%。真实场景中，Ours 相对 w/o CCM 将共有支持集 RGB 重投影 MAE 从 0.028 降至 0.019，覆盖率从 86.9% 增至 92.4%。表面提取和对应评价见附录 H。

Table 2. **离轨视图分布质量。**左右方向分别计算 FID/FVD 后取均值。

方法	偏移 ±1 m		偏移 ±2 m		偏移 ±4 m	
	FID ↓	FVD ↓	FID ↓	FVD ↓	FID ↓	FVD ↓
STORM	61.97	722.27	83.72	1029.36	132.57	1704.16
DGGT	73.99	984.00	93.36	1197.03	128.01	1661.70
StreetForward	84.30	878.95	103.31	1095.02	123.58	1578.63
Ours	**28.52**	**544.27**	**37.43**	**673.17**	**58.19**	**817.13**

Table 3. **组件消融。**$T = 8$，恢复模块、codec 与目标视图相同。报告三个训练种子和三个生成种子的均值；完整 SD 见补充材料附录 G。

变体	全图			动态区域	
	PSNR ↑	SSIM ↑	LPIPS ↓	PSNR ↑	SSIM ↑
w/o GCM	27.137	0.867	0.183	23.431	0.811
w/o CCM	28.286	0.893	0.147	24.683	0.849
Ours	**28.913**	**0.911**	**0.129**	**25.617**	**0.873**

4.4. 消融与组件上下文

协议。 消融在每条测试序列取一个 29 时刻窗口，使用三相机、$T = 2, 4, 8$ 的嵌套输入及七个共享目标（附录 G）。变体共享恢复模块、codec、状态、数据和优化预算。训练均匀采样 T，推理使用 24 步 Euler 积分。三个训练种子各评价三个生成种子，全部平均，不选择最优样本。10,908 个学习版本及 202 个确定性窗口实例均可渲染，低质量输出保留计分。

补全与上下文。 w/o GCM 关闭非已见、非天空高斯。w/o CCM 将共享记忆替换为各组件独立记忆，保留相同参数与全局日志条件，并重新训练阶段三、四。表 3 中，相对 w/o GCM 的全图 / 动态 PSNR 增益为 1.776 / 2.186 dB，相对 w/o CCM 为 0.627 / 0.934 dB。Ours 和 w/o CCM 的全图 PSNR 训练种子 SD 分别为 0.061 和 0.074 dB。固定 checkpoint，在 $T = 2, 4, 8$ 时的 PSNR 增益为 1.104、0.738、0.627 dB，LPIPS 降幅为 0.041、0.028、0.018（附录 G）。

CCM 在哪里有效。 在 100 个合成场景上，按输入视图并集的表面覆盖率划分充分可见（≥ 80%）与严重缺失（≤ 20%）组。严重缺失背景 / 车辆 / 人体分别获得 1.02 / 1.28 / 1.54 dB 增益，充分可见组为 0.04 / 0.04 / 0.03 dB。在 Waymo 上，对同一组 Ours checkpoint 施加推理期读取遮罩，仅背景 / 其他车辆 / 其他人体分别为 28.721 / 28.574 / 28.352 dB，全部组件为 28.913

Figure 4. **动态场景条件重建**。每行一个样例，依次为真实目标、DGGT、STORM、StreetForward 与 Ours。

Figure 5. **相机左移 2 m 的离轨渲染**。各列依次为 GT、STORM、DGGT、StreetForward 与 Ours。GT 为原轨迹记录图像。

Table 4. **编辑后新增可见资产表面**。合成配对测试。车辆 / 人体覆盖阈值为 2 / 1 cm；PSNR、覆盖率越高越好，LPIPS 越低越好。

资产	变体	PSNR	LPIPS	覆盖率
车辆	w/o GCM	17.80	0.362	63.4%
	w/o CCM	22.46	0.218	91.8%
	Ours	**24.18**	**0.176**	**96.1%**
人体	w/o GCM	17.12	0.391	60.8%
	w/o CCM	21.38	0.247	88.6%
	Ours	**23.06**	**0.201**	**94.3%**

dB；重训的 w/o CCM 为 28.286 dB。读取范围干预详见附录 H。

4.5. 状态复用与观测保持

资产编辑。 20 个真实和 20 个身份隔离合成场景各含一个受测车辆与人体。相机平移 1 m、车辆旋转 30° 及人体换姿均复用固定完成资产。表 4 评价合成场景新增可见表面，车辆 / 人体覆盖阈值为 2 / 1 cm。

九组训练 / 生成种子下，真实车辆编辑成功 177 / 180 次，人体为 157 / 180 次，总成功率 92.78%；场景聚类 bootstrap 的 95% 区间为 85.28–99.17%。车辆尺寸与人体体型保持固定，人体原已见纹理经规范对应后的线性 RGB MAE 为 0.014。逐种子结果、盲评规则，以及肘弯、自遮挡和衣物失败见附录 I。

观测保持。 在固定相机与参与者状态下，相对仅已见场景，Ours 严格保持已见高斯参数，输入视角 PSNR 下降 0.029 dB，深度 MAE 增加 2 mm。在 2,020,000 条固定射线上，新增遮挡及严格自由射线违规率为 0.18% 和 0.07%；移除自由射线损失后增至 1.34% 和 0.91%。参数与渲染测量见附录 J。

效率。 在 RTX 4090（FP16、batch 1）上，构建耗时 2.66 ± 0.11 s，单相机状态装配与 240×160 渲染耗时 7.8 ± 0.4 ms，峰值显存 14.2 GB。CCM 增加 5.1% 构建时间。1,000 次查询的摊销成本为每图 10.46 ms，场景规模、同步、预热和重复次数详见附录 K。

5. 讨论

DriveCompose 在固定照明下重建有限区域，车辆采用刚体表示，人体绑定固定骨架和衣物体积。深度、身份与规范姿态的精度决定补全继承的已见锚点。图 4 的行人和停放皮卡附近存在残余重建伪影，编辑失败集中于大幅肘弯、腿部自遮挡和宽松衣物边界。重光照与衣物几何变化需要更丰富的外观和形变模型。

6. 结论

DriveCompose 联合补全世界空间背景与规范参与者潜码，保留组件身份和运动绑定，实现状态驱动复用。共享场景上下文改善缺失表面重建，固定高斯资产支持相机平移、车辆旋转和人体换姿。Waymo 重建、配对隐藏表面测试与真实场景编辑展示了完成内容的质量及复用能力。

LLM Usage Statement

OpenAI Codex 用于辅助论文修订、翻译、LaTeX 编辑与一致性检查。OpenAI Image Gen 用于生成图 1–3 及补充材料放大图中的概念场景与方法插图，这些图件均标明机制示意身份。报告的实验数值由作者提供，作者对科学内容负责。

References

[1] Holger Caesar, Varun Bankiti, Alex H. Lang, Sourabh Vora, Venice Erin Liong, Qiang Xu, Anush Krishnan, Yu Pan, Giancarlo Baldan, and Oscar Beijbom. nuScenes: A Multimodal Dataset for Autonomous Driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 11621–11631, 2020. 1

[2] David Charatan, Sizhe Lester Li, Andrea Tagliasacchi, and Vincent Sitzmann. pixelSplat: 3D Gaussian Splats from Image Pairs for Scalable Generalizable 3D Reconstruction. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 19457–19467, 2024. 2

[3] Xiaoxue Chen, Ziyi Xiong, Yuantao Chen, Gen Li, Nan Wang, Hongcheng Luo, Long Chen, Haiyang Sun, Bing Wang, Guang Chen, Hongyang Li, Ya-Qin Zhang, Hangjun Ye, and Hao Zhao. DGGT: Feedforward 4D Reconstruction of Dynamic Driving Scenes using Unposed Images. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 1265–1276, 2026. 1, 2, 5

[4] Yuedong Chen, Haofei Xu, Chuanxia Zheng, Bohan Zhuang, Marc Pollefeys, Andreas Geiger, Tat-Jen Cham, and Jianfei Cai. MVSplat: Efficient 3D Gaussian Splatting from Sparse Multi-View Images. In *European Conference on Computer Vision (ECCV)*, 2024. 2

[5] Ziyu Chen, Jiawei Yang, Jiahui Huang, Riccardo de Lutio, Janick Martinez Esturo, Boris Ivanovic, Or Litany, Zan Gojcic, Sanja Fidler, Marco Pavone, Li Song, and Yue Wang. OmniRe: Omni Urban Scene Reconstruction. In *International Conference on Learning Representations*, pages 85508–85527, 2025. 1, 2

[6] Cheng Chi, Xianqi Wang, Hongcheng Luo, Mingfei Tu, Gangwei Xu, Zehan Zhang, Bing Wang, Guang Chen, Hangjun Ye, Sida Peng, Xin Yang, and Haiyang Sun. PointForward: Feedforward Driving Reconstruction through Point-Aligned Representations. *arXiv preprint arXiv:2605.11594*, 2026. 1, 2, 5

[7] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An Image is Worth 16x16 Words: Transformers for Image Recognition at

Scale. In *International Conference on Learning Representations (ICLR)*, 2021. 2

[8] Ruiyuan Gao, Kai Chen, Enze Xie, Lanqing HONG, Zhenguo Li, Dit-Yan Yeung, and Qiang Xu. MagicDrive: Street View Generation with Diverse 3D Geometry Control. In *International Conference on Learning Representations*, pages 22841–22860, 2024. 2

[9] Ruiqi Gao, Aleksander Hołyński, Philipp Henzler, Arthur Brussee, Ricardo Martin-Brualla, Pratul Srinivasan, Jonathan T. Barron, and Ben Poole. CAT3D: Create Anything in 3D with Multi-View Diffusion Models. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 75468–75494, 2024. 2

[10] Shenyuan Gao, Jiazhi Yang, Li Chen, Kashyap Chitta, Yihang Qiu, Andreas Geiger, Jun Zhang, and Hongyang Li. Vista: A Generalizable Driving World Model with High Fidelity and Versatile Controllability. In *Advances in Neural Information Processing Systems*, pages 91560–91596, 2024. 2

[11] Georg Hess, Carl Lindström, Maryam Fatemi, Christoffer Petersson, and Lennart Svensson. SplatAD: Real-Time Lidar and Camera Rendering with 3D Gaussian Splatting for Autonomous Driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 11982–11992, 2025. 2

[12] Yicong Hong, Kai Zhang, Jiuxiang Gu, Sai Bi, Yang Zhou, Difan Liu, Feng Liu, Kalyan Sunkavalli, Trung Bui, and Hao Tan. LRM: Large Reconstruction Model for Single Image to 3D. In *International Conference on Learning Representations*, pages 50678–50702, 2024. 2

[13] Shoukang Hu, Tao Hu, and Ziwei Liu. GauHuman: Articulated Gaussian Splatting from Monocular Human Videos. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 20418–20431, 2024. 2

[14] Jiahui Huang, Jiawei Ren, Michal Tyszkiewicz, Bjoern Haefner, Michael Shelley, Xin Kang, Seung Wook Kim, Ning Xu, Qi Wu, Janick Martinez Esturo, Shengyu Huang, Nick Schneider, Laura Leal-Taixé, Zan Gojcic, and Sanja Fidler. Instant NuRec: Feed-Forward 3D Gaussian Reconstruction for Driving Scene Simulation. *arXiv preprint arXiv:2607.14203*, 2026. 2, 5

[15] Bernhard Kerbl, Georgios Kopanas, Thomas Leimkühler, and George Drettakis. 3D Gaussian Splatting for Real-Time Radiance Field Rendering. *ACM Transactions on Graphics*, 42(4), 2023. 2

[16] Muhammed Kocabas, Jen-Hao Rick Chang, James Gabriel, Oncel Tuzel, and Anurag Ranjan. HUGS: Human Gaussian Splats. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 505–515, 2024. 2

[17] Ziwei Liao, Mohamed Sayed, Steven L. Waslander, Sara Vicente, Daniyar Turmukhambetov, and Michael Firman. Complete Gaussian Splats from a Single Image with Denoising Diffusion Models. *arXiv preprint arXiv:2508.21542*, 2025. 1, 2

[18] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow Matching for Generative Modeling. In *International Conference on Learning Representations*, 2023. 2, 3

[19] Ruoshi Liu, Rundi Wu, Basile Van Hoorick, Pavel Tokmakov, Sergey Zakharov, and Carl Vondrick. Zero-1-to-3: Zero-shot One Image to 3D Object. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 9298–9309, 2023. 2

[20] Matthew Loper, Naureen Mahmood, Javier Romero, Gerard Pons-Moll, and Michael J. Black. SMPL: A Skinned Multi-Person Linear Model. *ACM Trans. Graphics (Proc. SIGGRAPH Asia)*, 34(6):248:1–248:16, 2015. 2

[21] Yichong Lu, Yichi Cai, Shangzhan Zhang, Hongyu Zhou, Haoji Hu, Huimin Yu, Andreas Geiger, and Yiyi Liao. UrbanCAD: Towards Highly Controllable and Photorealistic 3D Vehicles for Urban Scene Simulation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 27519–27530, 2025. 2

[22] Ben Mildenhall, Pratul P. Srinivasan, Matthew Tancik, Jonathan T. Barron, Ravi Ramamoorthi, and Ren Ng. NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis. In *European Conference on Computer Vision (ECCV)*, 2020. 2

[23] Julian Ost, Fahim Mannan, Nils Thuerey, Julian Knodt, and Felix Heide. Neural Scene Graphs for Dynamic Scenes. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2856–2865, 2021. 2

[24] Jinhyung Park, Navyata Sanghvi, Erica Weng, Shawn Hunt, Shinya Tanaka, Hironobu Fujiyoshi, and Kris Kitani. Grounded Latents for Entity-Centric 4D Scene Generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 21420–21430, 2026. 2

[25] Georgios Pavlakos, Vasileios Choutas, Nima Ghorbani, Timo Bolkart, Ahmed A. A. Osman, Dimitrios Tzionas, and Michael J. Black. Expressive Body Capture: 3D Hands, Face, and Body From a Single Image. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 10975–10985, 2019. 2

[26] William Peebles and Saining Xie. Scalable Diffusion Models with Transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 4195–4205, 2023. 3

[27] Zhiyin Qian, Shaofei Wang, Marko Mihajlovic, Andreas Geiger, and Siyu Tang. 3DGS-Avatar: Animatable Avatars via Deformable 3D Gaussian Splatting. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 5020–5030, 2024. 2

[28] Lingteng Qiu, Xiaodong Gu, Peihao Li, Qi Zuo, Weichao Shen, Junfei Zhang, Kejie Qiu, Weihao Yuan, Guanying Chen, Zilong Dong, and Liefeng Bo. LHM: Large Animatable Human Reconstruction Model for Single Image to 3D in Seconds. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 14184–14194, 2025. 2

[29] Jiawei Ren, Michal Jan Tyszkiewicz, Jiahui Huang, and Zan Gojcic. TokenGS: Decoupling 3D Gaussian Prediction from Pixels with Learnable Tokens. In *Proceedings of*

the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pages 15365–15375, 2026. 2

[30] Yichun Shi, Peng Wang, Jianglong Ye, Long Mai, Kejie Li, and Xiao Yang. MVDream: Multi-view Diffusion for 3D Generation. In *International Conference on Learning Representations*, pages 39838–39859, 2024. 2

[31] Pei Sun, Henrik Kretzschmar, Xerxes Dotiwalla, Aurelien Chouard, Vijaysai Patnaik, Paul Tsui, James Guo, Yin Zhou, Yuning Chai, Benjamin Caine, Vijay Vasudevan, Wei Han, Jiquan Ngiam, Hang Zhao, Aleksei Timofeev, Scott Ettinger, Maxim Krivokon, Amy Gao, Aditya Joshi, Sheng Zhao, Shuyang Cheng, Yu Zhang, Jonathon Shlens, Zhifeng Chen, and Dragomir Anguelov. Scalability in Perception for Autonomous Driving: Waymo Open Dataset. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2446–2454, 2020. 1

[32] Qijian Tian, Xin Tan, Yuan Xie, and Lizhuang Ma. DrivingForward: Feed-forward 3D Gaussian Splatting for Driving Scene Reconstruction from Flexible Surround-view Input. In *Proceedings of the AAAI Conference on Artificial Intelligence*, pages 7374–7382, 2025. 2

[33] Adam Tonderski, Carl Lindström, Georg Hess, William Ljungbergh, Lennart Svensson, and Christoffer Petersson. NeuRAD: Neural Rendering for Autonomous Driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14895–14904, 2024. 2

[34] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Ł ukasz Kaiser, and Illia Polosukhin. Attention is All you Need. In *Advances in Neural Information Processing Systems*, 2017. 2

[35] Jianyuan Wang, Minghao Chen, Nikita Karaev, Andrea Vedaldi, Christian Rupprecht, and David Novotny. VGGT: Visual Geometry Grounded Transformer. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 5294–5306, 2025. 2

[36] Shuzhe Wang, Vincent Leroy, Yohann Cabon, Boris Chidlovskii, and Jerome Revaud. DUSt3R: Geometric 3D Vision Made Easy. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 20697–20709, 2024. 2

[37] Xiaofeng Wang, Zheng Zhu, Guan Huang, Xinze Chen, Jiagang Zhu, and Jiwen Lu. DriveDreamer: Towards Real-world-driven World Models for Autonomous Driving. In *European Conference on Computer Vision (ECCV)*, 2024. 2

[38] Yifan Wang, Francesco Pittaluga, Zaid Tasneem, Chenyu You, Manmohan Chandraker, and Ziyu Jiang. HorizonForge: Driving Scene Editing with Any Trajectories and Any Vehicles. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026. 2

[39] Jay Zhangjie Wu, Yuxuan Zhang, Haithem Turki, Xuanchi Ren, Jun Gao, Mike Zheng Shou, Sanja Fidler, Zan Gojcic, and Huan Ling. DIFIX3D+: Improving 3D Reconstructions with Single-Step Diffusion Models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 26024–26035, 2025. 2

[40] Qirui Wu, Yawar Siddiqui, Duncan Frost, Samir Aroudj, Armen Avetisyan, Richard Newcombe, Angel X. Chang, Jakob Engel, and Henry Howard-Jenkins. JRM: Joint Reconstruction Model for Multiple Objects without Alignment. *arXiv preprint arXiv:2603.25985*, 2026. 2

[41] Jianfeng Xiang, Zelong Lv, Sicheng Xu, Yu Deng, Ruicheng Wang, Bowen Zhang, Dong Chen, Xin Tong, and Jiaolong Yang. Structured 3D Latents for Scalable and Versatile 3D Generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 21469–21480, 2025. 2

[42] Jianfeng Xiang, Xiaoxue Chen, Sicheng Xu, Ruicheng Wang, Zelong Lv, Yu Deng, Hongyuan Zhu, Yue Dong, Hao Zhao, Nicholas Jing Yuan, and Jiaolong Yang. Native and Compact Structured Latents for 3D Generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14419–14429, 2026. 2

[43] Yunzhi Yan, Haotong Lin, Chenxu Zhou, Weijie Wang, Haiyang Sun, Kun Zhan, Xianpeng Lang, Xiaowei Zhou, and Sida Peng. Street Gaussians: Modeling Dynamic Urban Scenes with Gaussian Splatting. In *European Conference on Computer Vision (ECCV)*, 2024. 1, 2

[44] Yunzhi Yan, Zhen Xu, Haotong Lin, Haian Jin, Haoyu Guo, Yida Wang, Kun Zhan, Xianpeng Lang, Hujun Bao, Xiaowei Zhou, and Sida Peng. StreetCrafter: Street View Synthesis with Controllable Video Diffusion Models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 822–832, 2025. 1, 2

[45] Jiawei Yang, Jiahui Huang, Boris Ivanovic, Yuxiao Chen, Yan Wang, Boyi Li, Yurong You, Apoorva Sharma, Maximilian Igl, Peter Karkus, Danfei Xu, Yue Wang, and Marco Pavone. STORM: Spatio-TempOral Reconstruction Model For Large-Scale Outdoor Scenes. In *International Conference on Learning Representations*, pages 50446–50465, 2025. 1, 2, 5

[46] Ze Yang, Yun Chen, Jingkang Wang, Sivabalan Manivasagam, Wei-Chiu Ma, Anqi Joyce Yang, and Raquel Urtasun. UniSim: A Neural Closed-Loop Sensor Simulator. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 1389–1399, 2023. 1, 2

[47] Ze Yang, Jingkang Wang, Haowei Zhang, Sivabalan Manivasagam, Yun Chen, and Raquel Urtasun. GenAssets: Generating in-the-wild 3D Assets in Latent Space. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 22392–22403, 2025. 1, 2

[48] Zhongrui Yu, Zhao Wang, Yijia Xie, Yida Wang, Xueyang Zhang, Yifei Zhan, and Kun Zhan. StreetForward: Perceiving Dynamic Street with Feedforward Causal Attention. *arXiv preprint arXiv:2603.19552*, 2026. 1, 2, 5

[49] Hongyu Zhou, Longzhong Lin, Jiabao Wang, Yichong Lu, Dongfeng Bai, Bingbing Liu, Yue Wang, Andreas Geiger, and Yiyi Liao. HUGSIM: A Real-Time, Photo-Realistic and Closed-Loop Simulator for Autonomous Driving. *arXiv preprint arXiv:2412.01718*, 2024. 1, 2

[50] Xiaoyu Zhou, Zhiwei Lin, Xiaojun Shan, Yongtao Wang, Deqing Sun, and Ming-Hsuan Yang. DrivingGaussian: Composite Gaussian Splatting for Surrounding Dynamic Autonomous Driving Scenes. In *Proceedings of the IEEE/CVF*

Conference on Computer Vision and Pattern Recognition (CVPR), pages 21634–21643, 2024. 2

[51] Ziyue Zhu, Zhanqian Wu, Zhenxin Zhu, Lijun Zhou, Haiyang Sun, Bing Wan, Kun Ma, Guang Chen, Hangjun Ye, Jin Xie, and Jian Yang. WorldSplat: Gaussian-Centric Feed-Forward 4D Scene Generation for Autonomous Driving. *arXiv preprint arXiv:2509.23402*, 2025. 1, 2, 5

[52] Yiyu Zhuang, Jiaxi Lv, Hao Wen, Qing Shuai, Ailing Zeng, Hao Zhu, Shifeng Chen, Yujiu Yang, Xun Cao, and Wei Liu. IDOL: Instant Photorealistic 3D Human Creation from a Single Image. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 26308–26319, 2025. 2